Especialidad formativa
IFCD093PO

Orbe

Machine Learning aplicado usando Python

Horas formativas 150 h

© Autor: Entenova Gnosis

Edita: Orbe
B 84943885
C/Marie Curie Nº 20 Conjunto Possibilia, Edificio B. Planta Baja, Local D, 29590 Malaga
Tlf. 951 171 027

Edición: octubre 2025
ISBN: 979-13-88048-09-8

Cualquier forma de reproducción, distribución, comunicación pública o transformación de esta obra solo puede realizarse con la autorización de sus titulares, salvo excepción prevista por la ley. Diríjase a CEDRO (Centro Español de Derechos Reprográficos, www.cedro.org) si necesita fotocopiar o escanear algún fragmento de esta obra.

Imprime: Veprix https://www.veprix.com/ Tlf: 913300699

Manual /

IFCD093PO

Machine learning aplicado usando Python

150 horas de formación

Orbe

PRESENTACIÓN

La especialidad formativa es una agrupación de competencias profesionales, contenidos, y especificaciones técnicas que responde:

- A un conjunto de actividades de trabajo enmarcadas en una fase del proceso de producción y con funciones afines.
- A la adquisición de competencias transversales necesarias para el desempeño adecuado en el entorno y contexto profesional.

Cada especialidad formativa está adscrita a una familia y área profesional, y tiene asignado un determinado nivel de cualificación (niveles 1, 2, 3, 4 y 5).

El presente volumen incluye el desarrollo teórico del contenido basado en el programa de la especialidad formativa IFCD093PO, "Machine Learning aplicado usando Python". Junto al desarrollo teórico, también encontrará un conjunto de ejercicios de autoevaluación y actividades prácticas mediante los cuales se contribuye a la comprensión y asimilación del temario, según los objetivos didácticos formulados en el programa oficial.

ESPECIALIDAD FORMATIVA: MACHINE LEARNING APLICADO USANDO PYTHON

- Código: IFCD093PO
- Familia profesional: Informática y comunicaciones
- Área profesional: Desarrollo
- Horas de formación: 150

OBJETIVO GENERAL

- El curso tiene como objetivo principal formar al alumno en el desarrollo de sistemas predictivos mediante Machine Learning con Python, abarcando desde la introducción teórica hasta la implementación práctica con modelos supervisados y no supervisados. Se hace énfasis en el uso eficiente de librerías especializadas, la correcta preparación de datos, la validación de resultados y la construcción de pipelines reproducibles. Asimismo, se integran capacidades transversales como la evaluación ética de los modelos, la prevención del data leakage, la interpretación mediante técnicas como SHAP o permutation importance y, en su caso, el tratamiento de series temporales. Al finalizar, el alumno estará capacitado para afrontar proyectos de ML con rigor técnico y aplicabilidad real..

ÍNDICE

MÓDULO 1. INTRODUCCIÓN AL CURSO 9

1.1. Introducción al Python 10
1.2. Librería de Python para Machine Learning 18
1.3. Machine Learning. Introducción 27

MÓDULO 2. APRENDIZAJE SUPERVISADO 39

2.1. Definición y aplicaciones 40
2.2. Medidas de rendimiento 49
2.3. Modelos lineales 58
2.4. Modelos supervisados de ML: árboles, SVM, redes neuronales 67
2.5. Combinación de modelos. Random Forest 76

MÓDULO 3. APRENDIZAJE NO SUPERVISADO 85

3.1. Definición y aplicaciones 86
3.2. Medidas de rendimiento 97
3.3. Clustering 106
3.4. Biclustering 115
3.5. Manifolds 124
3.6. Análisis de la cesta 132

GLOSARIO 145
AUTOEVALUACIÓN 150

1

Introducción al curso

ÍNDICE

1.1. Introducción al Python

1.2. Librería de Python para Machine Learning.

1.3. Machine Learning. Introducción.

OBJETIVO

Este tema tiene como objetivo familiarizar al alumno con el entorno de trabajo y los fundamentos conceptuales del aprendizaje automático. Se aborda la instalación y configuración de Python y su ecosistema, incluyendo el uso de entornos virtuales, cuadernos interactivos y gestores de paquetes como pip y conda. Se presentan las principales bibliotecas para ciencia de datos y Machine Learning (scikit-learn, matplotlib, scipy, imbalanced-learn), así como la estructura de los proyectos, desde el análisis exploratorio hasta el despliegue. Además, se introducen los conceptos clave del aprendizaje automático, diferenciando entre tareas supervisadas, no supervisadas y por refuerzo, y se explica el flujo general de un proyecto de ML.

El aprendizaje automático utiliza algoritmos para identificar patrones en datos y generar modelos predictivos. Python destaca en este ámbito por su ecosistema de bibliotecas especializadas como scikit-learn y TensorFlow, que simplifican la implementación y experimentación. Los algoritmos de machine learning se clasifican principalmente en:

- Supervisados: Requieren datos etiquetados para predecir salidas, como regresión lineal y clasificación.
- No supervisados: Analizan datos sin etiquetas, agrupando o reduciendo la dimensionalidad (e.g., clustering, PCA).
- Por refuerzo: Aprenden mediante recompensas y penalizaciones, optimizando secuencias de acciones.

El flujo de trabajo típico comprende:

- Preparación de datos: limpieza, normalización y división en conjuntos de entrenamiento y prueba.
- Selección y configuración del modelo.
- Entrenamiento y validación.
- Evaluación con métricas como precisión, recall o matriz de confusión.

¿Sabías que...?

Python se ha consolidado como el lenguaje estándar en machine learning gracias a su sintaxis sencilla y a la integración de potentes librerías científicas, lo que permite desarrollar prototipos funcionales en pocas líneas de código.

1.1. Introducción al Python

Python, un lenguaje de programación interpretado de alto nivel, destaca por su sintaxis clara y concisa, lo que facilita su adopción en el desarrollo de aplicaciones de diversa complejidad. Su popularidad en el ámbito del machine learning radica en la amplia disponibilidad de bibliotecas dedicadas y su capacidad para integrarse con otras herramientas y lenguajes. La curva de aprendizaje moderada y la extensa comunidad de usuarios convierten a Python en la elección predilecta para científicos de datos e ingenieros de machine learning.

El primer paso operativo para utilizar Python consiste en instalar el entorno de desarrollo adecuado. Existen diversas alternativas, siendo las más comunes la instalación directa de Python desde el sitio oficial y el uso de distribuciones científicas como Anaconda. Python soporta múltiples sistemas operativos, permitiendo la ejecución de scripts tanto en Windows, macOS como en GNU/Linux. La versión recomendada para proyectos de machine learning es Python 3.8 o superior, debido a las mejoras en el manejo de memoria y compatibilidad con bibliotecas modernas.

Para instalar Python de forma estándar, se recomienda el procedimiento siguiente:

- Descargar el instalador correspondiente al sistema operativo desde https://www.python.org/downloads/.
- Ejecutar el instalador, marcando la opción "Add Python to PATH" para facilitar el acceso desde la terminal.
- Verificar la instalación abriendo una terminal o línea de comandos y ejecutando:

```
python --version
```

- Instalar un editor de código o entorno de desarrollo integrado (IDE). Las opciones más utilizadas en proyectos de machine learning son Visual Studio Code, PyCharm y Jupyter Notebook.

Las distribuciones como Anaconda simplifican la gestión de entornos y la instalación de bibliotecas científicas mediante conda, un gestor de paquetes especializado. Anaconda incluye Python y una amplia selección de herramientas científicas, permitiendo crear entornos aislados para evitar conflictos de dependencias. Para instalar Anaconda:

- Descargar el instalador desde https://www.anaconda.com/products/distribution.
- Ejecutar el instalador y seguir las instrucciones.
- Abrir Anaconda Navigator o utilizar la terminal para gestionar entornos.
- Crear un entorno de trabajo específico con:

```
conda create -n ml_env python=3.10
```

- Activar el entorno ejecutando:

```
conda activate ml_env
```

La selección del entorno de desarrollo depende de las preferencias personales y los requerimientos del proyecto. Jupyter Notebook es especialmente útil para

exploración y prototipado rápido en machine learning, permitiendo combinar código, visualizaciones y notas en un único documento interactivo.

Una vez instalado Python y configurado el entorno de desarrollo, el siguiente aspecto fundamental es la sintaxis básica. Python utiliza indentación para definir bloques de código, eliminando la necesidad de llaves o palabras clave como en otros lenguajes. Esta característica promueve la legibilidad y la organización estructurada del código. Todo programa en Python se compone de instrucciones secuenciales, donde el orden de ejecución corresponde al flujo del script.

El manejo de variables resulta directo y flexible. En Python, no se requiere declarar el tipo de una variable antes de su uso, ya que el lenguaje es dinámicamente tipado. La asignación de valores se realiza mediante el operador '='. Los nombres de variables deben comenzar con una letra o guion bajo, y pueden contener letras, números y guiones bajos. Están prohibidas las palabras reservadas del lenguaje.

Los tipos de datos primitivos más empleados en Python incluyen:

- int: Números enteros.
- float: Números decimales en punto flotante.
- str: Cadenas de texto.
- bool: Valores booleanos (True, False).

Los tipos de datos compuestos amplían las capacidades del lenguaje:

- list: Secuencias ordenadas y mutables de elementos.
- tuple: Secuencias ordenadas e inmutables.
- dict: Colecciones de pares clave-valor, no ordenadas hasta Python 3.6.
- set: Colecciones no ordenadas de elementos únicos.

La siguiente tabla compara las características principales de los tipos de datos compuestos más empleados:

Tipo	Ordenado	Mutable	Permite duplicados	Acceso por índice	Sintaxis de ejemplo
list	Sí	Sí	Sí	Sí	[1, 2, 3]
tuple	Sí	No	Sí	Sí	(1, 2, 3)

Tipo	Ordenado	Mutable	Permite duplicados	Acceso por índice	Sintaxis de ejemplo
dict	Sí*	Sí	Claves únicas	Por clave	{'a': 1, 'b': 2}
set	No	Sí	No	No	{1, 2, 3}

** Desde Python 3.7, los diccionarios mantienen el orden de inserción.*

El control de flujo en Python se gestiona mediante instrucciones condicionales y estructuras de repetición, lo que permite la ejecución selectiva o repetitiva de bloques de código según condiciones evaluadas en tiempo real.

Las instrucciones condicionales utilizan la palabra clave `if`, y pueden ampliarse con `elif` y `else` para cubrir múltiples casos. La sintaxis respeta la indentación para delimitar los bloques de código:

```
x = 10
if x > 0:
    print("El número es positivo.")
elif x == 0:
    print("El número es cero.")
else:
    print("El número es negativo.")
```

Las estructuras de repetición más frecuentes son `for` y `while`. El bucle `for` recorre secuencias como listas, tuplas, cadenas o rangos, permitiendo la iteración controlada. El bucle `while` repite un bloque de código mientras una condición se mantenga verdadera.

```
for i in range(5):
    print(i)
```

La función `range()` genera una secuencia de números, facilitando la iteración repetida. El bucle anterior imprimirá los números del 0 al 4.

Las funciones en Python encapsulan bloques de código reutilizables. Se definen mediante la palabra clave `def`, seguidas del nombre de la función y, opcionalmente, parámetros entre paréntesis. Las funciones pueden devolver valores utilizando la instrucción `return`.

```
def suma(a, b):
    return a + b
resultado = suma(3, 7)
print(resultado)
```

Python permite el uso de funciones anónimas (lambdas) para operaciones simples, especialmente útiles en programación funcional y manipulación de colecciones.

Las estructuras de datos integradas y la gestión automática de memoria proporcionan una base sólida para el desarrollo de algoritmos de machine learning, donde la manipulación eficiente de datos resulta fundamental. La interacción con archivos externos se realiza mediante funciones estándar de lectura y escritura, posibilitando la importación de conjuntos de datos desde archivos CSV, JSON o bases de datos.

Una operación básica de lectura de archivos en Python se realiza con la instrucción `open`, especificando el modo de apertura ('r' para lectura, 'w' para escritura):

```
with open('datos.txt', 'r') as archivo:
    contenido = archivo.read()
    print(contenido)
```

La instrucción `with` garantiza el cierre automático del archivo, optimizando la gestión de recursos.

La gestión de errores se implementa mediante el bloque `try-except`, que captura excepciones y permite un manejo controlado de situaciones imprevistas durante la ejecución del código.

```
try:
    resultado = 10 / 0
except ZeroDivisionError:
    print("No se puede dividir entre cero.")
```

El soporte para módulos y paquetes permite organizar el código en archivos y carpetas, promoviendo la reutilización y la mantenibilidad. Los módulos estándar cubren funcionalidades como matemáticas, manipulación de fechas, acceso a sistemas de archivos y comunicación en red. La importación de módulos se realiza con la instrucción `import`:

```
import math
print(math.sqrt(16))
```

Las bibliotecas externas se instalan habitualmente con pip, el gestor de paquetes de Python. Por ejemplo, para instalar la biblioteca numpy, se ejecuta:

```
pip install numpy
```

En el entorno científico, la gestión de dependencias mediante entornos virtuales es una práctica recomendada para evitar conflictos entre proyectos. Los entornos virtuales se crean con `venv` o mediante gestores como `conda` en Anaconda.

- Para crear un entorno virtual con venv:

  ```
  python -m venv mi_entorno
  ```

- Para activarlo en Windows:

  ```
  mi_entorno\Scripts\activate
  ```

- Para activarlo en macOS/Linux:

  ```
  source mi_entorno/bin/activate
  ```

La desactivación se realiza con el comando `deactivate`.

El diseño de scripts en Python se apoya en la simplicidad y modularidad. Un script típico consta de la declaración de variables, operaciones sobre datos, control de flujo y salida de resultados. La estructuración clara y la documentación con comentarios (`#`) favorecen la comprensión y el mantenimiento a largo plazo.

Python incorpora convenciones de estilo recogidas en el documento PEP 8, que recomienda buenas prácticas para nombrado de variables, espaciado, indentación (4 espacios por nivel) y longitud de líneas. El cumplimiento de estas recomendaciones agiliza la colaboración en equipos y la revisión de código.

La interpolación de cadenas y el formateo flexible permiten generar mensajes o resultados personalizados. Python ofrece varias formas de formatear cadenas, siendo las más utilizadas el método `format()` y las f-strings (disponibles desde Python 3.6):

```
nombre = "Ana"
edad = 28
print(f"{nombre} tiene {edad} años.")
```

La manipulación de listas y otras estructuras de datos se enriquece con operaciones de comprensión (list comprehensions), que simplifican la creación de nuevas listas a partir de secuencias existentes:

```
cuadrados = [x 2 for x in range(10)]
print(cuadrados)
```

La comprensión de listas proporciona una sintaxis compacta y eficiente para transformar y filtrar datos, aspecto relevante en el preprocesamiento de conjuntos de datos para machine learning.

El uso de bibliotecas científicas como numpy, pandas y matplotlib se fundamenta en la estructura básica de Python y amplía las posibilidades de análisis, manipulación y visualización de datos. La importación selectiva de funciones o submódulos optimiza el rendimiento y la claridad del código:

```
import numpy as np
import pandas as pd
```

La integración con Jupyter Notebook facilita la experimentación interactiva, permitiendo ejecutar bloques de código y visualizar resultados de forma inmediata. Los notebooks combinan código, resultados, visualizaciones y anotaciones, lo que los convierte en la herramienta preferente para documentación y prototipado en machine learning.

La gestión de dependencias y la actualización de paquetes requieren una supervisión constante para evitar incompatibilidades. Los archivos `requirements.txt` y la herramienta `pip freeze` permiten listar y reproducir el entorno de trabajo:

- Para generar un archivo de dependencias:

```
pip freeze > requirements.txt
```

- Para instalar dependencias desde un archivo:

```
pip install -r requirements.txt
```

La automatización de tareas repetitivas mediante scripts y la integración con sistemas de control de versiones como Git optimizan el flujo de trabajo en proyectos de machine learning. La modularización y la documentación exhaustiva resultan esenciales para asegurar la sostenibilidad y escalabilidad de los desarrollos.

En la fase de prototipado, la importación y preprocesamiento de datos son tareas recurrentes. Python facilita la lectura de archivos CSV, la limpieza de datos y la transformación de estructuras mediante pandas:

```
import pandas as pd
df = pd.read_csv('datos.csv')
print(df.head())
```

La función `head()` muestra las primeras filas del DataFrame, permitiendo una inspección rápida de los datos importados.

La capacidad de Python para interactuar con APIs externas, manejar grandes volúmenes de datos y realizar operaciones vectorizadas hace que sea especialmente adecuado para aplicaciones de machine learning. El soporte para la programación orientada a objetos (POO) permite estructurar los modelos y flujos de trabajo en torno a clases y objetos, promoviendo la reutilización y la abstracción.

Un ejemplo básico de clase en Python:

```
class Perro:
    def __init__(self, nombre, edad):
self.nombre = nombre
self.edad = edad
    def ladrar(self):
print(f"{self.nombre} dice: ¡Guau!")
mi_perro = Perro("Max", 4)
mi_perro.ladrar()
```

La definición de clases permite encapsular datos y comportamientos, facilitando la modelización de entidades y procesos complejos, como los algoritmos de machine learning.

Toma nota

La comprensión sólida de la sintaxis, los tipos de datos y la estructura básica de Python es imprescindible para abordar con eficacia los desafíos del machine learning, ya que estos elementos constituyen la base operativa sobre la que se construyen algoritmos, se procesan datos y se desarrollan modelos predictivos robustos.

La interoperabilidad de Python con otros lenguajes y sistemas, su soporte para concurrencia y paralelismo, y la facilidad para desplegar aplicaciones completan el conjunto de características que lo posicionan como una herramienta robusta y versátil en el ámbito científico y de la ingeniería.

Micro-caso aplicado: Un equipo de análisis de datos necesita preprocesar grandes volúmenes de registros de sensores ambientales. Usan Python para automatizar la limpieza, conversión y análisis de los datos, aprovechando la flexibilidad de las listas y los diccionarios, así como la integración con pandas y numpy. La estructura clara del código y la gestión eficiente de entornos virtuales les permite mantener versiones reproducibles y adaptar el flujo de trabajo a diferentes proyectos de machine learning.

1.2. Librería de Python para Machine Learning

Las librerías de Python especializadas en Machine Learning constituyen el eje operativo para el desarrollo de soluciones inteligentes en la industria moderna. Dominar su uso permite diseñar, entrenar y validar modelos predictivos con eficiencia y escalabilidad. Scikit-learn, TensorFlow y Keras representan la base tecnológica más extendida para abordar tareas de clasificación, regresión y procesamiento avanzado de datos en entornos productivos y de investigación.

Scikit-learn destaca por su interfaz consistente, su enfoque en algoritmos supervisados y no supervisados, y su integración nativa con estructuras de datos de Numpy y Pandas. La arquitectura modular de esta librería facilita la manipulación de conjuntos de datos, la transformación de variables y la evaluación sistemática de modelos. Por su parte, TensorFlow se orienta a la computación numérica eficiente, el desarrollo de redes neuronales profundas y la ejecución en hardware heterogéneo (CPU, GPU, TPU), mientras que Keras proporciona una API de alto nivel sobre TensorFlow, simplificando la construcción y entrenamiento de redes neuronales mediante una sintaxis intuitiva y expresiva.

El flujo de trabajo común en Machine Learning con Python abarca la instalación de las librerías, la preparación de los datos, el diseño del modelo, el ajuste de hiperparámetros, el entrenamiento y la evaluación final. La comprensión de las funciones clave y la correcta elección de la librería según el problema resultan determinantes para la eficiencia y calidad de la solución desarrollada.

Instalación de librerías principales

La instalación de las librerías se realiza mediante gestores de paquetes estándar de Python, como pip o conda. El entorno virtual garantiza un aislamiento adecuado de dependencias, evitando conflictos y facilitando la reproducibilidad.

pip install tensorflow

- Para instalar Scikit-learn, ejecutar:

```
pip install scikit-learn
```

- Para instalar TensorFlow y Keras (Keras se integra con TensorFlow desde la versión 2.x):

```
pip install tensorflow
```

La verificación de la instalación se efectúa importando los módulos en una consola interactiva o script:

```
import sklearn
import tensorflow as tf
from tensorflow import keras
print(sklearn.__version__, tf.__version__)
```

Las versiones de las librerías condicionan la disponibilidad de funcionalidades avanzadas y la compatibilidad con hardware específico. Es recomendable revisar la documentación oficial para asegurar la instalación de versiones compatibles con los requisitos del proyecto.

Estructura y funcionalidades principales de Scikit-learn

Scikit-learn se especializa en algoritmos clásicos de Machine Learning, proporcionando implementaciones optimizadas y herramientas para la evaluación comparativa. Los módulos más relevantes incluyen:

- `sklearn.datasets`: carga y generación de conjuntos de datos sintéticos y reales.
- `sklearn.model_selection`: partición de datos, validación cruzada, búsqueda de hiperparámetros.
- `sklearn.preprocessing`: normalización, codificación de variables categóricas y manejo de valores ausentes.
- `sklearn.pipeline`: construcción de flujos de trabajo reutilizables con pasos encadenados.

- `sklearn.metrics`: métricas de evaluación para clasificación, regresión y clustering.
- `sklearn.linear_model`, `sklearn.tree`, `sklearn.svm`: algoritmos de clasificación y regresión.

El diseño orientado a objetos de Scikit-learn permite instanciar modelos, ajustarlos a datos con `.fit()`, realizar predicciones con `.predict()`, y explorar métricas con funciones específicas. La interoperabilidad con Numpy y Pandas agiliza la manipulación previa de los datos y su integración en pipelines complejos.

Ejemplo práctico: Clasificación con Scikit-learn

Un flujo básico para la clasificación supervisada empleando un modelo de regresión logística puede estructurarse así:

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
# Carga de datos
X, y = load_iris(return_X_y=True)
# División en conjunto de entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)
# Escalado de variables
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
# Entrenamiento del modelo
clf = LogisticRegression()
clf.fit(X_train, y_train)
# Predicción y evaluación
y_pred = clf.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
print(f'Precisión: {accuracy:.2f}')
```

Este flujo abarca desde la carga de datos, la preparación y escalado, el entrenamiento del modelo, hasta la evaluación mediante la métrica de precisión. La modularidad de Scikit-learn permite reemplazar el modelo, ajustar hiperparámetros o añadir transformaciones adicionales con mínima reescritura.

Principios operativos de TensorFlow

TensorFlow, desarrollado por Google, soporta la creación y entrenamiento de redes neuronales profundas, así como la ejecución eficiente en diferentes arquitecturas de hardware. Su modelo de programación basado en grafos de flujo de datos permite la composición de operaciones numéricas complejas y el despliegue en sistemas distribuidos. Las funcionalidades esenciales de TensorFlow incluyen:

- Definición de tensores y operaciones matemáticas vectorizadas.
- Creación de modelos mediante la API Keras o la API funcional de bajo nivel.
- Gestión de sesiones y contexto de ejecución (modo gráfico y modo eager).
- Entrenamiento distribuido y soporte para aceleradores de hardware.
- Exportación y despliegue de modelos para producción.

La integración nativa de Keras en TensorFlow a partir de la versión 2.x facilita la definición de arquitecturas profundas con una sintaxis de alto nivel, sin renunciar a la flexibilidad para personalizaciones avanzadas.

Ejemplo práctico: Regresión con TensorFlow y Keras

Para construir y entrenar una red neuronal simple que resuelva un problema de regresión, la estructura típica sería:

```
import numpy as np
import tensorflow as tf
from tensorflow import keras
# Datos sintéticos de ejemplo
X = np.random.rand(100, 1)
y = 3 * X.squeeze() + 2 + np.random.randn(100) * 0.1
# Definición del modelo
model = keras.Sequential([
    keras.layers.Dense(1, input_shape=(1,))
])
model.compile(optimizer='adam', loss='mse')
# Entrenamiento
model.fit(X, y, epochs=100, verbose=0)
# Predicción
y_pred = model.predict(X[:5])
print(y_pred)
```

Este ejemplo ilustra la creación de un modelo secuencial con una sola capa densa, la compilación con el optimizador Adam y la función de pérdida MSE (error cuadrático medio), el entrenamiento sobre datos sintéticos y la obtención de predicciones para nuevos datos.

Keras: API de alto nivel para redes neuronales

Keras abstrae la complejidad del diseño de redes neuronales, proporcionando una interfaz clara y modular para definir arquitecturas secuenciales o funcionales. Sus principales ventajas incluyen:

- Sintaxis concisa y legible para la construcción de modelos.
- Compatibilidad con múltiples backends computacionales (TensorFlow, Theano, CNTK), aunque actualmente se emplea casi exclusivamente sobre TensorFlow.
- Soporte para capas estándar (densas, convolucionales, recurrentes, normalización, activación, etc.).
- Facilidad para el ajuste de hiperparámetros y el monitoreo del entrenamiento.
- Integración con herramientas de visualización y análisis (TensorBoard).

La definición de modelos en Keras puede realizarse mediante el enfoque secuencial (apilamiento lineal de capas) o el enfoque funcional (arquitecturas arbitrarias, incluidos modelos de múltiples entradas y salidas).

Micro-caso aplicado: Una empresa de seguros necesita predecir el importe de reclamaciones médicas a partir del perfil de sus clientes. Los ingenieros de datos utilizan Scikit-learn para preparar los datos y evaluar modelos de regresión lineal y de bosques aleatorios. Posteriormente, implementan una red neuronal con Keras sobre TensorFlow para comparar el rendimiento y explorar mejoras en la precisión de las predicciones.

Comparativa de librerías: Scikit-learn, TensorFlow y Keras

El siguiente cuadro sintetiza las diferencias operativas más relevantes entre estas librerías:

Característica	Scikit-learn	TensorFlow	Keras
Enfoque principal	ML clásico (SVM, árboles, regresión)	Deep Learning, computación numérica	API de alto nivel para Deep Learning

Característica	Scikit-learn	TensorFlow	Keras
Facilidad de uso	Muy alta	Media (API amplia)	Muy alta
Flexibilidad	Media	Muy alta	Alta
Hardware soportado	CPU	CPU, GPU, TPU	CPU, GPU (via backend TensorFlow)
Integración con otras librerías	Numpy, Pandas	Keras, Numpy, Pandas	TensorFlow, Numpy, Pandas
Modelos soportados	Supervisado, no supervisado, reducción de dimensionalidad	Redes neuronales profundas, modelos personalizados	Redes neuronales secuenciales y funcionales
Producción y escalabilidad	Media	Muy alta (serving, escalado)	Alta (a través de TensorFlow)
Documentación y comunidad	Muy amplia	Muy amplia	Muy amplia

La elección entre estas plataformas depende del tipo de problema, la complejidad de la arquitectura requerida y las restricciones de despliegue. Para tareas estándar de clasificación y regresión, Scikit-learn ofrece rapidez de desarrollo y facilidad de interpretación. Para problemas que exigen modelado profundo, procesamiento de grandes volúmenes de datos o entrenamiento en GPU, TensorFlow y Keras resultan más adecuados.

Preparación de datos y flujo de trabajo

La calidad y formato de los datos influyen decisivamente en el desempeño de los modelos. Tanto Scikit-learn como TensorFlow y Keras requieren que los datos de entrada estén correctamente estructurados (arrays Numpy, DataFrames de Pandas o tensores). Las etapas habituales de preparación comprenden:

- Limpieza de datos: imputación de valores ausentes, eliminación de duplicados.
- Transformación de variables: normalización, estandarización, codificación de variables categóricas.

- División en conjuntos de entrenamiento, validación y prueba.
- Selección de características relevantes.

Scikit-learn dispone de transformadores y pipelines para automatizar estos procesos, mientras que en TensorFlow/Keras se utilizan capas de preprocesamiento y utilidades específicas (`tf.data`, `tf.keras.layers.experimental.preprocessing`).

La correcta partición de los datos previene el sobreajuste y permite una evaluación objetiva del modelo. El uso de validación cruzada y la selección automática de hiperparámetros mediante búsqueda en cuadrícula (`GridSearchCV`) o aleatoria (`RandomizedSearchCV`) optimizan el rendimiento de los modelos tradicionales. En el caso de redes neuronales, el ajuste de arquitecturas, tasas de aprendizaje y regularización se realiza monitorizando métricas de validación durante el entrenamiento.

Evaluación y métricas

La selección de métricas de evaluación depende de la naturaleza del problema:

- Para clasificación: precisión, recall, F1-score, matriz de confusión, área bajo la curva ROC.
- Para regresión: error cuadrático medio (MSE), error absoluto medio (MAE), .

Scikit-learn ofrece implementaciones listas para usar en `sklearn.metrics`, mientras que Keras integra métricas en el proceso de entrenamiento y permite el seguimiento en tiempo real mediante callbacks.

Las métricas cuantifican el rendimiento predictivo, guían la selección de modelos y la toma de decisiones para su despliegue en producción. La interpretación adecuada de estos valores, junto con la validación cruzada y el análisis de errores, asegura modelos robustos y generalizables.

Integración y despliegue

La interoperabilidad entre estas librerías facilita la construcción de soluciones híbridas, donde el preprocesamiento y la selección de características se gestionan con Scikit-learn y el modelado profundo se implementa con TensorFlow/Keras. Esta sinergia amplía el espectro de problemas abordables y permite aprovechar lo mejor de cada herramienta.

El despliegue de modelos en entornos productivos puede realizarse exportando los modelos entrenados a formatos estándar (Pickle/Joblib para Scikit-learn, SavedModel para TensorFlow/Keras) y sirviéndolos mediante APIs REST, contenedores o plataformas especializadas (TensorFlow Serving, TFX, MLflow).

La actualización y monitorización de modelos en producción requieren procedimientos de seguimiento de métricas, detección de deriva en los datos y reentrenamiento periódico, tareas que las librerías modernas facilitan mediante integraciones con sistemas de monitorización y automatización.

Ventajas y desafíos de las principales librerías

Cada herramienta presenta ventajas específicas y desafíos particulares:

- Scikit-learn: ventaja en la rapidez de prototipado y facilidad de uso para problemas tabulares, aunque limitado en Deep Learning y procesamiento distribuido.
- TensorFlow: potencia y flexibilidad para arquitecturas complejas, entrenamiento distribuido y despliegue a gran escala, a cambio de una curva de aprendizaje más pronunciada.
- Keras: mayor accesibilidad en el diseño de redes neuronales, especialmente útil para usuarios no expertos, si bien la personalización profunda puede exigir recurrir a la API base de TensorFlow.

La formación técnica y la experiencia del equipo, así como los recursos computacionales disponibles, influyen en la elección y combinación óptima de estas soluciones.

Buenas prácticas en el uso de librerías para Machine Learning

- Mantener entornos virtuales para aislar dependencias y facilitar la reproducibilidad.
- Documentar las versiones de las librerías empleadas y los pasos del flujo de trabajo.
- Modularizar el código en scripts o notebooks reutilizables.
- Emplear pipelines y transformadores para asegurar la consistencia entre entrenamiento y predicción.
- Monitorear el consumo de recursos y optimizar el uso de hardware especializado según la escala del problema.
- Validar los modelos con métodos estadísticos y métricas pertinentes al dominio de aplicación.

Una implementación disciplinada, apoyada en estas buenas prácticas, garantiza la robustez y escalabilidad de las soluciones desarrolladas.

Tabla comparativa de procedimientos típicos

Procedimiento	Scikit-learn	TensorFlow/Keras
Preprocesa-miento	`StandardScaler`, `OneHotEncoder`, `Pipeline`	`tf.data`, `tf.keras.layers.experimental.preprocessing`
Dividir conjunto de datos	`train_test_split`	`tf.data.Dataset`
Entrenamiento de modelo	`.fit()`	`.fit()`
Predicción	`.predict()`	`.predict()`
Evaluación de métricas	`accuracy_score`, `mean_squared_error`	Métricas integradas o personalizadas
Guardar/cargar modelo	`joblib.dump()`/`joblib.load()`	`model.save()`/`tf.keras.models.load_model()`

La similitud de nombres de métodos y procedimientos entre Scikit-learn y Keras facilita la transición entre modelos clásicos y redes neuronales, permitiendo a los equipos adoptar la herramienta más adecuada en cada etapa del desarrollo.

Tendencias y evolución de las librerías de Machine Learning en Python

El ecosistema de Machine Learning en Python evoluciona de forma acelerada, integrando nuevas funcionalidades y optimizaciones orientadas a la eficiencia, la escalabilidad y la facilidad de uso.

Las principales tendencias incluyen:

- Automatización de procesos mediante AutoML y pipelines inteligentes.
- Integración nativa con sistemas de orquestación y despliegue continuo.
- Soporte mejorado para hardware especializado (GPU, TPU).
- Incorporación de explicabilidad y auditoría de modelos (XAI).
- Mayor énfasis en la seguridad y privacidad durante el procesamiento y entrenamiento de datos.

Scikit-learn, TensorFlow y Keras se adaptan a estas tendencias mediante actualizaciones regulares, expansión de sus APIs y desarrollo de módulos adicionales orientados a la producción y la integración empresarial.

Recomendaciones para el aprendizaje y el uso profesional

- Practicar con conjuntos de datos reales y problemas aplicados al dominio de interés.
- Consultar la documentación oficial y los foros de la comunidad para resolver dudas y conocer las mejores prácticas.
- Realizar experimentos comparativos entre modelos clásicos y redes neuronales para identificar la mejor solución en cada caso.
- Evaluar la escalabilidad y mantenibilidad de los modelos antes de su despliegue.
- Mantenerse actualizado respecto a las novedades y releases de las librerías principales, ajustando el stack tecnológico conforme a los requisitos y oportunidades emergentes.

La capacitación continua y la experimentación sistemática constituyen la base para el aprovechamiento óptimo de las herramientas de Machine Learning en Python.

Recuerda

El dominio operativo de Scikit-learn, TensorFlow y Keras habilita el desarrollo eficiente de soluciones de Machine Learning en Python, permitiendo abordar tareas de clasificación, regresión y modelado profundo con flexibilidad, escalabilidad y rigor técnico.

1.3. Machine Learning. Introducción

El Machine Learning representa una de las áreas más dinámicas y transformadoras de la inteligencia artificial. Permite a los sistemas aprender de los datos y mejorar su desempeño en tareas específicas sin intervención humana explícita. Este paradigma ha revolucionado el análisis de datos y la automatización de procesos, proporcionando nuevas capacidades en sectores como la salud, la industria, el comercio y la investigación científica.

Definición y fundamento del aprendizaje automático

El aprendizaje automático es un subcampo de la inteligencia artificial que se fundamenta en el desarrollo de algoritmos capaces de identificar patrones en

grandes volúmenes de datos y extrapolar ese conocimiento para tomar decisiones o realizar predicciones. El proceso de aprendizaje se basa en la experiencia: el modelo ajusta sus parámetros internos conforme analiza nuevos datos, optimizando su rendimiento según métricas predefinidas.

La diferencia fundamental entre el aprendizaje automático y la programación tradicional radica en la resolución de problemas: mientras que en la programación convencional el desarrollador codifica explícitamente las reglas, en el aprendizaje automático el algoritmo infiere esas reglas a partir de ejemplos. Así, el modelo no se limita a ejecutar instrucciones estáticas, sino que adapta su comportamiento a partir de la experiencia previa.

La relevancia de esta disciplina en el análisis de datos contemporáneo se debe a la explosión en la disponibilidad de datos y la necesidad de extraer valor de ellos de forma automatizada y escalable. Sectores como la banca, el comercio electrónico, la logística y la salud han integrado soluciones de Machine Learning para automatizar la toma de decisiones, optimizar operaciones y personalizar servicios.

Tipos principales de aprendizaje automático

El aprendizaje automático se clasifica en tres categorías principales: aprendizaje supervisado, aprendizaje no supervisado y aprendizaje por refuerzo. Cada uno aborda problemas diferentes y emplea estrategias particulares para aprender de los datos.

Aprendizaje supervisado

En el aprendizaje supervisado, el modelo se entrena utilizando un conjunto de datos etiquetado, es decir, cada ejemplo de entrenamiento incluye tanto las características de entrada como el resultado deseado (etiqueta). El objetivo es que el modelo aprenda una función que, dada una nueva entrada, prediga la etiqueta correspondiente.

Los problemas típicos que aborda el aprendizaje supervisado incluyen:

- Clasificación: asignar una categoría a cada entrada. Ejemplo: detección de correos electrónicos spam.
- Regresión: predecir un valor numérico continuo. Ejemplo: estimar el precio de una vivienda.

Durante el entrenamiento, el modelo compara sus predicciones con las etiquetas reales y ajusta sus parámetros para minimizar el error, utilizando métricas como la precisión, el error cuadrático medio o la exactitud, según el caso.

Aprendizaje no supervisado

El aprendizaje no supervisado trabaja con conjuntos de datos sin etiquetas. El objetivo es descubrir patrones inherentes en los datos, como agrupaciones o estructuras latentes. El modelo explora la organización interna de los datos y extrae información relevante sin guía externa.

Las tareas principales incluyen:

- Clustering (agrupamiento): segmentar los datos en grupos homogéneos según similitud. Ejemplo: segmentación de clientes en marketing.
- Reducción de dimensionalidad: simplificar la representación de los datos manteniendo su estructura esencial. Ejemplo: análisis de componentes principales (PCA) para visualizar datos de alta dimensión.

El aprendizaje no supervisado resulta fundamental cuando no se dispone de etiquetas fiables, o cuando se desea explorar la estructura subyacente de los datos antes de aplicar otros métodos.

Aprendizaje por refuerzo

En el aprendizaje por refuerzo, el modelo aprende a tomar decisiones secuenciales en un entorno interactivo. El agente realiza acciones y recibe retroalimentación en forma de recompensas o penalizaciones, ajustando su política de actuación para maximizar la recompensa acumulada a largo plazo.

Este enfoque es especialmente útil en problemas donde las acciones tienen consecuencias a lo largo del tiempo y la retroalimentación es escasa o diferida. Ejemplos representativos incluyen:

- Juegos (ajedrez, Go, videojuegos)
- Control de robots
- Optimización de rutas logísticas

El aprendizaje por refuerzo se apoya en conceptos de teoría de juegos, control óptimo y dinámica de sistemas, y requiere una exploración cuidadosa del entorno para evitar soluciones subóptimas.

Comparación de tipos de aprendizaje

La siguiente tabla resume las diferencias clave entre los tres tipos principales de aprendizaje automático:

Tipo de aprendizaje	Datos requeridos	Ejemplo de tarea	Feedback recibido	Aplicaciones típicas
Supervisado	Etiquetas disponibles	Clasificación	Directo (errores)	Detección de fraude, diagnóstico médico
No supervisado	Sin etiquetas	Clustering	Indirecto (patrones)	Segmentación de mercado, compresión de datos
Por refuerzo	Experiencia interactiva	Toma de decisiones	Recompensa/penalización	Robótica, juegos, sistemas de recomendación adaptativos

Ejemplos prácticos de aplicación

La aplicabilidad del aprendizaje automático es extensa y abarca problemas de clasificación, predicción, reconocimiento de patrones y automatización de procesos.

Algunos ejemplos ilustrativos:

- Diagnóstico médico: modelos clasifican imágenes médicas para detectar patologías como tumores en radiografías.
- Sistemas de recomendación: algoritmos sugieren productos o contenidos personalizados en plataformas de comercio electrónico y streaming.
- Detección de fraudes: modelos supervisados identifican transacciones anómalas en sistemas bancarios.
- Agrupamiento de documentos: técnicas no supervisadas organizan grandes colecciones de textos por similitud temática.
- Optimización de rutas: agentes por refuerzo aprenden a planificar rutas eficientes en logística de entregas.

Estos casos demuestran la capacidad del aprendizaje automático para abordar necesidades críticas en entornos reales, donde la escala y la complejidad de los datos superan la capacidad de análisis manual.

Flujo típico de un proyecto de Machine Learning

El desarrollo de una solución de aprendizaje automático implica una serie de etapas secuenciales y recurrentes. A continuación, se detalla el flujo de trabajo estándar, desde la conceptualización hasta la evaluación final del modelo.

- Definición del problema: delimitar el objetivo del proyecto y traducir la necesidad de negocio o investigación a un problema técnico abordable mediante Machine Learning.
- Recolección de datos: obtener datos relevantes, ya sea a través de bases existentes, sensores, APIs, o recopilación manual.
- Preparación y limpieza de datos: procesar los datos para eliminar errores, valores atípicos y completar ausencias. Involucra normalización, codificación de variables categóricas, tratamiento de datos faltantes y reducción de ruido.
- Análisis exploratorio de datos (EDA): visualizar y analizar las características principales del conjunto de datos, identificando tendencias, correlaciones y posibles sesgos.
- Selección de características (feature selection): identificar las variables más relevantes para el objetivo del modelo, eliminando información irrelevante o redundante.
- División del conjunto de datos: separar los datos en conjuntos de entrenamiento, validación y prueba para evaluar el rendimiento del modelo de forma objetiva y evitar sobreajuste.
- Selección y entrenamiento del modelo: elegir el algoritmo más adecuado según la naturaleza del problema (clasificación, regresión, clustering, etc.) y entrenarlo con los datos de entrenamiento.
- Ajuste de hiperparámetros: optimizar los parámetros configurables del modelo (como la tasa de aprendizaje, profundidad de árbol, número de vecinos, etc.) para maximizar el rendimiento.
- Evaluación del modelo: medir el desempeño del modelo utilizando métricas específicas (precisión, recall, F1-score, ROC-AUC, etc.) en los conjuntos de validación y prueba.
- Implementación y monitorización: desplegar el modelo en un entorno de producción y monitorizar su rendimiento a lo largo del tiempo, ajustando según se detecten desviaciones o cambios en los datos.

Este flujo no es estrictamente lineal; puede requerir iteraciones, especialmente en la limpieza de datos, ajuste de características y mejora del modelo, hasta alcanzar el rendimiento deseado.

Detalle de algunas etapas clave:

Preparación y limpieza de datos

La calidad de los datos determina en gran medida el éxito de un proyecto de Machine Learning. Eliminar inconsistencias, corregir formatos, gestionar valores ausentes y detectar posibles sesgos resulta esencial para evitar que el modelo aprenda patrones incorrectos. Técnicas habituales incluyen:

- Imputación de valores ausentes mediante la media, la mediana o algoritmos específicos.
- Detección y eliminación de duplicados.
- Normalización de escalas para variables numéricas.
- Tratamiento de variables categóricas mediante codificación (one-hot, ordinal, etc.).
- Detección y remoción de outliers.

Una preparación adecuada reduce el riesgo de sobreajuste y mejora la generalización del modelo a datos no vistos.

Selección y entrenamiento del modelo

La elección del algoritmo depende de la naturaleza del problema y las características del conjunto de datos. Entre los algoritmos más comunes se encuentran:

- Regresión lineal y logística: para problemas de regresión y clasificación binaria.
- Árboles de decisión y bosques aleatorios: para clasificación y regresión, robustos ante datos no lineales y variables categóricas.
- Máquinas de vectores de soporte (SVM): útiles en clasificación con alta dimensionalidad.
- Redes neuronales artificiales: aplicables en reconocimiento de imágenes, voz y texto.
- K-means y clustering jerárquico: para agrupamiento no supervisado.

El proceso de entrenamiento implica ajustar los parámetros internos del modelo minimizando una función de pérdida, que cuantifica el error entre las predicciones y los valores reales.

Evaluación del modelo

La evaluación objetiva del modelo requiere definir métricas adecuadas al tipo de problema. Para clasificación, métricas como la precisión (accuracy), la sensibilidad (recall) y la puntuación F1 permiten detectar tanto aciertos como errores críticos. En regresión, el error cuadrático medio (MSE) y el coeficiente de determinación (R^2) cuantifican la calidad de las predicciones.

El uso de técnicas de validación cruzada permite estimar el desempeño real del modelo, mitigando el riesgo de sobreajuste y proporcionando una visión más robusta de su capacidad de generalización.

Tabla comparativa de algoritmos y sus aplicaciones

Algoritmo	Tipo de aprendizaje	Problema típico	Ventajas principales	Limitaciones principales
Regresión lineal/logística	Supervisado	Regresión/ Clasificación	Simplicidad, interpretabilidad	No capta relaciones no lineales
Árboles de decisión/ Bosques	Supervisado	Clasificación/ Regresión	Maneja variables mixtas, robusto	Riesgo de sobreajuste
Máquinas de vectores de soporte	Supervisado	Clasificación	Eficaz en alta dimensionalidad	Requiere ajuste intensivo de parámetros
Redes neuronales	Supervisado	Imágenes, texto, voz	Flexibilidad, gran capacidad	Requiere muchos datos y recursos
K-means/ Clustering jerárquico	No supervisado	Agrupamiento	Simplicidad, velocidad	Difícil determinar número de grupos
Q-learning, Deep Q-Network	Por refuerzo	Toma de decisiones	Aprende políticas óptimas	Requiere muchas iteraciones

Python como herramienta para Machine Learning

Python se ha consolidado como el lenguaje de referencia para el desarrollo de proyectos de Machine Learning. Su sintaxis clara, la amplia comunidad y el ecosistema de bibliotecas especializadas (como NumPy, pandas, scikit-learn, TensorFlow y PyTorch) facilitan todas las etapas del flujo de trabajo:

- Carga y manipulación de datos: pandas permite gestionar y transformar grandes volúmenes de datos tabulares.
- Cálculo numérico: NumPy y SciPy proporcionan operaciones eficientes sobre grandes matrices y herramientas estadísticas.
- Modelado y entrenamiento: scikit-learn ofrece una interfaz homogénea para entrenar y evaluar una amplia gama de algoritmos supervisados y no supervisados.
- Redes neuronales y aprendizaje profundo: TensorFlow y PyTorch permiten construir, entrenar y desplegar modelos complejos de deep learning.
- Visualización: Matplotlib y Seaborn habilitan la exploración visual de los datos y los resultados del modelo.

La interoperabilidad entre estas bibliotecas, junto con la abundancia de documentación y recursos, permiten a los profesionales centrarse en los aspectos conceptuales y experimentales, reduciendo las barreras técnicas para la implementación de soluciones avanzadas.

Consideraciones éticas y desafíos actuales

El despliegue de modelos de Machine Learning en aplicaciones reales plantea desafíos éticos y técnicos de creciente relevancia:

- Sesgo en los datos: los modelos pueden aprender y amplificar sesgos presentes en los datos históricos, reproduciendo desigualdades o discriminaciones.
- Interpretabilidad: modelos complejos, como redes neuronales profundas, dificultan la explicación de las decisiones tomadas, obstaculizando la confianza y la adopción en sectores críticos.
- Privacidad: el uso de datos personales sensibles exige el cumplimiento de normativas de protección y garantías de anonimato.
- Robustez y seguridad: los modelos pueden ser vulnerables a ataques o manipulaciones adversarias, con consecuencias graves en sistemas automatizados.

La investigación en técnicas de aprendizaje explicable (Explainable AI), fairness y robustez busca mitigar estos desafíos, promoviendo el desarrollo de soluciones responsables y fiables.

Estudio de caso aplicado: predicción de demanda en comercio minorista

Considerar una cadena de tiendas que desea prever la demanda de productos para optimizar su logística y reducir costes de almacenamiento. El equipo recopila datos históricos de ventas, inventarios, promociones, clima y eventos locales. Tras limpiar y analizar los datos, se seleccionan las características más relevantes (producto, día de la semana, promociones activas). Se divide el conjunto de datos en entrenamiento y prueba. Se entrena un modelo de regresión supervisada (por ejemplo, un bosque aleatorio) y se ajustan sus hiperparámetros para maximizar la precisión en la predicción de unidades vendidas. Finalmente, se evalúa el modelo mediante el error cuadrático medio y se implementa en el sistema de gestión para actualizar las previsiones de stock en tiempo real.

Este caso ilustra el flujo completo de un proyecto de Machine Learning, desde la formulación del problema hasta la integración de la solución, destacando la articulación entre los conceptos teóricos y su aplicación práctica.

Limitaciones y tendencias emergentes

El aprendizaje automático, si bien poderoso, enfrenta limitaciones técnicas:

- Dependencia de grandes volúmenes de datos: muchos algoritmos requieren conjuntos extensos y representativos, lo que puede no estar disponible en todos los contextos.
- Capacidad de generalización: modelos sobreajustados pueden fallar en datos nuevos o no vistos.
- Consumo computacional: el entrenamiento, especialmente en deep learning, exige recursos significativos de hardware y tiempo.
- Mantenimiento y actualización: la degradación del rendimiento a lo largo del tiempo (concept drift) obliga a la revisión y retrain de los modelos.

Las tendencias emergentes buscan superar estos desafíos:

- Aprendizaje federado: permite entrenar modelos distribuidos sin centralizar los datos, mejorando la privacidad.
- Transfer learning: reutiliza modelos entrenados en grandes conjuntos para tareas afines con pocos datos.

- AutoML: automatiza la selección y ajuste de modelos, reduciendo la necesidad de expertos en cada etapa.
- Aprendizaje explicable y ético: desarrolla herramientas para auditar y justificar las decisiones de los modelos.

Estas innovaciones refuerzan la adaptabilidad y aplicabilidad del aprendizaje automático a nuevos dominios y requisitos.

Resumen visual del flujo de Machine Learning

A continuación, se presenta un diagrama simplificado del flujo típico de un proyecto de Machine Learning:

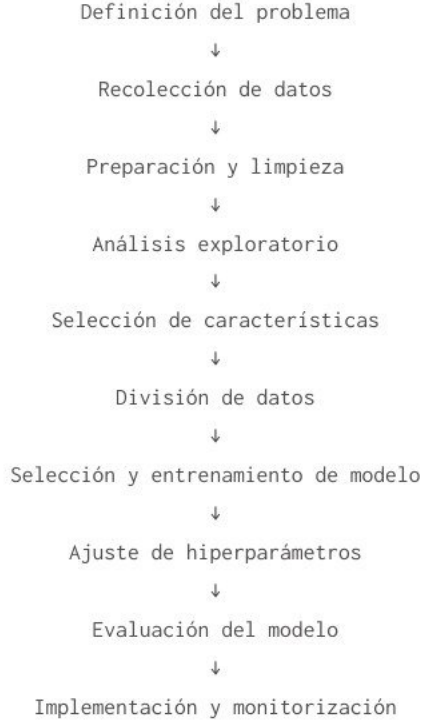

Cada etapa constituye un eslabón crítico y requiere conocimientos técnicos específicos, así como la capacidad de iterar y refinar el proceso en función de los resultados obtenidos.

Aspectos clave para el éxito en proyectos de Machine Learning

- Entendimiento profundo del problema y del contexto de aplicación.

- Selección adecuada del tipo de aprendizaje y del algoritmo.
- Calidad y representatividad de los datos utilizados.
- Evaluación objetiva y continua del rendimiento del modelo.
- Consideración de aspectos éticos, de privacidad y de interpretabilidad.
- Uso eficiente de herramientas y bibliotecas de Python para optimizar esfuerzos.

Dominar estos aspectos permite diseñar soluciones robustas, adaptables y alineadas con las necesidades reales de cada entorno de aplicación.

Ejercicio

Identifica un problema cotidiano en tu entorno (profesional, académico o personal) que pueda beneficiarse del uso de Machine Learning. Describe brevemente el objetivo, los datos que requerirías y el tipo de aprendizaje automático que aplicarías, justificando tu elección.

Actividades

1. ¿Cómo configurarías el entorno de trabajo en Python (instalación con Anaconda o venv, creación y activación de un entorno, instalación de paquetes básicos) y cuál sería el alcance del curso indicando las entregas técnicas esperadas (cuadernos, datasets y breves informes) según lo descrito, incluyendo cómo verificarías la instalación y versiones desde un cuaderno Jupyter?

2. ¿Cómo cargarías un archivo CSV en un cuaderno Jupyter usando pandas, realizarías una inspección inicial (por ejemplo, visualización de cabeceras), aplicarías una limpieza básica (imputación/eliminación de ausentes y normalización/estandarización cuando proceda con numpy/pandas) y dejarías trazabilidad clara del proceso en el propio cuaderno?

3. ¿Podrías diferenciar con tus palabras aprendizaje supervisado, no supervisado y por refuerzo, explicar sobreajuste frente a sesgo, y describir el ciclo EDA→modelado→validación→despliegue, además de identificar para qué utilizarías scikit-learn, matplotlib/plotly, scipy e imbalanced-learn dentro de ese flujo?

2

Aprendizaje supervisado

ÍNDICE

2.1. Definición y aplicaciones.

2.2. Medidas de rendimiento.

2.3. Modelos lineales

2.4. Modelos supervisados de ML: árboles, SVM, redes neuronales.

2.5. Combinación de modelos. Random Forest.

OBJETIVO

El objetivo de este tema es capacitar al alumno en el diseño, entrenamiento y validación de modelos supervisados para clasificación y regresión. Se profundiza en la elección de la variable objetivo, la correcta partición del conjunto de datos y la aplicación de técnicas de preprocesamiento y evaluación. Se estudian métricas como precisión, recall, F1-score, AUC-ROC y MAE/MSE, así como el análisis de la matriz de confusión. Además, se trabajan distintos algoritmos como regresión lineal, regresión logística, modelos penalizados (Lasso, Ridge), árboles de decisión, máquinas de vectores de soporte y redes neuronales básicas. El alumno aprenderá a ajustar modelos y a evaluar el sesgo y la varianza.

El aprendizaje supervisado utiliza conjuntos de datos etiquetados para entrenar modelos predictivos capaces de realizar tareas como clasificación y regresión. En Python, la implementación de regresión lineal involucra ajustar una línea recta que minimiza el error cuadrático medio entre predicciones y valores reales, útil para predecir variables continuas. Por otro lado, los árboles de decisión segmentan el espacio de características para clasificar o predecir resultados, resultando eficaces en problemas con relaciones no lineales. Para evaluar el rendimiento, se emplean métricas como precisión (accuracy) y la curva ROC, que permite comparar la capacidad de discriminación de modelos binarios. El flujo operativo típico incluye:

- Seleccionar y preparar el conjunto de datos etiquetados.
- Dividir los datos en subconjuntos de entrenamiento y prueba.
- Entrenar el modelo seleccionado (por ejemplo, regresión lineal o árbol de decisión).
- Realizar predicciones sobre el subconjunto de prueba.
- Calcular métricas de evaluación relevantes.

Algoritmo	Tipo de problema	Ventajas principales
Regresión lineal	Regresión	Interpretabilidad, rapidez
Árbol de decisión	Clasificación/Regresión	Maneja no linealidades, robusto

¿Sabías que...?

El uso de algoritmos supervisados en sectores como ventas minoristas permite anticipar tendencias de consumo y segmentar clientes, optimizando campañas y recursos con base en datos históricos.

2.1. Definición y aplicaciones

El aprendizaje supervisado constituye un pilar fundamental dentro del campo del machine learning. Su objetivo principal es construir modelos capaces de realizar predicciones precisas sobre datos nuevos a partir de un proceso de entrenamiento con conjuntos de datos etiquetados. En este contexto, cada muestra de datos incluye una entrada (características o atributos) y una salida asociada (etiqueta o variable objetivo). La naturaleza de estas etiquetas, ya sean discretas o continuas, define la tarea: clasificación cuando las etiquetas son categorías, y regresión cuando son valores numéricos continuos.

Definición formal de aprendizaje supervisado

En términos matemáticos, el aprendizaje supervisado busca aproximar una función $f : X \rightarrow Y$ donde X representa el espacio de características y Y el espacio de salidas. Dado un conjunto de entrenamiento $D = \{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$, el algoritmo ajusta los parámetros de un modelo hasta minimizar una función de pérdida, que cuantifica la discrepancia entre las predicciones del modelo $\hat{y}$ y los valores reales y. Por ejemplo, para regresión se suele emplear el error cuadrático medio (MSE):

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2$$

Mientras que para clasificación se utiliza la entropía cruzada o el porcentaje de aciertos.

El proceso de aprendizaje implica:

- Seleccionar un modelo adecuado (lineal, árbol de decisión, red neuronal, etc.).
- Ajustar los parámetros del modelo utilizando los datos etiquetados.
- Evaluar el rendimiento sobre datos no vistos (conjunto de validación o prueba).

La fortaleza del aprendizaje supervisado reside en su capacidad para generalizar patrones aprendidos y aplicarlos a datos desconocidos, siempre que los datos de entrenamiento reflejen adecuadamente la variabilidad del dominio real.

Aplicaciones prácticas del aprendizaje supervisado

El aprendizaje supervisado presenta una amplia variedad de aplicaciones en sectores industriales, comerciales, científicos y sociales. Las tareas más representativas incluyen clasificación y regresión, pero existen subcategorías y aplicaciones especializadas. Algunos ejemplos destacados:

- Clasificación de correos electrónicos: Distinguir automáticamente entre correos legítimos y spam.
- Predicción de precios inmobiliarios: Estimar el valor de venta de una propiedad a partir de características como ubicación, superficie, antigüedad y número de habitaciones.
- Reconocimiento de imágenes: Clasificar objetos, animales o personas en fotografías.
- Diagnóstico médico asistido: Predecir la presencia o ausencia de patologías a partir de datos clínicos y resultados de pruebas diagnósticas.
- Análisis de sentimiento: Determinar si un comentario en redes sociales expresa una opinión positiva, negativa o neutral.
- Predicción de demanda: Anticipar la cantidad de ventas futuras de un producto en función de factores históricos y estacionales.
- Sistemas de recomendación: Sugerir productos o contenidos personalizados en función del historial de usuario.

La siguiente tabla sintetiza algunas aplicaciones típicas, diferenciando tipo de tarea, entrada, salida esperada y ejemplos concretos:

Aplicación	Tipo de tarea	Entrada principal	Salida esperada	Ejemplo de uso
Clasificación de spam	Clasificación	Texto del correo	"Spam" o "No spam"	Filtros de correo electrónico
Predicción de precios inmobiliarios	Regresión	Características de la propiedad	Precio estimado (€)	Portales inmobiliarios
Diagnóstico médico	Clasificación	Parámetros clínicos, resultados de pruebas	"Enfermo" o "Sano"	Detección precoz de enfermedades
Recomendaciones de productos	Clasificación	Perfil y comportamiento del usuario	Lista de productos	Tiendas en línea
Predicción de demanda	Regresión	Historial de ventas, datos temporales	Volumen de ventas futuro	Gestión de inventarios
Análisis de sentimiento	Clasificación	Texto de reseñas o comentarios	"Positivo", "Negativo", etc.	Monitorización de redes sociales

Procedimiento típico de un proyecto de aprendizaje supervisado

El desarrollo de un sistema de aprendizaje supervisado implica una secuencia estructurada de etapas. La calidad de cada fase impacta directamente en el rendimiento global del modelo. El procedimiento estándar abarca:

- Recolección y preparación de datos: Obtención de datos representativos y su procesamiento inicial, incluyendo limpieza, eliminación de duplicados, imputación de valores faltantes y codificación de variables categóricas.
- Selección de características (feature selection): Identificación de los atributos más relevantes para la tarea, reduciendo la dimensionalidad y eliminando información redundante o irrelevante.

- División del conjunto de datos: Separación en subconjuntos de entrenamiento, validación y prueba para evaluar la capacidad de generalización del modelo y evitar sobreajuste (overfitting).
- Selección y ajuste del modelo: Elección del algoritmo más adecuado (regresión lineal, máquinas de soporte vectorial, árboles de decisión, redes neuronales, etc.) y optimización de hiperparámetros mediante validación cruzada.
- Entrenamiento del modelo: Ajuste de los parámetros internos utilizando los datos de entrenamiento para minimizar la función de pérdida seleccionada.
- Evaluación del rendimiento: Medición de métricas clave (precisión, sensibilidad, especificidad, F1-score, coeficiente de determinación , entre otras) sobre el conjunto de prueba o validación.
- Interpretación y comunicación de resultados: Análisis de los hallazgos, identificación de posibles sesgos y comunicación efectiva a los interesados.
- Despliegue y mantenimiento: Implementación del modelo en producción y monitorización periódica para detectar degradación del rendimiento o cambios en el entorno de datos.

Este flujo no siempre es secuencial; en la práctica, se recurre a iteraciones para refinar datos, ajustar modelos o mejorar la selección de características.

Selección de características y su impacto

La selección de características resulta crítica en aprendizaje supervisado. Incluir demasiadas variables puede introducir ruido, aumentar el riesgo de sobreajuste y ralentizar el entrenamiento. Por el contrario, omitir atributos relevantes puede limitar la capacidad predictiva del modelo. Existen técnicas automáticas, como el análisis de importancia de características, selección hacia adelante (forward selection), o métodos basados en regularización (Lasso, Ridge), que ayudan a identificar los subconjuntos óptimos.

Ventajas de una selección adecuada de características:

- Mejora la precisión y generalización del modelo.
- Reduce el coste computacional.
- Facilita la interpretación de los resultados.
- Disminuye el riesgo de sobreajuste.

La correcta combinación de experiencia de dominio y métodos automáticos suele producir los mejores resultados.

Evaluación del rendimiento del modelo

Cuantificar el rendimiento de un modelo supervisado exige el uso de métricas adecuadas al tipo de tarea. La evaluación objetiva permite comparar modelos y seleccionar la mejor alternativa para el problema concreto.

- Clasificación:
  - Precisión (accuracy): Proporción de aciertos sobre el total de predicciones.
  - Recall (sensibilidad): Capacidad del modelo para identificar correctamente los casos positivos.
  - Precisión (precision): Proporción de verdaderos positivos sobre todos los predichos como positivos.
  - F1-score: Media armónica entre precisión y recall, útil ante desequilibrios de clases.
  - Matriz de confusión: Tabla que muestra la distribución de aciertos y errores por clase.
- Regresión:
  - Error cuadrático medio (MSE) y raíz del error cuadrático medio (RMSE): Penalizan fuertemente los errores grandes.
  - Error absoluto medio (MAE): Promedia la magnitud absoluta de los errores.
  - Coeficiente de determinación (): Indica la proporción de varianza explicada por el modelo.

  Ejemplo de matriz de confusión para un problema binario:

	Predicho: Positivo	**Predicho: Negativo**
Real: Positivo	TP	FN
Real: Negativo	FP	TN

Donde:

- TP: Verdaderos positivos
- TN: Verdaderos negativos
- FP: Falsos positivos
- FN: Falsos negativos

La interpretación conjunta de estas métricas orienta la selección y optimización de modelos, especialmente en contextos con clases desbalanceadas o donde los errores tienen diferentes costes.

Importancia de la calidad de los datos

El aprendizaje supervisado depende de manera crítica de la calidad de los datos de entrenamiento. Errores, valores atípicos, datos faltantes o etiquetas incorrectas afectan negativamente la capacidad del modelo para aprender patrones representativos y, en consecuencia, reducen la precisión de las predicciones.

Consecuencias de datos de mala calidad:

- Modelos con alto sesgo o varianza.
- Capacidad limitada para generalizar.
- Predicciones poco fiables en producción.
- Dificultad para identificar la causa de errores.

Procedimientos recomendados para garantizar la calidad de los datos:

- Revisión manual y automática de las etiquetas.
- Análisis estadístico para detectar anomalías y valores atípicos.
- Imputación o eliminación de valores faltantes según el caso.
- Normalización o estandarización de variables numéricas.
- Codificación coherente de variables categóricas.

La inversión en calidad de datos suele traducirse en mejoras significativas del desempeño predictivo y en una mayor robustez del sistema.

Implementación en Python

Python se ha consolidado como el lenguaje de referencia en machine learning gracias a su ecosistema de librerías especializadas, facilidad de uso y capacidad de integración. Entre las herramientas más empleadas en aprendizaje supervisado destacan:

- scikit-learn: Proporciona implementaciones eficientes de algoritmos de clasificación, regresión, selección de características, evaluación y preprocesamiento.
- pandas: Facilita la manipulación y análisis de datos estructurados.

- NumPy: Ofrece operaciones vectorizadas y estructuras eficientes para el manejo de datos numéricos.
- matplotlib y seaborn: Permiten la visualización gráfica de datos y resultados.

El flujo típico de trabajo en Python para un proyecto de aprendizaje supervisado comprende:

- Importación de librerías y carga de datos.
- Preprocesamiento y limpieza del dataset.
- División en conjuntos de entrenamiento y prueba.
- Selección y ajuste del modelo mediante los módulos de scikit-learn.
- Entrenamiento y generación de predicciones.
- Evaluación de rendimiento con métricas específicas.
- Visualización de resultados y análisis de importancia de características.

Ejemplo de código básico para clasificación de correos electrónicos usando scikit-learn:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score
# Carga de datos
datos = pd.read_csv('correos.csv')
X = datos['texto']
y = datos['etiqueta']  # 1 = Spam, 0 = No spam
# Vectorización del texto
vectorizador = TfidfVectorizer()
X_vect = vectorizador.fit_transform(X)
# División en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X_vect, y, test_
size=0.2, random_state=42)
# Entrenamiento del modelo
modelo = MultinomialNB()
modelo.fit(X_train, y_train)
# Predicción y evaluación
```

```
y_pred = modelo.predict(X_test)
print("Precisión:", accuracy_score(y_test, y_pred))
```

Este esquema puede adaptarse fácilmente a tareas de regresión o a otros dominios, cambiando el modelo y ajustando el preprocesamiento de los datos según corresponda.

Riesgos y limitaciones del aprendizaje supervisado

A pesar de sus numerosas ventajas, el aprendizaje supervisado presenta limitaciones inherentes:

- Requiere grandes volúmenes de datos etiquetados, lo cual puede ser costoso o difícil de obtener.
- El modelo solo aprende patrones presentes en los datos de entrenamiento; puede fallar ante situaciones nuevas o anomalías (problema de generalización).
- Sensibilidad a datos desbalanceados: la presencia de clases mayoritarias puede sesgar el modelo.
- Riesgo de sobreajuste si el modelo es excesivamente complejo respecto al tamaño y la diversidad del conjunto de datos.
- Dificultad para interpretar modelos complejos (como redes neuronales profundas), especialmente en aplicaciones críticas.

La gestión de estos desafíos implica aplicar técnicas de regularización, validación cruzada, generación sintética de ejemplos, balanceo de clases y métodos de interpretación de modelos.

Micro-caso aplicado: Una empresa inmobiliaria desea predecir el precio de venta de viviendas en una ciudad. Dispone de un historial de transacciones con información sobre ubicación, superficie, número de habitaciones y antigüedad de las propiedades, junto con el precio final de venta. Utiliza aprendizaje supervisado para entrenar un modelo de regresión, ajustando los parámetros a partir de los datos históricos. Tras el entrenamiento y la evaluación, el sistema permite estimar el valor de una nueva propiedad con una precisión adecuada, facilitando la toma de decisiones de agentes y clientes.

Comparativa de algoritmos supervisados

La elección del algoritmo adecuado depende de la naturaleza del problema, la cantidad y tipo de datos, y los requisitos de interpretabilidad y rendimiento. A continuación se presenta una tabla comparativa de algunos algoritmos habituales de aprendizaje supervisado:

Algoritmo	Tipo de tarea	Ventajas principales	Limitaciones	Casos de uso comunes
Regresión lineal	Regresión	Simplicidad, interpretabilidad, rapidez	No captura relaciones no lineales	Predicción de precios, análisis financiero
Árboles de decisión	Clas./ Regresión	Fácil interpretación, maneja variables mixtas	Sensibles al sobreajuste	Diagnóstico médico, clasificación básica
Bosques aleatorios (Random Forest)	Clas./ Regresión	Robustos al sobreajuste, alta precisión	Menor interpretabilidad	Detección de fraude, predicción de demanda
Máquinas de soporte vectorial (SVM)	Clas./ Regresión	Eficaces en espacios de alta dimensión	Costosas en grandes conjuntos	Reconocimiento de imágenes, texto
Redes neuronales	Clas./ Regresión	Capturan relaciones complejas	Requieren mucho dato y cómputo	Reconocimiento de voz, visión artificial
k-Vecinos más cercanos (kNN)	Clas./ Regresión	Simplicidad, sin entrenamiento explícito	Lento en predicción, sensible a ruido	Recomendaciones, clasificación básica

Cada algoritmo puede ajustarse mediante hiperparámetros y técnicas de preprocesamiento para mejorar su rendimiento en tareas específicas.

Aspectos éticos y de privacidad

El uso de aprendizaje supervisado puede plantear retos éticos y de privacidad, en especial cuando se emplean datos personales o sensibles. Se deben atender cuestiones como:

- Obtención de consentimiento informado para el uso de datos.
- Garantía de anonimato y protección frente a accesos no autorizados.

- Mitigación de sesgos en los datos que puedan llevar a decisiones discriminatorias.
- Transparencia en el funcionamiento de los modelos, especialmente en sectores regulados como banca y salud.

El cumplimiento normativo y la implementación de buenas prácticas en el manejo de datos resultan esenciales para prevenir impactos negativos y proteger los derechos de los usuarios.

2.2. Medidas de rendimiento

La evaluación de modelos de aprendizaje supervisado requiere métricas precisas que permitan cuantificar su rendimiento y adecuación a los objetivos del problema. La selección e interpretación de estas medidas condicionan tanto la optimización como la toma de decisiones en proyectos de machine learning. Abordar de manera sistemática las métricas fundamentales —precisión, recall, F1-score y curva ROC— proporciona un marco robusto para comparar, mejorar y seleccionar modelos de clasificación, especialmente en contextos donde la distribución de clases es desigual o las consecuencias del error varían en gravedad.

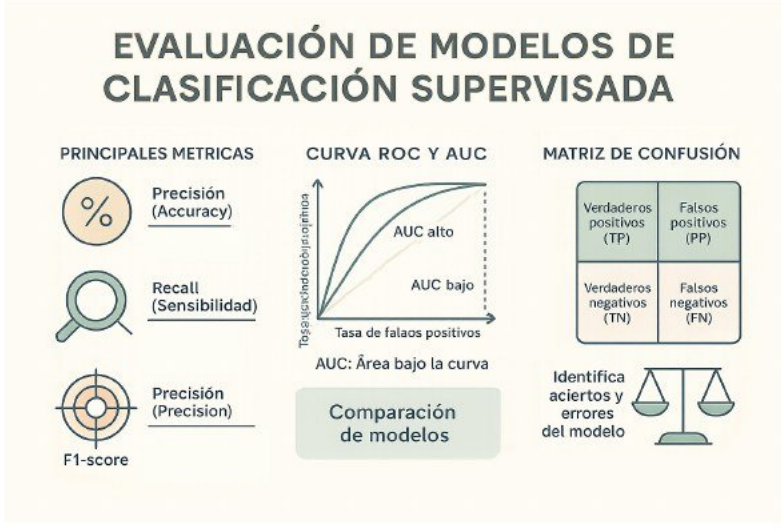

Precisión (Accuracy)

La precisión representa la proporción de predicciones correctas sobre el total de casos evaluados. Para un modelo de clasificación binaria, se calcula como:

$$\text{Precisión} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

donde:

- *TP* (True Positives): verdaderos positivos.

- *TN* (True Negatives): verdaderos negativos.

- *FP* (False Positives): falsos positivos.

- *FN* (False Negatives): falsos negativos.

Este indicador ofrece una visión general del desempeño, pero puede inducir a error en problemas con clases desbalanceadas. Por ejemplo, si el 95% de los datos pertenecen a una sola clase, un modelo que siempre prediga esa clase tendrá una precisión elevada sin ser útil para identificar los casos minoritarios.

Recall (Sensibilidad o Tasa de Verdaderos Positivos)

El recall mide la capacidad del modelo para identificar correctamente los casos positivos. Es especialmente relevante cuando las consecuencias de omitir un caso positivo son críticas, como en la detección de fraudes o enfermedades.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Un recall alto indica que el modelo captura la mayoría de los positivos reales, aunque puede generar más falsos positivos. Su contraparte, la especificidad, mide la capacidad de identificar correctamente los negativos, pero en muchos contextos supervisados la prioridad recae en el recall, especialmente con clases minoritarias.

Precisión (Precision)

La precisión en el contexto de machine learning se refiere a la proporción de verdaderos positivos entre todas las predicciones positivas realizadas por el modelo:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Un valor alto de precisión implica que, entre todas las veces que el modelo predice la clase positiva, la mayoría son correctas. Esta métrica resulta esencial cuando los falsos positivos tienen un alto coste operativo o social, como en sistemas de diagnóstico automático o detección de spam.

Relación entre Precisión y Recall

Precisión y recall presentan una relación inversamente proporcional; optimizar uno puede reducir el valor del otro. El ajuste de umbrales de decisión permite desplazar el punto de equilibrio entre estas métricas, pero obliga a considerar el contexto del problema para establecer prioridades adecuadas.

F1-score

El F1-score sintetiza la precisión y el recall en una única métrica armónica, proporcionando una visión equilibrada cuando existe un compromiso entre ambas. Su fórmula es:

$$F_1 = \frac{2\,\mathrm{Precision}\,\mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}$$

El F1-score toma valores entre 0 y 1, donde 1 indica el rendimiento ideal. Es especialmente útil en escenarios con clases desbalanceadas o cuando tanto los falsos positivos como los falsos negativos conllevan consecuencias significativas.

Curva ROC (Receiver Operating Characteristic) y AUC

La curva ROC es una herramienta gráfica que ilustra el rendimiento de un modelo de clasificación binaria al variar su umbral de decisión. Representa la tasa de verdaderos positivos (recall) frente a la tasa de falsos positivos para cada posible umbral:

$$\frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}}$$

El Área Bajo la Curva (AUC) cuantifica el rendimiento global del clasificador; un valor de 0.5 indica un modelo aleatorio, mientras que 1.0 representa una discriminación perfecta. El AUC facilita la comparación entre modelos, especialmente en conjuntos de datos desbalanceados o cuando se requiere priorizar la sensibilidad sobre la especificidad o viceversa.

Interpretación y Selección de Métricas según el Contexto

La selección de la métrica óptima depende de la naturaleza del problema y de las consecuencias asociadas a los errores de clasificación. En contextos médicos, priorizar el recall reduce el riesgo de omitir diagnósticos positivos. En sistemas financieros, un énfasis en la precisión minimiza las falsas alarmas. El uso combinado de métricas proporciona una perspectiva más completa que la dependencia exclusiva de una sola medida.

La siguiente tabla resume las principales métricas, sus fórmulas y aplicaciones típicas:

Métrica	Fórmula	Contexto de uso principal
Precisión	$\text{Precisió n} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$	Modelos balanceados, visión global
Recall	$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$	Importancia en detección de positivos
Precisión	$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$	Reducción de falsos positivos
F1-score	$F_1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}$	Equilibrio entre precisión y recall
AUC-ROC	Área bajo la curva ROC	Comparación global de modelos

Cálculo de métricas con scikit-learn

Las bibliotecas de Python ofrecen métodos robustos para calcular estas métricas de manera eficiente. La librería scikit-learn es la referencia estándar para implementar evaluaciones de rendimiento en tareas de clasificación.

Para calcular precisión, recall y F1-score sobre datos reales, se emplean las funciones `accuracy_score`, `precision_score`, `recall_score` y `f1_score`. El siguiente ejemplo muestra su uso básico:

```
from sklearn.metrics import accuracy_score, precision_score, recall_
score, f1_score
# Etiquetas reales y predichas
y_true = [0, 1, 1, 0, 1, 0, 1]
y_pred = [0, 1, 0, 0, 1, 1, 1]
precision = precision_score(y_true, y_pred)
recall = recall_score(y_true, y_pred)
f1 = f1_score(y_true, y_pred)
accuracy = accuracy_score(y_true, y_pred)
print(f'Precisión: {precision:.2f}')
```

```
print(f'Recall: {recall:.2f}')
print(f'F1-score: {f1:.2f}')
print(f'Accuracy: {accuracy:.2f}')
```

La función `roc_curve` permite obtener los valores necesarios para graficar la curva ROC, mientras que `roc_auc_score` calcula el AUC directamente:

```
from sklearn.metrics import roc_curve, roc_auc_score
import matplotlib.pyplot as plt
# Probabilidades de predicción para la clase positiva
y_scores = [0.1, 0.9, 0.2, 0.4, 0.8, 0.7, 0.6]
fpr, tpr, thresholds = roc_curve(y_true, y_scores)
auc = roc_auc_score(y_true, y_scores)
plt.plot(fpr, tpr, label=f'AUC = {auc:.2f}')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('Tasa de falsos positivos')
plt.ylabel('Tasa de verdaderos positivos (Recall)')
plt.title('Curva ROC')
plt.legend()
plt.show()
```

El análisis visual de la curva ROC permite comparar modelos y ajustar umbrales de decisión según las necesidades específicas del caso.

Métricas en problemas multiclase

En tareas de clasificación con más de dos clases, las métricas se generalizan mediante estrategias como one-vs-rest (OvR) y macro/micro promedios. Scikit-learn soporta estos enfoques a través del parámetro `average` en sus funciones de evaluación.

- `average='macro'`: calcula la métrica para cada clase y luego promedia, tratando todas las clases por igual.
- `average='micro'`: calcula la métrica globalmente, considerando el total de verdaderos positivos, falsos positivos y falsos negativos.
- `average='weighted'`: promedia las métricas ponderando cada clase según su frecuencia.

Ejemplo para clasificación multiclase

```
from sklearn.metrics import f1_score
y_true = [0, 1, 2, 2, 1, 0]
y_pred = [0, 2, 1, 2, 0, 1]
f1_macro = f1_score(y_true, y_pred, average='macro')
f1_micro = f1_score(y_true, y_pred, average='micro')
f1_weighted = f1_score(y_true, y_pred, average='weighted')
print(f'F1-score macro: {f1_macro:.2f}')
print(f'F1-score micro: {f1_micro:.2f}')
print(f'F1-score weighted: {f1_weighted:.2f}')
```

La elección entre promedios macro, micro o ponderados depende de la relevancia relativa asignada a las clases y de la distribución de los datos.

Interpretación de la matriz de confusión

La matriz de confusión sintetiza los aciertos y errores del modelo, permitiendo identificar patrones específicos de fallo. En problemas binarios, se representa como:

	Pred. Positivo	**Pred. Negativo**
Real Pos.	TP	FN
Real Neg.	FP	TN

En escenarios multiclase, la matriz se expande a una estructura cuadrada donde cada celda (i, j) refleja el número de veces que la clase i fue clasificada como j.

La inspección de la matriz de confusión permite ajustar estrategias de preprocesamiento, selección de umbrales y ponderación de clases, optimizando la efectividad general del modelo.

Ajuste de umbrales y trade-off entre métricas

Los algoritmos de clasificación suelen producir probabilidades o puntuaciones para cada muestra. El umbral por defecto (usualmente 0.5) puede no ser óptimo para todos los contextos. Ajustar el umbral permite desplazar el balance entre precisión y recall, optimizando la métrica prioritaria para el caso de uso. La curva ROC y la curva de precisión-recall facilitan la visualización de estos compromisos.

Ejemplo de ajuste de umbral

```
import numpy as np
from sklearn.metrics import precision_score, recall_score
y_scores = np.array([0.1, 0.9, 0.2, 0.4, 0.8, 0.7, 0.6])
y_true = np.array([0, 1, 1, 0, 1, 0, 1])
for thresh in np.arange(0.1, 1.0, 0.1):
    y_pred = (y_scores >= thresh).astype(int)
    precision = precision_score(y_true, y_pred)
    recall = recall_score(y_true, y_pred)
    print(f'Umbral: {thresh:.1f} - Precisión: {precision:.2f}, Recall:
{recall:.2f}')
```

Este procedimiento permite seleccionar el umbral que mejor se ajusta a los requisitos del problema (por ejemplo, maximizar el recall sin sacrificar demasiado la precisión).

Micro-caso aplicado: Una empresa de telecomunicaciones desea identificar clientes propensos a abandonar el servicio. El conjunto de datos presenta un 90% de clientes que permanecen y un 10% que abandonan. Si se evalúa únicamente la precisión, un modelo que siempre prediga "no abandono" tendrá un 90% de acierto, pero será inútil para anticipar bajas. Al priorizar el recall, el modelo mejora la identificación de potenciales bajas, permitiendo a la empresa tomar medidas preventivas. El F1-score ofrece un balance para evitar que un aumento en recall degrade excesivamente la precisión, garantizando una gestión eficiente de los recursos de retención.

Comparación de métricas: ventajas y limitaciones

El uso de una métrica sobre otra implica ventajas y limitaciones. La siguiente tabla sintetiza sus principales características para facilitar la selección informada:

Métrica	Ventajas	Limitaciones
Precisión	Fácil interpretación, global	Insensible a clases desbalanceadas
Recall	Prioriza positivos, útil en problemas críticos	Puede incrementar falsos positivos
Precisión	Minimiza falsos positivos	Puede reducir recall
F1-score	Balance entre precisión y recall	No refleja especificidad ni negativos

Métrica	Ventajas	Limitaciones
AUC-ROC	Evalúa rendimiento global, útil en desequilibrios	Menos intuitivo, no refleja umbral específico

Efecto de la desbalance de clases

El desbalance de clases afecta significativamente la utilidad de las métricas. En estos escenarios, la precisión suele ser engañosa, mientras que recall, precisión y F1-score ofrecen una evaluación más realista. El AUC-ROC y las curvas de precisión-recall son preferibles cuando la clase minoritaria es la de mayor interés operativo.

Uso de métricas en la validación cruzada

La validación cruzada permite estimar la variabilidad del rendimiento de un modelo y evitar sobreajuste. Es recomendable calcular las métricas de rendimiento en cada pliegue y reportar sus distribuciones (media, desviación estándar) para una evaluación robusta.

Ejemplo con scikit-learn:

```
from sklearn.model_selection import cross_val_score
from sklearn.linear_model import LogisticRegression
X = ... # Matriz de características
y = ... # Etiquetas
clf = LogisticRegression()
scores = cross_val_score(clf, X, y, cv=5, scoring='f1')
print(f'F1-score promedio (5-fold CV): {scores.mean():.2f}')
```

Este enfoque generaliza a cualquier métrica soportada por scikit-learn, garantizando la reproducibilidad y la representatividad de los resultados.

Métricas adicionales en machine learning supervisado

Además de las métricas principales, existen indicadores complementarios que enriquecen el análisis de modelos:

- Especificidad: mide la proporción de verdaderos negativos identificados correctamente. Útil cuando los falsos positivos son costosos.

- Curva de precisión-recall (PRC): especialmente informativa en conjuntos desbalanceados, pues enfatiza el rendimiento sobre la clase positiva.
- Matthews Correlation Coefficient (MCC): indicador robusto para problemas desbalanceados, combina la información de todas las celdas de la matriz de confusión en una sola métrica.

Para problemas de regresión, otras métricas como el error absoluto medio (MAE), el error cuadrático medio (MSE) y el coeficiente de determinación (R^2) son aplicables, pero no relevantes en clasificación.

Visualización y análisis avanzado de métricas

Las herramientas de visualización potencian la interpretación de los resultados y la comunicación con equipos no técnicos. Entre los recursos más frecuentes destacan:

- Curvas ROC y AUC: facilitan la comparación gráfica de modelos y la selección de umbrales.
- Curvas de precisión-recall: útiles en casos de clases desbalanceadas.
- Matriz de confusión: permite visualizar los patrones de error y guiar el ajuste de hiperparámetros.

Ejemplo de visualización de la matriz de confusión con scikit-learn y matplotlib:

```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
cm = confusion_matrix(y_true, y_pred)
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
disp.plot()
plt.show()
```

La interpretación combinada de estas gráficas complementa el análisis numérico, facilitando la toma de decisiones técnicas y estratégicas.

Importancia de la métrica en la selección y optimización de modelos

La métrica elegida orienta la optimización de hiperparámetros, la selección de modelos y la evaluación final. Por ejemplo, un modelo optimizado para F1-score puede comportarse de manera muy diferente a uno optimizado para precisión, especialmente en contextos con distribuciones de clase asimétricas o costes de error diferenciados. La adecuada alineación entre la métrica y los objetivos del proyecto es un factor crítico de éxito en machine learning aplicado.

Impacto en la toma de decisiones y ciclo de vida del proyecto

Las métricas de rendimiento influyen en la gestión del ciclo de vida del modelo: desde la fase de desarrollo y validación hasta el monitoreo en producción. La monitorización continua de las métricas clave permite identificar desviaciones en el comportamiento del modelo, anticipar la necesidad de reentrenamiento y garantizar que las soluciones implementadas sigan alineadas con los objetivos de negocio.

Recuerda

El uso adecuado y contextualizado de métricas de rendimiento como precisión, recall, F1-score y AUC-ROC es esencial para evaluar, comparar y seleccionar modelos de machine learning con base en sus resultados y su idoneidad respecto a los objetivos del problema. La interpretación crítica de estos indicadores, junto con su implementación práctica en Python, permite tomar decisiones informadas que optimizan el impacto de los modelos en entornos reales.

2.3. Modelos lineales

Los modelos lineales constituyen la piedra angular de numerosos algoritmos de aprendizaje supervisado, facilitando la modelización de relaciones entre variables independientes y una variable dependiente mediante una función lineal. Estos modelos asumen una relación directa y proporcional entre las variables de entrada y la salida, permitiendo soluciones interpretables, eficientes y robustas ante conjuntos de datos de tamaño moderado o grande. Su popularidad en el ámbito del machine learning reside en su facilidad de implementación, bajo coste computacional y capacidad para servir como punto de partida para técnicas más complejas.

Fundamentos de los modelos lineales

Un modelo lineal predice la variable objetivo (y) como una combinación lineal ponderada de las variables de entrada ($x_1, x_2,\ldots,x_n$) y un término independiente (b): $\boldsymbol{y = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b}$

donde w_i representa el coeficiente asociado a cada variable x_i y b es el sesgo o intercepto. El objetivo del aprendizaje es encontrar los valores óptimos de los coeficientes (w_i) y el intercepto (b) que mejor ajustan los datos observados.

Regresión lineal: descripción y formulación

La regresión lineal es el ejemplo clásico de modelo lineal. Busca la mejor línea (o hiperplano en dimensiones superiores) que minimiza la diferencia entre los valores predichos y los valores reales de la variable objetivo. Esta diferencia se cuantifica comúnmente mediante el error cuadrático medio (MSE), donde x_i es el vector de características de la observación *i*.

$$J\left(w, b\right) = \frac{1}{m}\sum_{i=1}^{m}\left(y_i - \left(w \cdot x_i + b\right)\right)^2$$

El proceso de ajuste consiste en encontrar los valores de *w* y *b* que minimizan *J* (*w*,*b*). Esto puede lograrse mediante métodos analíticos (como la ecuación normal) o algoritmos iterativos como descenso por gradiente.

Interpretación de los coeficientes

Los coeficientes w_i representan la contribución esperada de cada variable independiente x_i en la predicción de y, manteniendo las demás variables constantes. Un coeficiente positivo indica una relación directa, mientras que uno negativo indica una relación inversa. La magnitud del coeficiente refleja la sensibilidad de y ante cambios unitarios en x_i.

La interpretación precisa depende de la escala y la naturaleza de las variables. Por esta razón, es frecuente estandarizar o normalizar las variables antes de ajustar el modelo, especialmente cuando las escalas de las variables difieren significativamente.

Métricas de evaluación de modelos lineales

La calidad del ajuste de un modelo lineal se evalúa mediante métricas que cuantifican la discrepancia entre los valores reales y los predichos. Las métricas más utilizadas son:

Error cuadrático medio (MSE):

$$\mathrm{MSE} = \frac{1}{m}\sum_{i=1}^{m}\left(y_i - \hat{y}_i\right)^2$$

Penaliza fuertemente los errores grandes, lo que lo hace sensible a valores atípicos.

Raíz del error cuadrático medio (RMSE): $\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$

Proporciona una medida en las mismas unidades que la variable objetivo, facilitando la interpretación.

Error absoluto medio (MAE): Menos sensible a valores atípicos que el MSE.

$$\mathbf{MAE} = \frac{1}{m}\sum_{i=1}^{m}\left|y_i - \hat{y}_i\right|$$

Coeficiente de determinación (R^2): Indica la proporción de la varianza de *y* explicada por el modelo.

$$R^2 = 1 - \frac{\sum_{i=1}^{m}\left(y_i - \hat{y}_i\right)^2}{\sum_{i=1}^{m}\left(y_i - \overline{y}\right)^2}$$

Un R^2 cercano a 1 sugiere un buen ajuste.

Métrica	Fórmula	Interpretación	Sensibilidad a atípicos
MSE	$\mathbf{MSE} = \frac{1}{m}\sum_{i=1}^{m}\left(y_i - \hat{y}_i\right)^2$	Error cuadrático promedio	Alta
RMSE	$\mathbf{RMSE} = \sqrt{\mathbf{MSE}}$	Error cuadrático promedio (unidad de *y*)	Alta
MAE	$\mathbf{MAE} = \frac{1}{m}\sum_{i=1}^{m}\left\|y_i - \hat{y}_i\right\|$	Error absoluto promedio	Baja
(R^2)	$R^2 = 1 - \frac{\sum_{i=1}^{m}\left(y_i - \hat{y}_i\right)^2}{\sum_{i=1}^{m}\left(y_i - \overline{y}\right)^2}$	Fracción de varianza explicada	Media

Implementación de modelos lineales en Python con scikit-learn

La biblioteca scikit-learn proporciona herramientas eficientes para implementar y ajustar modelos lineales. Para la regresión lineal, se utiliza la clase `LinearRegression`. El flujo de trabajo habitual incluye la preparación de los datos, el ajuste del modelo y la evaluación del rendimiento.

Preparación y ajuste del modelo

- Importar las bibliotecas necesarias:

```
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
```

- Cargar y dividir los datos:

```
# Supongamos que 'df' es un DataFrame con las columnas
'caracteristica1', 'caracteristica2' y 'objetivo'
X = df[['caracteristica1', 'caracteristica2']]
y = df['objetivo']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)
```

- Ajustar el modelo:

```
modelo = LinearRegression()
modelo.fit(X_train, y_train)
```

- Obtener los coeficientes e intercepto:

```
print("Coeficientes:", modelo.coef_)
print("Intercepto:", modelo.intercept_)
```

Predicción y evaluación

- Realizar predicciones:

```
y_pred = modelo.predict(X_test)
```

- Calcular métricas de evaluación:

```
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_test, y_pred)
print("MSE:", mse)
print("RMSE:", rmse)
print("R^2:", r2)
```

Consideraciones sobre la preparación de datos

La calidad y el tipo de datos influyen directamente en la capacidad predictiva del modelo lineal. Las siguientes prácticas mejoran la robustez del ajuste:

- Eliminar o imputar valores nulos.
- Detectar y manejar valores atípicos.
- Escalar o normalizar las variables si presentan diferentes órdenes de magnitud.
- Convertir variables categóricas a variables numéricas mediante codificación (por ejemplo, one-hot encoding).
- Dividir los datos en conjuntos de entrenamiento y prueba para evitar sobreajuste.

Regularización en modelos lineales

Los modelos lineales presentan riesgo de sobreajuste cuando la cantidad de características es elevada o existe multicolinealidad. Las técnicas de regularización introducen penalizaciones al tamaño de los coeficientes para mejorar la generalización.

Regularización L1 (Lasso)

Añade la suma de los valores absolutos de los coeficientes a la función de coste.

Tiende a forzar algunos coeficientes a cero, realizando selección automática de variables.

La regularización L1 (Lasso) introduce una penalización proporcional al valor absoluto de los coeficientes en la función de coste:

$$J_{\text{Lasso}}\left(w, b\right) = \text{MSE} + \alpha \sum_{j=1}^{n} \left| w_j \right|$$

Regularización L2 (Ridge)

Añade la suma de los cuadrados de los coeficientes a la función de coste.

Tiende a reducir todos los coeficientes de manera proporcional, sin anularlos completamente:

$$J_{\text{Ridge}}\left(w, b\right) = \text{MSE} + \alpha \sum_{j=1}^{n} {w_j}^2$$

En scikit-learn, la regularización se implementa con las clases `Lasso`, `Ridge` y `ElasticNet`:

```
from sklearn.linear_model import Ridge, Lasso, ElasticNet
ridge = Ridge(alpha=1.0)
lasso = Lasso(alpha=0.1)
elastic = ElasticNet(alpha=0.1, l1_ratio=0.5)
ridge.fit(X_train, y_train)
lasso.fit(X_train, y_train)
elastic.fit(X_train, y_train)
```

El parámetro `alpha` controla la fuerza de la regularización. Un valor más alto implica mayor penalización y coeficientes más pequeños.

Evaluación y validación cruzada

Para estimar el rendimiento real de un modelo lineal y ajustar hiperparámetros como `alpha`, se emplea la validación cruzada. Esta técnica divide el conjunto de datos en *k* particiones, entrena el modelo en *k-1* partes y lo evalúa en la restante, repitiendo este proceso *k* veces y promediando los resultados.

En scikit-learn, se implementa usando `cross_val_score`:

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(Ridge(alpha=1.0), X, y, cv=5, scoring='neg_
mean_squared_error')
print("MSE medio:", -scores.mean())
```

La validación cruzada reduce el riesgo de sobreajuste y ayuda a seleccionar el modelo y los hiperparámetros óptimos.

Limitaciones y supuestos de los modelos lineales

Los modelos lineales requieren que se cumplan ciertos supuestos para que sus estimaciones sean fiables y sus predicciones precisas:

- Linealidad: Existe una relación lineal entre las variables independientes y la dependiente.
- Independencia de errores: Los residuos son independientes entre sí.
- Homoscedasticidad: La varianza de los errores es constante a lo largo de las predicciones.

- Normalidad de los errores: Los residuos se distribuyen normalmente (especialmente relevante para inferencia).
- Ausencia de multicolinealidad: Las variables independientes no están altamente correlacionadas entre sí.

La violación de estos supuestos puede conducir a estimaciones sesgadas o ineficaces. Es recomendable diagnosticar los residuos del modelo mediante gráficos de dispersión y pruebas estadísticas.

Micro-caso aplicado: Una empresa inmobiliaria dispone de datos históricos sobre ventas de viviendas, incluyendo características como superficie, número de habitaciones, antigüedad y ubicación. Utilizando un modelo lineal, el equipo de análisis estima el precio de futuras propiedades, interpretando la influencia relativa de cada característica. Gracias a la regularización, el modelo selecciona automáticamente las variables más relevantes, descartando aquellas que aportan poco valor predictivo.

Comparación con otros enfoques supervisados

Los modelos lineales destacan por su interpretabilidad y eficiencia, pero presentan limitaciones ante relaciones no lineales o interacciones complejas entre variables. En comparación con algoritmos como árboles de decisión, redes neuronales o máquinas de soporte vectorial, los modelos lineales requieren menos ajuste y datos para lograr buenos resultados cuando la relación subyacente es efectivamente lineal.

Modelo	Interpretabilidad	Capacidad para relaciones no lineales	Sensibilidad a ruido/atípicos	Complejidad computacional
Lineal	Alta	Baja	Alta	Baja
Árbol de decisión	Media	Media	Media	Media
Red neuronal	Baja	Alta	Alta	Alta
SVM (kernel no lineal)	Baja	Alta	Media	Alta

Seleccionar el modelo adecuado depende de la naturaleza de los datos y del problema. Los modelos lineales resultan especialmente efectivos cuando la interpretabilidad y la rapidez son prioritarias.

Ajuste de hiperparámetros y selección de características

El ajuste de hiperparámetros, como el parámetro de regularización `alpha`, puede realizarse con técnicas automáticas como la búsqueda en rejilla (`GridSearchCV`). Además, la selección de características mejora la capacidad predictiva y la eficiencia del modelo.

- Selección automática basada en regularización L1: El modelo Lasso tiende a eliminar variables irrelevantes.
- Métodos de eliminación recursiva: Algoritmos como `RFE` (Recursive Feature Elimination) identifican y descartan características menos importantes.

Ejemplo de búsqueda en rejilla para ajustar `alpha` en Ridge:

```
from sklearn.model_selection import GridSearchCV
param_grid = {'alpha': [0.01, 0.1, 1, 10]}
grid = GridSearchCV(Ridge(), param_grid, cv=5, scoring='neg_mean_
squared_error')
grid.fit(X_train, y_train)
print("Mejor alpha:", grid.best_params_)
```

La selección cuidadosa de características y la optimización de los hiperparámetros elevan el rendimiento del modelo, reducen el riesgo de sobreajuste y mejoran la interpretabilidad.

Técnicas avanzadas: interacciones y polinomios

Aunque los modelos lineales tradicionales no capturan relaciones no lineales, es posible ampliar su capacidad introduciendo términos de interacción y características polinómicas.

- Términos de interacción: Reflejan efectos combinados de dos o más variables.
- Características polinómicas: Permiten modelar relaciones cuadráticas o de mayor orden.

La generación de estas características se realiza con `PolynomialFeatures` de scikit-learn:

```
from sklearn.preprocessing import PolynomialFeatures
poly = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly.fit_transform(X)
```

La inclusión de términos polinómicos incrementa la flexibilidad del modelo, pero puede aumentar el riesgo de sobreajuste y la complejidad computacional.

Diagnóstico y visualización del modelo

El análisis de residuos y la visualización de predicciones versus valores reales permiten identificar posibles desviaciones y mejorar la comprensión del ajuste.

- Gráficos de residuos: Un patrón aleatorio indica cumplimiento de supuestos. Patrones sistemáticos sugieren problemas de linealidad o heteroscedasticidad.
- Gráficos de dispersión predicción-real: Revelan el grado de ajuste y la presencia de errores sistemáticos.

Ejemplo con matplotlib:

```
import matplotlib.pyplot as plt
plt.scatter(y_test, y_pred)
plt.xlabel("Valores reales")
plt.ylabel("Predicciones")
plt.title("Predicciones vs. Valores reales")
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'k-
-')
plt.show()
```

La interpretación visual complementa las métricas cuantitativas y facilita la comunicación de resultados a audiencias técnicas y no técnicas.

Resumen operativo de la implementación de modelos lineales

- Preparar y limpiar los datos.
- Dividir en conjuntos de entrenamiento y prueba.
- Seleccionar y ajustar el modelo lineal adecuado.
- Aplicar regularización si es necesario.
- Evaluar el rendimiento con métricas apropiadas.
- Diagnosticar supuestos y ajustar hiperparámetros.
- Interpretar y comunicar los resultados.

El dominio de estas etapas permite construir soluciones robustas, interpretables y eficientes para una amplia gama de problemas supervisados.

2.4. Modelos supervisados de ML: árboles, SVM, redes neuronales

Los modelos supervisados constituyen una familia central de técnicas en el Machine Learning, diseñadas para aprender patrones a partir de datos etiquetados y realizar predicciones sobre instancias futuras. Entre las metodologías más extendidas destacan los árboles de decisión, las máquinas de soporte vectorial (SVM) y las redes neuronales. Cada una ofrece enfoques y capacidades específicas para abordar problemas de clasificación y regresión, diferenciándose tanto en su funcionamiento interno como en su aplicabilidad, ventajas y limitaciones.

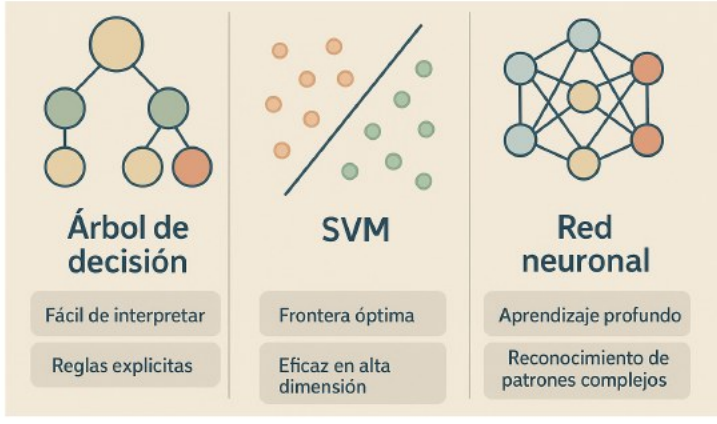

Árboles de decisión

Los árboles de decisión se estructuran como modelos jerárquicos que dividen el espacio de características en regiones homogéneas respecto a la variable objetivo. El proceso de toma de decisiones se representa mediante una estructura de nodos y ramas, donde cada nodo interno evalúa una condición sobre un atributo y cada rama representa el resultado de esa condición. La predicción final se determina en los nodos hoja.

Funcionamiento

El algoritmo construye el árbol seleccionando recursivamente el atributo y el umbral que mejor separan las clases (o minimizan la varianza en regresión) en cada nodo. Las métricas habituales para la selección de particiones incluyen:

- Gini: mide la impureza de una partición; se emplea en clasificación.

- Entropía: mide la incertidumbre asociada a una partición; también se usa en clasificación.
- Reducción de varianza: utilizada en problemas de regresión.

El árbol se expande hasta que se cumple un criterio de parada, como alcanzar una profundidad máxima, un número mínimo de muestras por hoja o una mejora mínima en la métrica de partición.

Ventajas

- Interpretabilidad alta: la estructura es legible y fácil de visualizar.
- Maneja variables numéricas y categóricas sin requerir preprocesamiento especial.
- Soporta relaciones no lineales y capturan interacciones entre variables.
- Requiere poco ajuste de parámetros en comparación con otros modelos.

Desventajas

- Tienden al sobreajuste si no se regulan adecuadamente (árboles muy profundos).
- Sensibles a pequeñas variaciones en los datos; pueden generar árboles muy diferentes ante mínimas perturbaciones.
- Menor rendimiento comparado con técnicas más complejas en problemas de alta dimensionalidad o con muchos valores atípicos.

Aplicaciones

Los árboles de decisión se aplican en tareas de clasificación (diagnóstico médico, detección de fraude) y regresión (predicción de precios, estimación de demanda). Su extensión en técnicas de ensamblado como Random Forests y Gradient Boosted Trees los ha consolidado como componentes clave en competiciones de Machine Learning y soluciones industriales.

Implementación en Python

Para implementar un árbol de decisión en Python, la biblioteca scikit-learn proporciona la clase `DecisionTreeClassifier` (clasificación) y `DecisionTreeRegressor` (regresión). El flujo básico comprende:

- Preparar y codificar los datos (transformación de etiquetas, manejo de valores nulos).

- Dividir el conjunto de datos en subconjuntos de entrenamiento y prueba.
- Instanciar el modelo y ajustar hiperparámetros (profundidad máxima, criterio de partición, etc.).
- Entrenar el modelo con los datos de entrenamiento.
- Realizar predicciones y evaluar el rendimiento con métricas adecuadas (precisión, F1, exactitud, MAE/MSE en regresión).

Ejemplo mínimo de clasificación:

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
X, y = load_iris(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
clf = DecisionTreeClassifier(max_depth=3, criterion='gini', random_
state=42)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
print('Accuracy:', accuracy_score(y_test, y_pred))
```

Máquinas de soporte vectorial (SVM)

Las máquinas de soporte vectorial son modelos supervisados fundamentados en la maximización del margen entre clases. Su principio consiste en encontrar el hiperplano óptimo que separa las clases de manera que la distancia a los puntos más cercanos de cada clase (vectores soporte) sea máxima. Esta formulación garantiza una separación robusta y una buena capacidad de generalización, especialmente en espacios de alta dimensión.

Funcionamiento

En problemas linealmente separables, la SVM calcula el hiperplano que maximiza el margen. Si los datos no son separables linealmente, la SVM introduce un margen tolerante a errores (soft margin) y utiliza funciones núcleo (kernels) para proyectar los datos en espacios de mayor dimensión donde la separación es factible.

Kernels comunes:

- Lineal: separación directa mediante un hiperplano.

- Polinomial: considera combinaciones polinómicas de las características.
- Radial Basis Function (RBF) o Gaussiano: separa datos con fronteras no lineales.
- Sigmoide: emula una red neuronal de una sola capa oculta.

La función objetivo de la SVM puede escribirse como:

$$\left(\min\right)\left(w, b, \xi\right) = \frac{1}{2} \|^{w} + C \sum_{i=1}^{n} \xi_i$$

sujeto a $y_i(w \cdot x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$ donde C controla la penalización por errores de clasificación.

Ventajas

- Eficiente en espacios de alta dimensión.
- Funciona bien con conjuntos de datos con número de características mayor que el número de muestras.
- Flexibilidad gracias a los kernels; capaz de modelar relaciones no lineales.
- Robustez al sobreajuste cuando se ajusta correctamente el parámetro .

Desventajas

- El coste computacional crece rápidamente con el tamaño del conjunto de datos, tanto en memoria como en tiempo.
- La elección y ajuste del kernel es crítica y puede requerir experimentación.
- Escalabilidad limitada en conjuntos de datos muy grandes.
- Difícil interpretación de los modelos, especialmente con kernels no lineales.

Aplicaciones

La SVM es efectiva en clasificación de texto (spam, análisis de sentimientos), reconocimiento de imágenes, bioinformática y problemas donde las fronteras de decisión pueden ser complejas y el número de muestras no es masivo.

Implementación en Python

La clase `SVC` de scikit-learn implementa SVM para clasificación. Para regresión existe `SVR`. El proceso estándar incluye:

- Escalar las características, preferiblemente con `StandardScaler`.
- Dividir los datos en entrenamiento y prueba.
- Definir el kernel adecuado y ajustar los hiperparámetros (C, gamma, grado).
- Entrenar el modelo.
- Realizar predicciones y medir el rendimiento.

Ejemplo básico de SVM de clasificación:

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import classification_report
X, y = load_wine(return_X_y=True)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_
size=0.3, random_state=42)
svm = SVC(kernel='rbf', C=1.0, gamma='scale', random_state=42)
svm.fit(X_train, y_train)
y_pred = svm.predict(X_test)
print(classification_report(y_test, y_pred))
```

Redes neuronales

Las redes neuronales artificiales (ANN) modelan relaciones complejas mediante la conexión de múltiples unidades de procesamiento llamadas neuronas. Inspiradas en el sistema nervioso biológico, estas redes pueden aproximar funciones arbitrarias y capturar patrones no lineales de gran complejidad.

Funcionamiento

Una red neuronal típica consta de:

- Capa de entrada: recibe las características del problema.
- Capas ocultas: capas intermedias donde las neuronas combinan los valores de entrada mediante pesos y funciones de activación no lineales.
- Capa de salida: produce la predicción final (clase, valor continuo, etc.).

- Cada neurona ejecuta la operación:

$$z = \sum_i w_i x_i + b$$
$$a = f(z)$$

donde w_i son los pesos, b el sesgo y f la función de activación (ReLU, sigmoide, tanh). El entrenamiento ajusta los pesos minimizando una función de pérdida mediante retropropagación y descenso de gradiente. La arquitectura y la profundidad (número de capas ocultas) determinan la capacidad del modelo para capturar relaciones complejas. Las redes profundas (deep learning) han mostrado resultados sobresalientes, aunque requieren más datos y capacidad de cómputo.

Ventajas

- Capacidad de aproximar funciones altamente no lineales y complejas.
- Adaptabilidad a datos estructurados y no estructurados (imágenes, texto, sonido).
- Capacidad de aprendizaje jerárquico de representaciones.

Desventajas

- Requieren grandes cantidades de datos y recursos computacionales para entrenar.
- Menor interpretabilidad: se consideran modelos de "caja negra".
- Susceptibilidad al sobreajuste si no se regulan (dropout, regularización L1/L2).
- Ajuste de hiperparámetros y arquitectura complejo, con alta sensibilidad a la inicialización y el aprendizaje.

Aplicaciones

Las redes neuronales han revolucionado el procesamiento de imágenes (reconocimiento facial, diagnóstico médico), análisis de texto (traducción automática, chatbots), reconocimiento de voz y predicción de series temporales, entre otros.

Implementación en Python

En Python, scikit-learn ofrece `MLPClassifier` y `MLPRegressor` para problemas estándar. Bibliotecas especializadas como TensorFlow y PyTorch permiten arquitecturas avanzadas y entrenamiento eficiente en GPU.

Pasos básicos usando `MLPClassifier`:

- Normalizar/características los datos.
- Dividir en entrenamiento y prueba.
- Definir la arquitectura (número de capas, neuronas, función de activación).
- Ajustar hiperparámetros como tamaño de lote, tasa de aprendizaje, número de épocas.
- Entrenar y evaluar el modelo.

Ejemplo mínimo de red neuronal para clasificación:

```
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score
X, y = load_digits(return_X_y=True)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_
size=0.3, random_state=42)
mlp = MLPClassifier(hidden_layer_sizes=(100,), activation='relu', max_
iter=200, random_state=42)
mlp.fit(X_train, y_train)
y_pred = mlp.predict(X_test)
print('Accuracy:', accuracy_score(y_test, y_pred))
```

Comparativa de modelos

La elección entre árboles de decisión, SVM y redes neuronales depende del problema, la naturaleza de los datos y los requisitos prácticos.

La siguiente tabla resume las principales diferencias:

Criterio	Árboles de decisión	SVM	Redes neuronales
Interpretabilidad	Alta	Baja-moderada	Baja

Criterio	Árboles de decisión	SVM	Redes neuronales
Robustez al sobreajuste	Baja (sin poda)	Alta (bien ajustado)	Media-baja
Escalabilidad	Alta (con ensamblado)	Limitada	Alta (con hardware adecuado)
Datos requeridos	Pocos-moderados	Moderados	Muchos
Manejo de no linealidad	Bueno	Excelente (con kernel)	Excelente
Preprocesamiento	Bajo	Alto (escalado necesario)	Alto (normalización, codificación)
Ajuste de parámetros	Bajo-moderado	Alto	Alto
Soporte para regresión	Sí	Sí	Sí
Velocidad de inferencia	Muy alta	Alta	Variable (según arquitectura)
Aplicaciones típicas	Tablas, reglas, scoring	Texto, imágenes, bioinfo	Imágenes, texto, voz, series

Procedimientos típicos de implementación

Independientemente del modelo seleccionado, el flujo genérico para construir modelos supervisados en Python incluye:

- Preparación y preprocesamiento de datos:
  - Limpieza (eliminación/tratamiento de valores nulos).
  - Codificación de variables categóricas (one-hot, label encoding).
  - Normalización o estandarización de atributos.
  - División de los datos en conjuntos de entrenamiento y prueba (por ejemplo, 70/30%).

- Selección y configuración del modelo:
  - Instanciación del modelo apropiado y ajuste de sus hiperparámetros.
  - Para SVM y redes neuronales, asegurarse del escalado adecuado de los datos.
- Entrenamiento:
  - Ajuste del modelo usando los datos de entrenamiento.
  - Posible validación cruzada para seleccionar hiperparámetros óptimos.
- Evaluación del rendimiento:
  - Métricas comunes en clasificación: exactitud (accuracy), precisión, recall, F1.
  - Métricas en regresión: MAE (Error Absoluto Medio), MSE (Error Cuadrático Medio), R2.
  - Inspección de matrices de confusión y curvas ROC/AUC en clasificación.
- Ajuste y validación:
  - Ajuste de hiperparámetros mediante búsqueda en malla (`GridSearchCV`).
  - Evaluación de la robustez mediante validación cruzada k-fold.
  - Aplicación de regularización y técnicas de reducción de sobreajuste si es necesario.
- Despliegue y uso en producción:
  - Serialización del modelo entrenado (`joblib`, `pickle`).
  - Integración en sistemas de predicción o aplicaciones.
  - Monitorización continua del rendimiento para detectar deriva de datos.

Micro-caso aplicado: Una entidad bancaria desea predecir la probabilidad de impago de nuevos solicitantes de crédito. Utiliza un árbol de decisión para identificar reglas interpretables sobre edad, ingresos y empleo, lo que facilita la explicación de las decisiones a los clientes. Paralelamente, un modelo SVM ajustado con kernel RBF permite detectar patrones complejos en el historial crediticio, optimizando la discriminación entre clientes solventes y de riesgo. Finalmente, la entidad evalúa una red neuronal profunda sobre grandes volúmenes de datos históricos para extraer patrones no evidentes, mejorando la precisión a costa de una menor interpretabilidad.

Consideraciones prácticas

La selección de un modelo debe basarse en la calidad y cantidad de los datos, la necesidad de interpretabilidad, los recursos computacionales disponibles y el contexto de aplicación. Los árboles de decisión son idóneos cuando la comprensión del modelo es prioritaria; las SVM destacan en problemas con fronteras complejas y conjuntos de datos moderados; las redes neuronales resultan imbatibles en datos masivos y tareas donde la no linealidad y la abstracción de representaciones son determinantes.

El ajuste de hiperparámetros y la evaluación rigurosa mediante validación cruzada constituyen prácticas esenciales para maximizar el rendimiento y la robustez del modelo. La monitorización en producción y la actualización periódica de los modelos son imprescindibles para mantener la calidad predictiva en entornos dinámicos.

¿Sabías que...?

La primera red neuronal artificial funcional, conocida como el perceptrón, fue desarrollada en 1957 por Frank Rosenblatt. Aunque inicialmente limitada, sentó las bases de la inteligencia artificial moderna y, décadas después, inspiró el desarrollo de redes neuronales profundas que impulsan tecnologías actuales como el reconocimiento automático de voz y la visión por computador.

2.5. Combinación de modelos. Random Forest

La combinación de modelos constituye una estrategia robusta dentro del aprendizaje supervisado, permitiendo incrementar la precisión y robustez de las predicciones mediante la agregación de múltiples estimadores. Entre las técnicas más eficaces y extendidas se encuentra Random Forest, un algoritmo de ensamble basado en la generación y combinación de múltiples árboles de decisión. El fundamento de Random Forest reside en la reducción de la varianza inherente a cada árbol individual, logrando así una mayor generalización y minimización del sobreajuste en conjuntos de datos complejos.

Random Forest pertenece a la familia de métodos de bagging (Bootstrap Aggregating), los cuales aprovechan el muestreo aleatorio con reemplazo para construir varios modelos independientes sobre subconjuntos diferentes del conjunto de datos original. En cada iteración, el algoritmo genera una muestra bootstrap y entrena un árbol de decisión sobre ella. Además, en cada nodo de división de un árbol, Random Forest selecciona aleatoriamente un subconjunto de características, de modo que

cada árbol explora diferentes combinaciones de variables predictoras. Esta doble aleatorización —tanto en las instancias como en las variables— es clave para garantizar la independencia entre árboles y potenciar la diversidad del conjunto.

Los modelos individuales de árboles de decisión presentan alta varianza: pequeñas fluctuaciones en los datos de entrenamiento pueden causar diferencias significativas en su estructura y predicción. Random Forest mitiga este problema al promediar (en regresión) o votar (en clasificación) las salidas de múltiples árboles, logrando así modelos más estables y precisos. El efecto combinado de múltiples árboles reduce la probabilidad de tomar decisiones sesgadas por anomalías o ruido presentes en los datos de entrenamiento.

Funcionamiento de Random Forest

El proceso de construcción de un Random Forest sigue estos pasos principales:

- Se define el número de árboles a construir (n_estimators).
- Para cada árbol:
    - Se selecciona aleatoriamente una muestra bootstrap del conjunto de entrenamiento (con reemplazo).
    - En cada nodo de división, se escoge aleatoriamente un subconjunto de variables predictoras (max_features) y se elige la mejor división solo entre esas variables.
    - El árbol se desarrolla hasta un criterio de parada especificado (por ejemplo, profundidad máxima o número mínimo de muestras por hoja).
- Para nuevas predicciones:
    - En clasificación, cada árbol vota por una clase; la clase mayoritaria es la predicción final.
    - En regresión, se promedian las predicciones de todos los árboles.

Estos principios permiten que Random Forest aproveche la fortaleza de cada árbol individual, a la vez que neutraliza sus debilidades mediante la agregación colectiva.

Ventajas de Random Forest

- Reducción del sobreajuste: El promediado o votación reduce el riesgo de que el modelo se adapte demasiado a las particularidades del conjunto de entrenamiento.

- Robustez ante ruido y valores atípicos: La diversidad de árboles y el muestreo aleatorio disminuyen la sensibilidad a datos erróneos o atípicos.
- Manejo eficiente de grandes volúmenes de datos: Es eficiente tanto en problemas de clasificación como de regresión, incluso con conjuntos de datos extensos y de alta dimensionalidad.
- Estimación de importancia de variables: Random Forest facilita la evaluación de la relevancia de cada variable predictora, útil para tareas de selección de características.
- Versatilidad: Funciona bien con datos faltantes, variables categóricas y escalas distintas entre variables.

Limitaciones y consideraciones

- Modelos poco interpretables: Debido a la complejidad acumulada de muchos árboles, la interpretación directa del modelo como un todo resulta difícil, aunque se puedan extraer reglas individuales de árboles concretos.
- Coste computacional: El entrenamiento y la predicción pueden ser más lentos en comparación con modelos individuales, especialmente con un número elevado de árboles y datos masivos.
- Propensión a sobreajuste en casos extremos: Aunque Random Forest está diseñado para evitar el sobreajuste, puede producirlo si los árboles individuales se vuelven excesivamente complejos o no se ajustan los hiperparámetros adecuadamente.

Combinación de modelos: comparación entre enfoques

Random Forest se diferencia de otras técnicas de ensamble, como el boosting, en la forma en que combina sus modelos base:

Método	Base learners	Combina por	Diversidad lograda por	Sensibilidad al sobreajuste
Bagging (RF)	Árboles indep.	Votación/prome.	Bootstrap + selección de variables	Baja
Boosting	Árboles secuenc.	Ponderación sec.	Enfoque en errores previos	Moderada/Alta

Método	Base learners	Combina por	Diversidad lograda por	Sensibilidad al sobreajuste
Stacking	Modelos diversos	Meta-modelo	Diferentes algoritmos	Variable

Random Forest pertenece claramente a la categoría de bagging, priorizando la diversidad y la independencia entre modelos base.

Implementación de Random Forest en Python

La biblioteca scikit-learn proporciona una implementación optimizada y sencilla para aplicar Random Forest tanto en clasificación como en regresión. Su uso básico implica los siguientes pasos:

- Preparación de los datos: limpieza, codificación de variables categóricas y división en conjuntos de entrenamiento y prueba.
- Instanciación del modelo: selección del tipo (RandomForestClassifier o RandomForestRegressor) y fijación de hiperparámetros iniciales.
- Entrenamiento (fit): ajuste del modelo sobre el conjunto de entrenamiento.
- Predicción (predict): generación de predicciones sobre nuevos datos.
- Evaluación: cálculo de métricas de rendimiento para validar la eficacia del modelo.

Ejemplo de clasificación con Random Forest

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
X, y = load_iris(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)
clf = RandomForestClassifier(n_estimators=100, max_depth=5, random_
state=42)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
print(f"Precisión: {accuracy_score(y_test, y_pred):.3f}")
```

Este código prepara el clásico conjunto de datos de iris, divide los datos, entrena el modelo y reporta la precisión obtenida sobre el conjunto de prueba.

Ejemplo de regresión con Random Forest

```
from sklearn.ensemble import RandomForestRegressor
from sklearn.datasets import load_boston
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error
X, y = load_boston(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_
size=0.25, random_state=0)
reg = RandomForestRegressor(n_estimators=100, max_depth=10, random_
state=0)
reg.fit(X_train, y_train)
y_pred = reg.predict(X_test)
print(f"RMSE: {mean_squared_error(y_test, y_pred, squared=False):.2f}")
```

Este ejemplo ilustra la aplicación para un problema de regresión, mostrando cómo obtener la raíz del error cuadrático medio (RMSE) como métrica principal.

Selección y ajuste de hiperparámetros

La calidad de un modelo Random Forest depende en gran medida de la correcta elección de sus hiperparámetros principales:

- n_estimators: número de árboles en el bosque. Más árboles suelen mejorar la robustez, aunque incrementan el coste computacional.
- max_depth: profundidad máxima permitida para cada árbol. Limitar la profundidad ayuda a evitar el sobreajuste.
- min_samples_split: número mínimo de muestras requeridas para dividir un nodo.
- min_samples_leaf: número mínimo de muestras requeridas para ser una hoja.
- max_features: número de características seleccionadas aleatoriamente en cada división de nodo.
- bootstrap: si se utiliza el muestreo con reemplazo al construir cada árbol.

El ajuste óptimo de estos parámetros requiere una evaluación sistemática, generalmente mediante técnicas de búsqueda en cuadrícula (Grid Search)

o búsqueda aleatoria (Randomized Search), junto con validación cruzada. Un procedimiento típico sería:

- Definir un rango de valores para cada hiperparámetro relevante.
- Ejecutar la búsqueda sistemática (grid search) usando validación cruzada para comparar combinaciones.
- Seleccionar la configuración que maximice la métrica de interés (precisión, F1, AUC, RMSE, etc.).
- Volver a entrenar el modelo completo con los mejores hiperparámetros encontrados.

Ejemplo de ajuste de hiperparámetros con GridSearchCV

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [None, 5, 10],
    'max_features': ['sqrt', 'log2']
}
clf = RandomForestClassifier(random_state=42)
grid_search = GridSearchCV(clf, param_grid, cv=5, scoring='accuracy')
grid_search.fit(X_train, y_train)
print("Mejores parámetros:", grid_search.best_params_)
```

Este fragmento realiza una búsqueda en cuadrícula para encontrar la mejor combinación de hiperparámetros utilizando validación cruzada de 5 particiones.

Evaluación del rendimiento del modelo

La evaluación rigurosa de un Random Forest requiere comparar su rendimiento usando métricas adecuadas para la tarea:

- Clasificación:
  - Precisión: proporción de aciertos sobre el total de predicciones.
  - Matriz de confusión: desglosa aciertos y errores por clase.
  - F1-score: balance entre precisión y exhaustividad.
  - AUC-ROC: mide la capacidad de discriminación entre clases.

- Regresión:
  - RMSE (Root Mean Squared Error): raíz del error cuadrático medio.
  - MAE (Mean Absolute Error): error absoluto medio.
  - (Coeficiente de determinación): proporción de varianza explicada.

  Comparar Random Forest con otros modelos base (como un solo árbol de decisión o una regresión logística) permite visualizar su ventaja en términos de reducción de error y mejora de la estabilidad predictiva.

Interpretabilidad y análisis de importancia de variables

Aunque Random Forest no es directamente interpretable como un árbol individual, ofrece mecanismos para analizar la relevancia de las variables predictoras. La importancia de variables se calcula típicamente mediante la reducción en la impureza (Gini o entropía) o la disminución del error al permutar los valores de una variable.

En Python, acceder a la importancia de variables es directo:

```
import matplotlib.pyplot as plt
importancias = clf.feature_importances_
plt.bar(range(len(importancias)), importancias)
plt.xlabel('Variables')
plt.ylabel('Importancia')
plt.title('Importancia de variables en Random Forest')
plt.show()
```

Esta visualización guía la selección de variables y permite identificar predictores clave para la toma de decisiones.

Consideraciones prácticas y mejores prácticas

Para maximizar el rendimiento y la utilidad de Random Forest en escenarios reales, se recomienda:

- Estandarizar y limpiar los datos antes del entrenamiento.
- Probar varios valores de hiperparámetros clave, especialmente n_estimators y max_depth.
- Utilizar validación cruzada para evaluar la generalización.

- Analizar la importancia de variables y reducir dimensionalidad si el conjunto lo permite.
- Implementar técnicas de balanceo de clases en problemas desbalanceados, como el sobremuestreo o el submuestreo.
- Monitorizar el coste computacional y emplear técnicas de paralelización si el volumen de datos o la cantidad de árboles lo requiere.

Micro-caso aplicado: En una empresa de telecomunicaciones, el área de retención de clientes necesita predecir la probabilidad de abandono basándose en datos históricos de consumo, incidencias y atención al cliente. Al aplicar Random Forest, se consigue una mejora significativa en la precisión respecto a modelos tradicionales, permitiendo identificar a tiempo a los clientes con mayor riesgo de baja. El análisis de importancia de variables revela que los patrones de llamadas y el historial de reclamaciones son los factores más determinantes, lo que orienta nuevas políticas preventivas.

Comparación práctica: Random Forest vs. Árbol de decisión individual

Característica	Árbol de decisión	Random Forest
Varianza	Alta	Baja
Sobreajuste	Propenso	Menor probabilidad
Interpretabilidad	Alta	Baja
Robustez ante ruido	Baja	Alta
Precisión general	Moderada	Alta
Coste computacional	Bajo	Moderado/Alto

Procedimiento resumido para aplicar Random Forest en un proyecto

- Definir el objetivo del modelo (clasificación o regresión).
- Recopilar y preparar los datos: limpieza, codificación, escalado y partición.
- Instanciar el modelo Random Forest adecuado.
- Ajustar los hiperparámetros mediante validación cruzada.
- Entrenar el modelo sobre el conjunto de entrenamiento.
- Evaluar el rendimiento sobre el conjunto de prueba usando métricas apropiadas.

- Analizar la importancia de variables y ajustar el modelo si es necesario.
- Implementar el modelo en el entorno productivo y monitorizar su desempeño.

Random Forest representa una de las herramientas más fiables y versátiles para la combinación de modelos en aprendizaje supervisado, destacando por su capacidad de manejar datos complejos, reducir el sobreajuste y ofrecer resultados competitivos en una amplia gama de aplicaciones.

Toma nota

Random Forest sobresale como técnica de combinación de modelos por su capacidad para reducir la varianza y mejorar la precisión predictiva, siendo especialmente útil en escenarios con datos complejos, alta dimensionalidad y presencia de ruido, lo que lo convierte en una elección preferente en la práctica profesional del aprendizaje supervisado.

Actividades

4. ¿Cómo definirías la variable objetivo en un caso supervisado, justificarías la elección entre clasificación o regresión, y organizarías el conjunto de datos en train/validation/test con estrategias adecuadas (p. ej., StratifiedKFold cuando proceda), indicando qué métricas utilizarías según el tipo de tarea (accuracy, precisión, recall, F1, AUC-ROC/PR o MAE/MSE) y cómo evitarías leakage fijando `random_state` y separando correctamente el preprocesado del ajuste?

5. ¿Podrías construir un pipeline con `ColumnTransformer` que incluya imputación, codificación y escalado, y entrenar modelos lineales (Regresión/Regresión Logística y variantes regularizadas Ridge/Lasso/Elastic Net), explicando la interpretación de coeficientes y comparando el rendimiento con MAE/MSE en regresión o con precisión/recall/F1 en clasificación, dejando trazabilidad de cada paso?

6. ¿Cómo entrenarías y ajustarías árboles de decisión, SVM (con kernels) y una red neuronal básica tipo MLP de scikit-learn, utilizando `GridSearchCV` o búsqueda aleatoria con `StratifiedKFold`, comparando el trade-off sesgo–varianza, reportando matriz de confusión y curvas ROC/PR, y tratando el desbalanceo con `class_weight` o técnicas como SMOTE integradas en el pipeline?

7. ¿De qué forma aplicarías una combinación de modelos mediante bagging/ Random Forest, validarías la importancia de variables, usarías validación cruzada para comparar con los modelos anteriores, analizarías learning curves y aplicarías permutation importance o SHAP (cuando aplique) para interpretar el modelo, justificando la selección final con las métricas definidas?

3

Aprendizaje no supervisado

ÍNDICE

3.1. Definición y aplicaciones.

3.2. Medidas de rendimiento.

3.3. Clustering. Tipos

3.4. Biclustering

3.5. Manifolds. Reducción de la dimensionalidad

3.6. Análisis de la cesta.

OBJETIVO

Este tema tiene como finalidad que el alumno pueda aplicar técnicas de aprendizaje no supervisado para analizar estructuras latentes en los datos. Se estudian distintos métodos de clustering (k-means, DBSCAN, clustering jerárquico, k-medoids), incluyendo la justificación de hiperparámetros como k o epsilon y el uso de métricas de validación interna y externa (silhouette, Calinski-Harabasz, Davies-Bouldin). Además, se abordan técnicas avanzadas como biclustering y reducción de dimensionalidad mediante PCA, t-SNE y UMAP, evaluando la pérdida de información. También se introduce el análisis de la cesta de la compra con reglas de asociación, destacando la extracción de insights accionables a partir de patrones frecuentes.

El aprendizaje no supervisado explora datos sin etiquetas para identificar patrones o agrupamientos latentes. Algoritmos como K-means segmentan datos en grupos según similitud, mientras que DBSCAN detecta agrupaciones de densidad variable, útil para descubrir anomalías.

La reducción de dimensionalidad, como PCA (Análisis de Componentes Principales), simplifica conjuntos de datos complejos preservando la información más relevante. La validación de resultados en este contexto requiere métricas como la inercia (en K-means), el silhouette score o la inspección visual de los

grupos generados. El ajuste de parámetros, como el número de clusters o el radio de densidad, resulta esencial para optimizar el desempeño del modelo. Estos métodos facilitan tareas como segmentar clientes, identificar patrones de consumo o preparar datos para modelos supervisados.

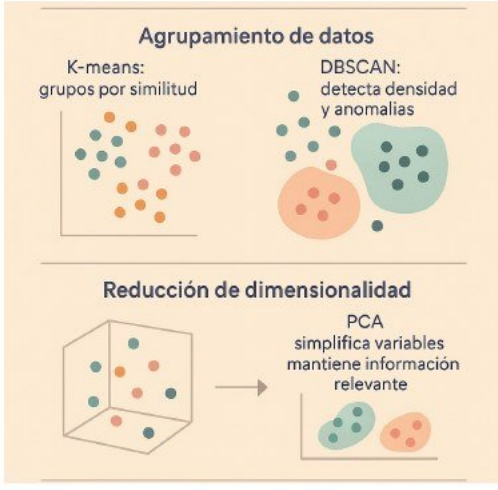

Algoritmo	Tipo de agrupamiento	Parámetros clave	Ventajas	Limitaciones
K-means	Centroides	k (nº clusters)	Rápido, simple	Sensible a outliers
DBSCAN	Densidad	eps, min_ samples	Detecta ruido	No define k

¿Sabías que...?

Al aplicar PCA, los primeros componentes suelen retener más del 80% de la varianza original, permitiendo visualizar datos de alta dimensión en solo dos o tres variables con mínima pérdida de información.

3.1. Definición y aplicaciones

El aprendizaje no supervisado constituye una de las ramas primordiales del machine learning, caracterizándose por la capacidad de identificar estructuras, patrones y

relaciones intrínsecas en conjuntos de datos sin etiquetas o anotaciones previas. A diferencia del aprendizaje supervisado, donde el modelo aprende a partir de ejemplos con respuestas conocidas, el aprendizaje no supervisado se orienta a descubrir información latente y útiles agrupamientos sin intervención directa sobre los resultados. Esta aproximación es especialmente relevante en escenarios donde la obtención de etiquetas resulta costosa, inviable o simplemente innecesaria para el objetivo analítico.

La importancia del aprendizaje no supervisado radica en su aplicabilidad para extraer valor de datos no estructurados, abundantes en dominios como marketing, finanzas, biomedicina y seguridad informática. Permite abordar problemas donde la naturaleza subyacente de los datos no es evidente, facilitando el análisis exploratorio y la toma de decisiones basadas en patrones emergentes. Además, sirve como punto de partida para tareas más complejas o para mejorar el rendimiento de modelos supervisados al reducir la dimensionalidad o identificar subgrupos relevantes.

Características fundamentales del aprendizaje no supervisado

- Procesa datasets sin etiquetas, es decir, sin una variable objetivo explícita.
- Busca estructuras ocultas, regularidades o agrupaciones naturales en los datos.
- Utiliza métricas de similitud, distancia o correlación para definir relaciones entre muestras.
- Requiere menor intervención humana inicial, pero puede necesitar interpretación experta sobre los resultados.
- Puede ser sensible a la escala y representación de los datos, exigiendo preprocesamiento cuidadoso.

Tipos principales de problemas de aprendizaje no supervisado

El enfoque no supervisado abarca diversos problemas, entre los que destacan:

- Agrupamiento (clustering): Consiste en organizar los datos en grupos o clústeres de acuerdo a su similitud interna. Cada clúster contiene muestras que son más parecidas entre sí que respecto a las de otros grupos. Ejemplo: segmentación de clientes.
- Reducción de dimensionalidad: Busca representar los datos en un espacio de menor dimensión preservando la máxima cantidad de información importante. Ejemplo: visualización de datos mediante técnicas como PCA.

- Detección de anomalías: Identifica puntos fuera de lo común, desviaciones significativas respecto al comportamiento normal de los datos. Ejemplo: detección de fraudes.
- Asociación: Extrae reglas o relaciones frecuentes entre variables o ítems, común en análisis de cestas de compra.

El enfoque, el algoritmo y la interpretación de resultados varían en función del problema a resolver y la naturaleza de los datos.

Aplicaciones prácticas del aprendizaje no supervisado

El aprendizaje no supervisado se implementa en una variedad de contextos. A continuación se presentan aplicaciones concretas acompañadas de ejemplos de código en Python.

Segmentación de clientes

La segmentación de clientes en marketing permite a las empresas agrupar usuarios en función de sus características y comportamientos de compra, optimizando campañas y recursos.

- El proceso habitual implica:
- Recolectar datos relevantes (edad, frecuencia de compra, gasto medio, etc.).
- Preprocesar los datos (normalización, tratamiento de valores nulos).
- Aplicar un algoritmo de agrupamiento como K-means.
- Interpretar los clústeres resultantes para definir estrategias personalizadas.

Ejemplo de código: Segmentación con K-means

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
# Supongamos un DataFrame 'clientes' con columnas 'edad', 'frecuencia_
compra', 'gasto_medio'
clientes = pd.DataFrame({
    'edad': [25, 34, 45, 23, 35, 40, 52, 23, 37, 29],
    'frecuencia_compra': [5, 2, 3, 8, 7, 3, 1, 9, 6, 4],
    'gasto_medio': [300, 400, 500, 200, 350, 450, 600, 150, 370, 320]
})
```

```
# Normalización de los datos
scaler = StandardScaler()
clientes_normalizados = scaler.fit_transform(clientes)
# Aplicación de K-means
kmeans = KMeans(n_clusters=3, random_state=42)
clientes['segmento'] = kmeans.fit_predict(clientes_normalizados)
print(clientes)
```

Este ejemplo ilustra cómo se pueden asignar automáticamente segmentos a los clientes, facilitando la toma de decisiones basada en datos.

Reducción de dimensionalidad

El análisis de datos multivariantes suele involucrar decenas o cientos de variables, lo que dificulta la visualización y análisis. La reducción de dimensionalidad permite proyectar los datos en espacios de menor dimensión, preservando la mayor cantidad posible de varianza.

El Análisis de Componentes Principales (PCA) es una técnica fundamental en este contexto. PCA transforma los datos originales en nuevas variables ortogonales (componentes principales) ordenadas según su aporte a la varianza total.

Ejemplo de código: Reducción de dimensiones con PCA

```
import numpy as np
from sklearn.decomposition import PCA
# Generar datos sintéticos de ejemplo
X = np.random.rand(100, 5)  # 100 muestras, 5 variables
# Aplicar PCA para reducir a 2 dimensiones
pca = PCA(n_components=2)
X_reducido = pca.fit_transform(X)
print("Varianza explicada:", pca.explained_variance_ratio_)
print("Datos reducidos:\n", X_reducido[:5])
```

El resultado facilita la visualización y análisis, permitiendo identificar patrones o agrupamientos en los datos originales.

Detección de anomalías

La detección de anomalías es crucial en ámbitos como la seguridad, el control industrial o la monitorización financiera. Consiste en identificar observaciones que

se desvían significativamente del patrón general, lo que puede indicar fraude, fallos o eventos inusuales.

Una estrategia común es aplicar algoritmos de agrupamiento y considerar como anomalías los puntos alejados de los centros de los clústeres o con baja densidad de vecinos.

Ejemplo de código: Detección de anomalías con K-means

```
import numpy as np
from sklearn.cluster import KMeans
# Datos simulados con una anomalía
X = np.array([[1, 2], [1, 4], [1, 0], [10, 2]])  # El último punto es atípico
kmeans = KMeans(n_clusters=2, random_state=42)
kmeans.fit(X)
distancias = kmeans.transform(X).min(axis=1)
umbral = np.percentile(distancias, 90)
anomalías = X[distancias > umbral]
print("Puntos anómalos:", anomalías)
```

Este método permite identificar elementos atípicos a partir del agrupamiento, aunque existen técnicas especializadas para escenarios más complejos.

Algoritmos centrales en aprendizaje no supervisado

Diversos algoritmos han sido desarrollados para abordar problemas de aprendizaje no supervisado. A continuación se describen los dos más representativos: K-means para agrupamiento y PCA para reducción de dimensionalidad.

K-means

El algoritmo K-means es una herramienta de agrupamiento basada en la asignación de puntos a clústeres según la proximidad a sus centros o centroides.

- Funcionamiento básico:
  - Seleccionar número de clústeres.Inicializar aleatoriamente los centroides.
  - Asignar cada muestra al centro más cercano (según la distancia euclidiana, por defecto).
  - Recalcular los centroides como la media de los puntos asignados.

- Repetir los dos pasos anteriores hasta que no cambien las asignaciones o se alcance un número máximo de iteraciones.

- Ventajas:
  - Escalabilidad para grandes volúmenes de datos.
  - Sencillez conceptual y facilidad de implementación.

- Limitaciones:
  - Requiere especificar el número de clústeres a priori.
  - Sensible a la inicialización y a la presencia de outliers.
  - Supone que los clústeres son esféricos e igualmente distribuidos en tamaño.

Ejemplo de código detallado con K-means

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
# Generar datos sintéticos
np.random.seed(0)
X = np.vstack([
    np.random.normal(loc=[2, 2], scale=0.5, size=(50, 2)),
    np.random.normal(loc=[7, 7], scale=0.5, size=(50, 2)),
    np.random.normal(loc=[2, 7], scale=0.5, size=(50, 2))
])
# Aplicación de K-means
kmeans = KMeans(n_clusters=3, random_state=42)
etiquetas = kmeans.fit_predict(X)
centroides = kmeans.cluster_centers_
# Visualización
plt.scatter(X[:, 0], X[:, 1], c=etiquetas, cmap='viridis', alpha=0.6)
plt.scatter(centroides[:, 0], centroides[:, 1], c='red', marker='x',
s=100)
plt.title('Clustering con K-means')
plt.show()
```

Análisis de Componentes Principales (PCA)

El PCA es una técnica estadística que transforma un conjunto de variables correlacionadas en un conjunto de variables no correlacionadas llamadas componentes principales. El objetivo es reducir la dimensionalidad manteniendo la mayor cantidad de varianza posible.

- Procedimiento:
  - Centrar los datos restando la media de cada variable.
  - Calcular la matriz de covarianza.
  - Obtener los vectores y valores propios (autovectores y autovalores) de la matriz.
  - Ordenar los autovectores según sus autovalores de mayor a menor.
  - Seleccionar los primeros componentes principales y proyectar los datos sobre ellos.
- Ventajas:
  - Facilita la visualización de datos de alta dimensión.
  - Puede eliminar ruido y redundancia.
  - Mejora la eficiencia de algoritmos posteriores.
- Limitaciones:
  - Supone linealidad en las relaciones entre variables.
  - Puede ser difícil de interpretar cuando los componentes combinan muchas variables originales.
  - No conserva necesariamente la separabilidad de clases en tareas supervisadas.

Ejemplo de código detallado con PCA

```
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
# Cargar datos de ejemplo
iris = load_iris()
X = iris.data
y = iris.target
```

```
# Aplicar PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X)
# Visualización
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=y, cmap='viridis',
edgecolor='k')
plt.xlabel('Componente principal 1')
plt.ylabel('Componente principal 2')
plt.title('Reducción de dimensionalidad con PCA')
plt.show()
```

Comparación entre K-means y PCA

A continuación se presenta una tabla comparativa resaltando los aspectos más relevantes de ambos algoritmos:

Característica	K-means	PCA
Objetivo principal	Agrupamiento	Reducción de dimensionalidad
Tipo de salida	Etiquetas de clúster	Nuevas variables (componentes)
Requiere número de grupos	Sí	Sí (número de componentes)
Supone estructura lineal	No	Sí
Sensible a escala	Sí	Sí
Aplicable a datos categóricos	No (directamente)	No
Interpretabilidad	Media	Baja (si hay muchas variables)
Visualización	Agrupamientos	Proyección en menor dimensión
Uso típico	Segmentación, detección de outliers	Visualización, preprocesamiento

Técnicas adicionales y consideraciones prácticas

El aprendizaje no supervisado comprende una amplia gama de técnicas adicionales y variantes, incluyendo:

- Algoritmos de agrupamiento jerárquico: Construyen una jerarquía de clústeres mediante fusiones o divisiones sucesivas. Ejemplo: aglomerativo, divisivo.
- DBSCAN: Agrupa puntos en función de la densidad, eficaz para clústeres de forma arbitraria y detección de outliers.
- t-SNE y UMAP: Métodos no lineales para reducción de dimensionalidad y visualización de datos complejos.
- Modelos de mezcla gaussiana (GMM): Permiten modelar la distribución de los datos y agruparlos considerando la probabilidad de pertenencia a cada clúster.

Al implementar algoritmos no supervisados, es fundamental considerar:

- Preprocesamiento: La normalización o estandarización de variables previene la dominancia de escalas diferentes y mejora la estabilidad de los algoritmos.
- Selección de parámetros: El número de clústeres o componentes puede determinarse mediante métodos como la "elbow method" (codo), análisis de varianza explicada o validación cruzada no supervisada.
- Interpretación de resultados: Los agrupamientos o componentes identificados requieren validación y contextualización según el dominio de aplicación.
- Visualización: Herramientas gráficas (scatter plots, mapas de calor, dendrogramas) ayudan a comprender la estructura emergente y detectar posibles anomalías.

Micro-caso aplicado: Una empresa minorista desea optimizar sus campañas publicitarias. Utiliza aprendizaje no supervisado para segmentar a sus clientes en grupos basados en hábitos de compra. Tras aplicar K-means con tres clústeres, identifica perfiles: compradores frecuentes, esporádicos y grandes gastadores. Posteriormente, utiliza PCA para reducir la dimensionalidad de las variables de comportamiento y facilitar la visualización de estos segmentos, permitiendo a los responsables de marketing diseñar estrategias diferenciadas por grupo.

Limitaciones y desafíos del aprendizaje no supervisado

Aunque el aprendizaje no supervisado es potente, enfrenta desafíos inherentes:

- Determinación de la estructura óptima: Es difícil validar objetivamente si los grupos o componentes hallados son los más adecuados sin etiquetas conocidas.

- Interpretación subjetiva: La asignación de significado a los clústeres o componentes depende del contexto y del conocimiento experto.
- Sensibilidad al preprocesamiento: Elecciones como la selección de variables, la normalización o la eliminación de outliers influyen directamente en el resultado.
- Escalabilidad: Algunos algoritmos presentan limitaciones de rendimiento con grandes volúmenes de datos o alta dimensionalidad.
- Suposiciones implícitas: La mayoría de los métodos asumen ciertas propiedades (linealidad, esfericidad, densidad homogénea) que pueden no cumplirse en la práctica, afectando la calidad de los resultados.

Buenas prácticas en proyectos de aprendizaje no supervisado

- Exploración inicial de datos: Analizar la distribución, correlación y posibles valores atípicos antes de aplicar modelos.
- Validación interna: Utilizar métricas como la silueta, el coeficiente de Davies–Bouldin o la varianza explicada para evaluar la calidad de los resultados.
- Iteración y ajuste: Probar diferentes algoritmos y parámetros, comparando interpretabilidad y desempeño.
- Documentación y trazabilidad: Registrar decisiones, transformaciones y resultados para asegurar la reproducibilidad y facilitar la revisión.

Implementación técnica y flujo de trabajo

El flujo de trabajo típico para una tarea de aprendizaje no supervisado incluye:

- Selección y exploración de datos pertinentes.
- Preprocesamiento (gestión de nulos, normalización, selección de variables).
- Aplicación del algoritmo elegido (K-means, PCA, etc.).
- Evaluación de la calidad de los resultados mediante métricas internas.
- Interpretación y contextualización de los patrones hallados.
- Comunicación de hallazgos y toma de decisiones basada en los resultados.

Este proceso puede automatizarse parcialmente mediante pipelines, pero la supervisión y revisión experta siguen siendo esenciales dada la naturaleza exploratoria del aprendizaje no supervisado.

Métricas y validación en aprendizaje no supervisado

La ausencia de etiquetas limita el uso de métricas tradicionales de precisión o recall. En su lugar, se utilizan medidas específicas como:

- Índice de silueta: Evalúa la coherencia interna de los clústeres.
- Inercia: Suma de distancias cuadráticas dentro de los clústeres (usada en K-means).
- Varianza explicada: Proporción de varianza capturada por los componentes principales en PCA.
- Coeficiente de Davies–Bouldin: Relación entre la dispersión interna de los clústeres y la distancia entre ellos.
- Validación cruzada no supervisada: Métodos como "stability-based validation" evalúan la robustez de los agrupamientos ante perturbaciones.

La interpretación de estas métricas debe realizarse considerando el contexto y el objetivo del análisis.

Herramientas y entornos de desarrollo en Python

Python ofrece un ecosistema robusto para el aprendizaje no supervisado, con librerías ampliamente utilizadas:

- scikit-learn: Implementa K-means, PCA, DBSCAN, GMM, t-SNE, entre otros.
- pandas y numpy: Manipulación de datos y operaciones numéricas.
- matplotlib y seaborn: Visualización de resultados y patrones.
- scipy: Funciones avanzadas de estadística y álgebra lineal.

El uso combinado de estas herramientas permite construir flujos de trabajo reproducibles y eficientes, integrando preprocesamiento, modelado y visualización en notebooks interactivos (como Jupyter).

Recomendaciones para la aplicación efectiva

- Seleccionar algoritmos y métricas acordes a la naturaleza del problema y los datos disponibles.
- Prestar especial atención a la calidad y representatividad de los datos introducidos en los modelos.
- Interpretar los resultados en colaboración con expertos del dominio para maximizar el valor práctico de los patrones extraídos.

- Documentar cada paso del proceso, incluyendo las decisiones sobre parámetros y los criterios de evaluación aplicados.
- Mantener actualizado el conocimiento sobre nuevas técnicas y herramientas emergentes en el campo del aprendizaje no supervisado.

3.2. Medidas de rendimiento

Las medidas de rendimiento en aprendizaje no supervisado permiten cuantificar la calidad de los agrupamientos, evaluando tanto la coherencia interna de los grupos como su separación respecto a otros. A diferencia del aprendizaje supervisado, en donde métricas como la precisión o el recall dependen de etiquetas conocidas, en el aprendizaje no supervisado se requiere de métricas que calibren la estructura y la utilidad de las agrupaciones generadas a partir de los datos sin referencia externa. Las dos métricas más relevantes en la evaluación de agrupamientos son el coeficiente de Silhouette y el índice de Davies-Bouldin. Ambas se fundamentan en la distancia entre puntos y clústeres, proporcionando una visión objetiva de la compactación y separación de los grupos.

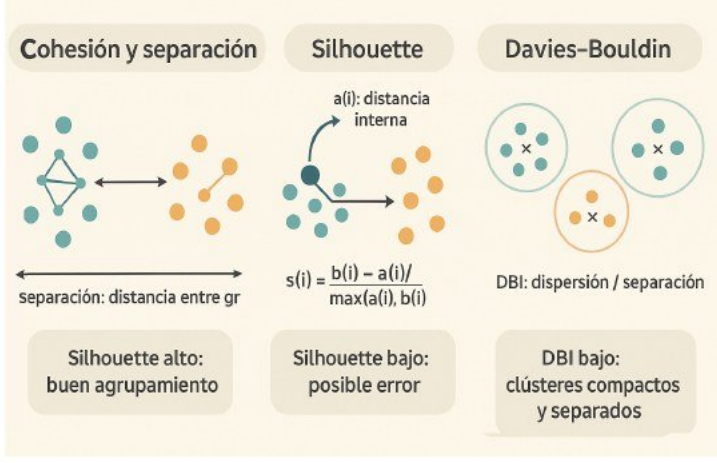

Métricas internas de validación: conceptos fundamentales

Las métricas internas de validación miden la calidad de los clústeres utilizando únicamente los datos y las asignaciones de agrupamiento, sin requerir conocimiento previo sobre la estructura real de los grupos. Su objetivo es maximizar la cohesión intraclúster (proximidad de los puntos dentro de un mismo grupo) y la separación interclúster (distancia entre diferentes grupos).

Los principales aspectos evaluados por estas métricas incluyen:

- Cohesión: Evalúa qué tan próximos están los elementos dentro de un mismo clúster.
- Separación: Determina cuán alejados están los distintos clústeres entre sí.
- Compacidad: Indica el grado de dispersión de los datos dentro de un clúster.
- Consistencia: Analiza si el agrupamiento obtenido es estable frente a pequeñas perturbaciones de los datos.

La correcta interpretación de estas métricas es esencial para seleccionar el número óptimo de clústeres, comparar diferentes algoritmos de agrupamiento y validar la utilidad práctica de los resultados en problemas reales, como la segmentación de clientes o la detección de patrones anómalos.

Coeficiente de Silhouette

El coeficiente de Silhouette cuantifica la calidad de la asignación de cada muestra a su clúster, comparando la distancia media a los puntos de su propio clúster (cohesión) con la distancia media a los puntos del clúster más cercano (separación). El valor obtenido para cada muestra varía entre -1 y 1:

- Cercano a 1: La muestra está bien agrupada y separada de los otros clústeres.
- Cercano a 0: La muestra está en el límite entre dos clústeres.
- Cercano a -1: La muestra puede estar mal asignada, más cerca de otro clúster.

La fórmula para el coeficiente de Silhouette para una muestra i es:

$$s_i = \frac{b_i - a_i}{\max\{a_i, b_i\}}$$

donde:

- a_i es la distancia media desde la muestra *i* a los otros puntos de su mismo clúster.
- b_i es la distancia media desde la muestra al clúster más cercano del que no forma parte.

Para evaluar el agrupamiento global se calcula la media de todos los coeficientes de Silhouette.

Interpretación práctica

Un valor medio de Silhouette elevado indica que los clústeres son compactos y bien separados. Si el valor es bajo o negativo, conviene revisar la configuración del algoritmo, el número de clústeres o la idoneidad de la métrica de distancia utilizada.

Aplicación en Python con Scikit-learn

Scikit-learn proporciona herramientas directas para calcular el coeficiente de Silhouette. El procedimiento estándar consiste en:

- Realizar el agrupamiento con el algoritmo elegido (por ejemplo, K-means).
- Calcular los coeficientes de Silhouette para cada muestra y su media global.
- Visualizar los resultados para identificar la calidad de los clústeres y posibles puntos problemáticos.

Ejemplo de cálculo con K-means:

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, silhouette_samples
import numpy as np
# Supongamos que X es una matriz de datos con n muestras y d
características
kmeans = KMeans(n_clusters=3, random_state=42)
labels = kmeans.fit_predict(X)
# Coeficiente de Silhouette medio global
silhouette_avg = silhouette_score(X, labels)
# Coeficiente de Silhouette por muestra
sample_silhouette_values = silhouette_samples(X, labels)
```

La visualización mediante gráficos de Silhouette permite identificar visualmente la calidad de los clústeres y detectar muestras mal asignadas.

Ventajas y limitaciones

- Ventajas:
    - Interpretable y fácil de calcular.
    - No requiere conocimiento previo de la estructura de los datos.
    - Útil para determinar el número óptimo de clústeres.

- Limitaciones:
    - Su rendimiento disminuye en agrupamientos no esféricos o de densidad variable.
    - Sensible a la métrica de distancia seleccionada.
    - Puede ser computacionalmente costoso en grandes volúmenes de datos.

Índice de Davies-Bouldin

El índice de Davies-Bouldin (DBI) evalúa la calidad del agrupamiento estimando la relación entre la dispersión dentro de los clústeres y la distancia entre clústeres. Un valor bajo de DBI indica agrupamientos compactos y bien separados. La fórmula general es:

$$\text{DBI} = \frac{1}{k} \sum_{i=1}^{k} \max_{j \neq i} \frac{S_i + S_j}{M_{ij}}$$

donde:

- k es el número de clústeres.
- s_i es la dispersión media de los puntos en el clúster i respecto a su centroide.
- m_{ij} es la distancia entre los centroides de los clústeres i y j.

El índice busca, para cada clúster, el peor caso de superposición con los demás, y promedia esta medida sobre todos los clústeres. Un menor valor de DBI representa clústeres más compactos y mejor separados.

Interpretación práctica

- Valores bajos: Los clústeres son densos y están bien separados.
- Valores altos: Los clústeres presentan solapamientos o dispersión interna elevada.

El DBI permite comparar diferentes configuraciones de algoritmos de agrupamiento y elegir la que proporcione el valor más bajo.

Aplicación en Python con Scikit-learn

El cálculo del índice de Davies-Bouldin en Scikit-learn es inmediato utilizando la función `davies_bouldin_score`. El flujo típico consiste en:

- Ejecutar el algoritmo de agrupamiento sobre los datos.

- Obtener las etiquetas de clúster.
- Calcular el índice DBI.

Ejemplo de uso:

```
from sklearn.metrics import davies_bouldin_score
# labels: vector con la asignación de clústeres
dbi = davies_bouldin_score(X, labels)
```

El valor obtenido permite comparar diferentes valores de *ko* distintos algoritmos.

Ventajas y limitaciones

- Ventajas:
  - Proporciona una métrica cuantitativa para comparar configuraciones.
  - Es eficiente computacionalmente.
  - No requiere etiquetas verdaderas.
- Limitaciones:
  - Puede subestimar la calidad si existen clústeres de tamaño o densidad muy dispares.
  - Dificultad para interpretar el significado exacto del valor de DBI fuera de la comparación relativa entre modelos.

Comparación entre Silhouette y Davies-Bouldin

Ambas métricas se utilizan ampliamente para evaluar la calidad de los agrupamientos, pero presentan diferencias clave en su formulación y uso. La siguiente tabla resume sus principales características:

Métrica	Rango de valores	Óptimo	Requiere etiquetas	Sensible a la métrica	Idónea para…
Silhouette	[-1, 1]	Máximo	No	Sí	Evaluar calidad global/local
Davies-Bouldin (DBI)	[0, ∞)	Mínimo	No	Sí	Comparar configuraciones

El coeficiente de Silhouette facilita la evaluación individual de muestras y clústeres, mientras que el DBI ofrece una visión global resumida en un solo valor. Es recomendable utilizar ambas métricas de forma complementaria.

Otras métricas internas relevantes

Existen otras métricas de validación interna, aunque su uso es menos extendido en aplicaciones prácticas:

- Índice de Calinski-Harabasz (CH): Mide la proporción entre la dispersión interclúster y la intraclúster. Valores altos indican agrupamientos compactos y separados.
- Índice de Dunn: Relaciona la distancia mínima entre clústeres con el diámetro máximo intraclúster. Valores altos son preferibles.
- Distancia media intraclúster: Promedio de las distancias internas a cada clúster.

La elección de la métrica depende del tipo de datos, la escala, el algoritmo y los objetivos específicos del análisis.

Selección del número óptimo de clústeres

El número de clústeres (k) es un parámetro crucial. Un valor inadecuado puede conducir a agrupamientos poco significativos. Las métricas internas permiten determinar k de forma objetiva. El procedimiento habitual consiste en:

- Ejecutar el algoritmo de agrupamiento para diferentes valores de .
- Calcular la métrica de validación para cada resultado.
- Seleccionar el valor de que optimiza la métrica (máximo en Silhouette, mínimo en DBI).

Ejemplo de cálculo iterativo en Python:

```
import matplotlib.pyplot as plt
silhouette_scores = []
dbi_scores = []
range_n_clusters = range(2, 11)
for n_clusters in range_n_clusters:
    kmeans = KMeans(n_clusters=n_clusters, random_state=42)
    labels = kmeans.fit_predict(X)
    silhouette_scores.append(silhouette_score(X, labels))
    dbi_scores.append(davies_bouldin_score(X, labels))
```

```
plt.plot(range_n_clusters, silhouette_scores, label='Silhouette')
plt.plot(range_n_clusters, dbi_scores, label='Davies-Bouldin')
plt.xlabel('Número de clústeres')
plt.legend()
plt.show()
```

El análisis visual de estos resultados permite identificar el punto óptimo.

Micro-caso aplicado: *Una empresa de telecomunicaciones busca segmentar a sus clientes para personalizar campañas de marketing. Utiliza K-means sobre un conjunto de características de consumo. Calcula el coeficiente de Silhouette y el índice de Davies–Bouldin para diferentes valores de k. Selecciona k=4 porque obtiene un Silhouette medio de 0.54 (indicando buena separación) y un DBI de 0.45 (indicando compactación y baja superposición). Así, ajusta sus campañas para cada segmento identificado, logrando una mejora medible en la respuesta de los clientes.*
Consideraciones prácticas en el uso de métricas internas

Al emplear métricas internas es fundamental tener en cuenta:

- Preprocesamiento: La escala y la normalización de los datos afectan las distancias y, por tanto, los valores de las métricas.
- Tipo de distancia: La elección de la métrica de distancia (Euclídea, Manhattan, etc.) impacta directamente en la evaluación de cohesión y separación.
- Forma de los clústeres: Algoritmos como K-means asumen clústeres esféricos; métricas como Silhouette se ajustan mejor a estos supuestos.
- Tamaño de los datos: En grandes volúmenes, el cálculo exhaustivo puede ser costoso. Es recomendable usar muestras representativas o técnicas de reducción de dimensionalidad.

En la práctica, es habitual combinar varias métricas y análisis visuales (como el gráfico de Silhouette) para validar los resultados, evitando depender de una única medida.

Métricas externas (breve referencia)

Cuando existen etiquetas verdaderas, las métricas externas como el índice de Rand ajustado, la homogeneidad o la completitud permiten comparar la asignación de clústeres con la verdad conocida. Sin embargo, en la mayoría de los escenarios reales de aprendizaje no supervisado, solo se dispone de métricas internas.

Ejemplo avanzado: segmentación de clientes y validación

Supóngase un conjunto de datos con diferentes variables de consumo y demográficas. El procedimiento estándar para evaluar la segmentación es:

- Preprocesar y escalar los datos.
- Ejecutar K-means para varios valores de .
- Calcular Silhouette y Davies-Bouldin para cada .
- Analizar visualmente los clústeres mediante reducción de dimensionalidad (PCA, t-SNE).
- Seleccionar óptimo según las métricas y la interpretación del negocio.Código de ejemplo:

```
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
# Escalado
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# Reducción de dimensionalidad para visualización
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
# Agrupamiento y métricas
kmeans = KMeans(n_clusters=4, random_state=42)
labels = kmeans.fit_predict(X_scaled)
silhouette_avg = silhouette_score(X_scaled, labels)
dbi = davies_bouldin_score(X_scaled, labels)
# Visualización
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=labels, cmap='viridis')
plt.title(f'Silhouette: {silhouette_avg:.2f}, DBI: {dbi:.2f}')
plt.show()
```

La interpretación conjunta de métricas y visualización asegura que los grupos identificados sean coherentes y útiles para la toma de decisiones.

Métricas y algoritmos alternativos

Distintos algoritmos de agrupamiento pueden requerir métricas de validación específicas. Por ejemplo:

- DBSCAN: Útil para clústeres de densidad variable; la métrica de Silhouette puede ser menos informativa si existen muchos puntos frontera.
- Agglomerative Clustering: Admite diferentes métricas de distancia; la interpretación de Silhouette sigue siendo válida.
- Spectral Clustering: Requiere analizar la estructura de los datos después de la transformación espectral.

La elección de la métrica interna adecuada debe considerar las características del algoritmo y la estructura esperada de los datos.

Implementación eficiente en grandes conjuntos de datos

El cálculo de métricas como Silhouette puede volverse prohibitivo en conjuntos de datos de gran tamaño, ya que implica el cálculo de distancias entre todas las muestras. Algunas recomendaciones para abordar este desafío incluyen:

- Utilizar una muestra aleatoria representativa para calcular las métricas.
- Emplear técnicas de reducción de dimensionalidad antes del agrupamiento y la validación.
- Aprovechar implementaciones optimizadas y procesamiento paralelo disponibles en bibliotecas como Scikit-learn.

Ejemplo de cálculo en una muestra aleatoria:

```
from sklearn.utils import resample
# Selección de una muestra aleatoria
X_sample = resample(X, n_samples=1000, random_state=42)
labels_sample = kmeans.predict(X_sample)
silhouette_avg_sample = silhouette_score(X_sample, labels_sample)
```

Esta aproximación permite obtener una estimación fiable de la calidad del agrupamiento sin incurrir en costes computacionales elevados.

Resumen de buenas prácticas

Para garantizar la validez de los modelos de agrupamiento y su utilidad práctica:

- Normalizar y escalar los datos antes de aplicar algoritmos y métricas.
- Evaluar diferentes valores de y comparar mediante varias métricas.
- Interpretar conjuntamente los resultados métricos y visuales.

- Considerar la naturaleza de los datos y el objetivo de segmentación.
- Documentar las decisiones tomadas y los valores de las métricas obtenidas.

El dominio de las métricas de validación interna y la capacidad de aplicarlas con herramientas como Python y Scikit-learn permiten desarrollar modelos de aprendizaje no supervisado robustos, comparables y alineados con las necesidades reales de negocio.

¿Sabías que...?

El coeficiente de Silhouette fue propuesto por Peter J. Rousseeuw en 1987 y, desde entonces, se ha consolidado como uno de los indicadores más utilizados para validar agrupamientos en análisis de datos, permitiendo una interpretación visual directa de la calidad de cada clúster y facilitando la toma de decisiones en aplicaciones empresariales y científicas.

3.3. Clustering

El clustering constituye una técnica esencial en el aprendizaje no supervisado, destinada a identificar y agrupar observaciones similares dentro de un conjunto de datos sin etiquetas predefinidas. El objetivo principal consiste en maximizar la similitud interna de los grupos (clusters) y, al mismo tiempo, potenciar la disimilitud entre grupos distintos. Esta aproximación resulta fundamental para tareas como la segmentación de clientes, la agrupación de imágenes, la detección de patrones de comportamiento y la reducción de dimensionalidad, permitiendo descubrir estructuras subyacentes que serían difíciles de detectar manualmente.

Fundamentos y objetivos del clustering

El clustering explora la estructura interna de los datos, relacionando instancias de acuerdo a su proximidad en el espacio de características. La definición de "proximidad" depende de la métrica utilizada, siendo la distancia euclídea la más habitual en espacios numéricos, aunque otras métricas (como Manhattan, Mahalanobis o distancias de coseno) pueden ser más apropiadas según el problema.

Los algoritmos de clustering buscan construir particiones de los datos tales que:

- Los elementos dentro de un mismo cluster presentan alta similitud.
- Los elementos de diferentes clusters presentan baja similitud.

- Cada elemento pertenece a un único cluster (particionamiento estricto), aunque existen variantes difusas donde un elemento puede pertenecer parcialmente a varios clusters.

Las aplicaciones prácticas del clustering incluyen:

- Segmentación de clientes en marketing, para personalizar campañas.
- Agrupación de documentos o imágenes por similitud semántica o visual.
- Detección de anomalías, donde los outliers pueden formar clusters propios o quedar fuera de los grupos principales.
- Preprocesamiento para reducción de la dimensionalidad o generación de variables sintéticas.

Algoritmos principales: K-means y DBSCAN

Dos de los algoritmos más empleados en clustering son K-means y DBSCAN. Ambos presentan enfoques y propiedades distintas, adecuados a diferentes problemáticas y estructuras de datos.

K-means

K-means es un algoritmo de particionamiento iterativo que busca dividir un conjunto de n observaciones en k clusters, minimizando la suma de las distancias cuadráticas de cada punto a su centroide. Su funcionamiento básico se describe en los siguientes pasos:

- Inicialización: Seleccionar aleatoriamente k centroides iniciales.
- Asignación: Asignar cada punto de datos al centroide más cercano, formando k grupos.
- Actualización: Recalcular el centroide de cada grupo como la media aritmética de sus puntos asignados.
- Repetición: Iterar los pasos de asignación y actualización hasta que los centroides no cambien significativamente o se alcance un número máximo de iteraciones.

K-means requiere definir previamente el número de clusters k, lo que puede suponer una limitación cuando la estructura de los datos es desconocida. La sensibilidad a la inicialización y la tendencia a encontrar soluciones locales también son aspectos relevantes.

Ventajas de K-means

- Simplicidad y eficiencia computacional, especialmente en grandes conjuntos de datos.
- Fácil interpretación de los resultados.
- Escalabilidad con respecto al número de muestras y dimensiones.

Limitaciones:

- Requiere especificar k a priori.
- Sensibilidad a la inicialización de los centroides.
- Dificultades con clusters de forma no esférica, distribución desigual o densidad variable.
- Poca tolerancia a outliers y ruido.

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN es un algoritmo basado en densidad que agrupa puntos densamente conectados y considera como ruido aquellos que no pertenecen a ninguna región densa. No requiere definir el número de clusters de antemano y resulta especialmente eficaz para descubrir clusters de forma arbitraria y con densidades variables.

El procedimiento de DBSCAN se resume en:

- Definir dos parámetros clave:
  - (eps): Radio de vecindad para determinar la proximidad.
  - min_samples: Número mínimo de puntos para considerar una región como densa (núcleo de un cluster).
- Clasificar los puntos en:
  - Núcleo: Tiene al menos min_samples puntos en su vecindad .
  - Borde: Está dentro de la vecindad de un núcleo, pero no es núcleo.
  - Ruido: No es núcleo ni borde.
  - Expandir clusters a partir de puntos núcleo, conectando puntos densa y transitivamente alcanzables.

Ventajas de DBSCAN:

- No requiere especificar el número de clusters.
- Identifica outliers de manera natural.
- Maneja clusters de forma y tamaño arbitrarios.
- Robusto ante ruido.

Limitaciones:

- Sensibilidad a la elección de y min_samples.
- Menor rendimiento en datos con densidades muy variables.
- Requiere una definición adecuada de la métrica de distancia.

Métricas de similitud y distancia

La elección de una métrica de distancia adecuada es determinante para el éxito del clustering:

- Distancia Euclídea: Apropiada para variables numéricas y escalares.
- Distancia de Manhattan: Útil cuando las diferencias absolutas son más relevantes que las cuadráticas.
- Distancia de Coseno: Recomendada para datos de alta dimensionalidad o vectores de texto.
- Distancia de Mahalanobis: Considera la correlación entre variables.

La normalización o estandarización previa de los datos suele ser necesaria, especialmente para K-means, para evitar la dominancia de variables con mayor rango.

Evaluación de la calidad de los agrupamientos

La validación del resultado del clustering requiere métricas objetivas, ya que no existen etiquetas de referencia. Las principales métricas internas incluyen:

- Inercia (para K-means): Suma de las distancias cuadráticas internas a los centroides. Menor inercia indica clusters más compactos.
- Coeficiente de Silueta: Evalúa la separación y cohesión de los clusters. Valores cercanos a 1 indican clusters bien definidos.

- Davies-Bouldin Index: Promedio de la relación entre la dispersión intra-cluster y la distancia inter-cluster. Valores bajos son mejores.

En aplicaciones prácticas, la interpretación visual también resulta útil, especialmente en problemas de baja dimensionalidad. Los métodos de reducción de dimensionalidad, como PCA o t-SNE, pueden facilitar la visualización de los clusters.

Implementación de clustering en Python

El ecosistema Python ofrece herramientas robustas para el desarrollo de modelos de clustering, destacando la biblioteca scikit-learn por su facilidad de uso y flexibilidad.

Preparación de los datos

Antes de aplicar un algoritmo de clustering, es fundamental llevar a cabo tareas de preprocesamiento:

- Limpieza de datos: Eliminar o imputar valores nulos.
- Normalización o estandarización de variables.
- Selección de características relevantes.
- Reducción de dimensionalidad si es necesario.

Un ejemplo de normalización usando StandardScaler:

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Aplicación de K-means

La implementación básica de K-means en scikit-learn sigue los pasos:

```
from sklearn.cluster import KMeans
kmeans = KMeans(n_clusters=3, random_state=42)
labels = kmeans.fit_predict(X_scaled)
centroids = kmeans.cluster_centers_
inertia = kmeans.inertia_
```

Es común utilizar el método del codo (elbow method) para determinar el número óptimo de clusters. Este método grafica la inercia en función de k, observando el punto donde la mejora se estabiliza.

```
import matplotlib.pyplot as plt
inertia_vals = []
for k in range(1, 10):
    km = KMeans(n_clusters=k, random_state=42)
    km.fit(X_scaled)
    inertia_vals.append(km.inertia_)
plt.plot(range(1, 10), inertia_vals, marker='o')
plt.xlabel('Número de clusters (k)')
plt.ylabel('Inercia')
plt.show()
```

Una vez ajustado el modelo, se puede visualizar la asignación de clusters (en problemas bidimensionales):

```
plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=labels, cmap='viridis')
plt.scatter(centroids[:, 0], centroids[:, 1], c='red', marker='X', s=200)
plt.title('K-means clustering')
plt.show()
```

Aplicación de DBSCAN

La implementación de DBSCAN requiere ajustar los parámetros ε y min_samples, lo cual puede hacerse mediante análisis gráfico (k-distance plot) o heurísticas.

```
from sklearn.cluster import DBSCAN
dbscan = DBSCAN(eps=0.5, min_samples=5)
labels = dbscan.fit_predict(X_scaled)
```

Los puntos rotulados como -1 corresponden a ruido (outliers no agrupados). La visualización puede seguir el mismo esquema:

```
plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=labels, cmap='plasma')
plt.title('DBSCAN clustering')
plt.show()
```

La elección adecuada de ε puede lograrse graficando la distancia al k-ésimo vecino más cercano para todos los puntos y localizando el "codo" en la curva.

Evaluación de los resultados

El coeficiente de silueta permite comparar la calidad de los clusters generados por distintos algoritmos o configuraciones:

```
from sklearn.metrics import silhouette_score
sil_score = silhouette_score(X_scaled, labels)
print("Coeficiente de silueta:", sil_score)
```

Valores superiores a 0.5 suelen indicar una estructura de clusters razonablemente definida.

Ajuste de parámetros y buenas prácticas

El rendimiento de los algoritmos de clustering depende en gran medida del ajuste de sus hiperparámetros. Para K-means, la elección de k es crucial; para DBSCAN, la selección de ε y min_samples determina la sensibilidad al ruido y la estructura de los clusters.

Buenas prácticas:

- Utilizar técnicas de visualización para explorar la estructura de los datos antes de ajustar los parámetros.
- Probar diferentes métricas de distancia si las variables presentan escala o naturaleza heterogénea.
- Validar la estabilidad de los agrupamientos repitiendo los experimentos con diferentes inicializaciones o subconjuntos de datos.
- Documentar la interpretación de los clusters en términos de variables originales para facilitar la toma de decisiones.

Micro-caso aplicado: Una empresa de comercio electrónico busca segmentar a sus usuarios para personalizar campañas de marketing. Utilizando K-means sobre variables de comportamiento (frecuencia de compra, importe promedio, tipos de productos), identifica tres grupos principales: compradores ocasionales, compradores frecuentes de bajo importe y grandes compradores. Al visualizar los clusters, el equipo de marketing ajusta las promociones dirigidas a cada segmento, incrementando la tasa de conversión y mejorando la experiencia del usuario.

Consideraciones para clustering en datos complejos

En conjuntos de datos de alta dimensionalidad, la "maldición de la dimensionalidad" puede dificultar la identificación de clusters. En tales casos, la reducción de dimensionalidad mediante PCA o técnicas no lineales como t-SNE o UMAP puede mejorar la visualización y la eficacia del clustering.

Para datos categóricos, variantes específicas de clustering, como K-modes o clustering jerárquico, pueden ser más apropiadas. Además, en contextos donde los clusters se solapan o existen relaciones complejas, se recomiendan métodos

difusos (fuzzy clustering) o modelos probabilísticos como Gaussian Mixture Models (GMM).

El clustering jerárquico, no abordado en detalle aquí, permite crear dendrogramas que reflejan relaciones multinivel entre instancias, facilitando la exploración de estructuras de agrupamiento a diferentes escalas.

Interpretación y uso de los clusters

La interpretación de los clusters es crítica para su aplicación práctica. Se recomienda:

- Analizar la media y desviación estándar de las variables dentro de cada cluster.
- Identificar variables que diferencian claramente los clusters.
- Validar los agrupamientos con expertos de dominio o mediante el análisis de resultados de negocio (por ejemplo, incremento en ventas o retención de clientes tras la aplicación de estrategias segmentadas).

La asignación de etiquetas descriptivas a los clusters facilita la comunicación con equipos no técnicos y contribuye a la adopción de soluciones basadas en clustering.

Resumen de ventajas y limitaciones de los principales métodos

Método	Ventajas principales	Limitaciones clave
K-means	Rápido, simple, eficiente en grandes datos	Requiere k, sensible a outliers, forma esférica
DBSCAN	Descubre formas arbitrarias, detecta outliers	Sensible a parámetros, menor escalabilidad
GMM	Modela clusters elípticos, probabilístico	Mayor coste computacional, requiere k
Jerárquico	No requiere k, visualización multinivel	Escalabilidad limitada, sensible a ruido

Herramientas y bibliotecas adicionales

Además de scikit-learn, existen otras bibliotecas útiles:

- SciPy: Implementa clustering jerárquico y métricas de distancia avanzadas.
- HDBSCAN: Versión mejorada de DBSCAN para clusters de densidad variable.
- Yellowbrick: Ofrece visualizaciones específicas para clustering, como el diagrama de silueta.

Seguridad y ética en clustering

La segmentación automática puede tener implicaciones éticas, especialmente cuando afecta a la toma de decisiones sobre personas (por ejemplo, segmentación en créditos o seguros). Es necesario evaluar el impacto potencial de los agrupamientos y asegurar la protección de datos sensibles. Se recomienda anonimizar los datos y evitar decisiones automáticas sin validación humana.

Integración en flujos de Machine Learning

El clustering puede servir como etapa previa a modelos supervisados, por ejemplo, generando variables adicionales (features) basadas en la pertenencia a clusters. Asimismo, la detección de outliers mediante clustering contribuye a mejorar la calidad de los datos para modelos posteriores. La incorporación de clustering en flujos automáticos requiere monitorizar periódicamente la validez de los clusters, ya que la estructura de los datos puede variar con el tiempo (drift).

Resumen de pasos operativos para un pipeline de clustering

- Preprocesar y normalizar los datos.
- Seleccionar y ajustar el algoritmo adecuado (K-means, DBSCAN, etc.).
- Determinar los hiperparámetros óptimos mediante análisis gráfico y métricas internas.
- Aplicar el algoritmo y obtener las etiquetas de cluster.
- Evaluar la calidad de los agrupamientos.
- Interpretar los clusters y validar su utilidad práctica.
- Integrar los resultados en procesos de negocio o posteriores etapas de análisis.

Toma nota

El clustering permite identificar patrones y subgrupos en datos sin etiquetas, facilitando la toma de decisiones basada en la estructura inherente del conjunto de datos; su eficacia depende de la correcta elección del algoritmo, el ajuste de parámetros y la interpretación experta de los resultados.

3.4. Biclustering

La biclustering constituye una estrategia avanzada de aprendizaje no supervisado que identifica simultáneamente subgrupos de filas y columnas en matrices de datos, revelando patrones locales y asociaciones entre subconjuntos de variables y muestras. A diferencia del clustering tradicional, que agrupa únicamente en una dimensión, el biclustering explora correlaciones ocultas en dos dimensiones, lo que resulta esencial para analizar conjuntos de datos complejos, especialmente aquellos con estructuras heterogéneas o efectos de confusión localizados.

El biclustering surge en contextos donde los patrones de interés afectan solo partes del conjunto de datos. Por ejemplo, en matrices de expresión génica, determinados genes pueden mostrar comportamientos similares únicamente bajo condiciones específicas. De igual modo, en análisis de mercado, un segmento de consumidores puede compartir intereses solo respecto a ciertos productos. El biclustering permite descomponer la matriz original en bloques coherentes, facilitando la interpretación y toma de decisiones basada en subestructuras relevantes.

Fundamentos teóricos del biclustering

Formalmente, se considera una matriz de datos $A \in R^{mxn}$, donde mrepresenta el número de filas (por ejemplo, genes o clientes) y nel número de columnas (condiciones experimentales o productos). El objetivo es encontrar subconjuntos de filas $I \subseteq \{1,\ldots,m\}$y columnas $J \subseteq \{1,\ldots,n\}$tales que los elementos a_ij, con $i \in I$y $j \in J$, exhiban patrones de interés, como coexpresión, correlación, o varianza baja.

A diferencia del clustering tradicional, donde cada elemento pertenece a un único grupo, el biclustering permite solapamiento: una fila o columna puede formar parte de múltiples biclusters, reflejando la complejidad inherente de muchos conjuntos de datos reales.

Las propiedades que caracterizan un bicluster pueden incluir:

- Coherencia aditiva: las diferencias entre los valores dentro del bicluster son aproximadamente constantes.
- Coherencia multiplicativa: los valores en el bicluster difieren por un factor común.
- Varianza baja: los valores son similares entre sí.
- Correlación de patrones: las filas o columnas siguen un perfil común a lo largo de la otra dimensión.

Estas propiedades definen diferentes objetivos y métricas de calidad para los algoritmos de biclustering.

Diferencias entre clustering y biclustering

La siguiente tabla resume las principales diferencias operativas entre clustering tradicional y biclustering:

Característica	Clustering tradicional	Biclustering
Dimensión de agrupación	Una (filas o columnas)	Dos (filas y columnas)
Solapamiento	Generalmente no	Sí, frecuente
Patrones descubiertos	Globales	Locales (submatrices)
Aplicación típica	Segmentación, clasificación	Descubrimiento de bloques
Ejemplo	Agrupar clientes	Subgrupos de clientes/ productos

El biclustering permite detectar patrones que afectan solo a subconjuntos de muestras y variables, lo que resulta indispensable en análisis donde existen interacciones complejas y no homogéneas.

Algoritmos de biclustering

Se han desarrollado múltiples algoritmos de biclustering, cada uno optimizado para identificar tipos específicos de patrones. Los dos enfoques más representativos y utilizados en la práctica son:

- Biclustering K-means extendido
- Cheng & Church

Biclustering K-means extendido

El algoritmo K-means tradicional agrupa objetos en base a la minimización de la suma de distancias cuadráticas respecto al centroide del grupo. Su extensión al biclustering consiste en identificar simultáneamente grupos de filas y columnas cuyas combinaciones presentan similitud interna. Existen varias formulaciones,

una de las cuales implica iterativamente asignar filas y columnas a biclusters, redefiniendo centroides para maximizar la homogeneidad dentro de cada submatriz.

Los pasos generales de un algoritmo de biclustering K-means son:

- Inicializar un número predeterminado de biclusters, seleccionando subconjuntos aleatorios de filas y columnas.
- Asignar filas y columnas a los biclusters en función de la distancia (por ejemplo, euclídea) respecto al centroide bicluster.
- Actualizar los centroides de cada bicluster según los miembros actuales.
- Repetir asignación y actualización hasta convergencia o alcanzado un número máximo de iteraciones.

La complejidad computacional aumenta respecto al K-means tradicional, ya que la asignación y actualización involucran dos dimensiones y potencial solapamiento.

Algoritmo de Cheng & Church

El método de Cheng & Church (2000) se orienta a matrices donde los patrones de interés se pueden caracterizar por una varianza baja. Introduce la métrica de "mean squared residue" (residuo cuadrático medio, MSR) para cuantificar la coherencia de un submatriz. Un bicluster se define como un conjunto de filas y columnas donde el MSR es inferior a un umbral predefinido. El procedimiento general es:

- Identificar un subconjunto inicial de filas y columnas.
- Calcular el MSR del submatriz.
- Eliminar iterativamente filas o columnas que contribuyen a un aumento del MSR.
- Añadir nuevas filas o columnas que reduzcan el MSR.
- Repetir hasta alcanzar el umbral de coherencia deseado o un número máximo de iteraciones.
- Opcionalmente, enmascarar el bicluster encontrado en la matriz original y repetir el proceso para encontrar múltiples biclusters.

El MSR para una submatriz A_{IJ} se define como:

$$\mathrm{MSR}\left(I, J\right) = \frac{1}{|I||J|} \sum_{i \in I, j \in J} \left(a_{ij} - a_{iJ} - a_{Ij} + a_{IJ}\right)^2$$

- a_{ij}: Elemento en la fila i y columna j.

- a_{iJ}: Promedio de la fila i en las columnas de J.

- a_{Ij}: Promedio de la columna j en las filas de I.

- a_{IJ}: Promedio global de la submatriz A_{IJ}.

Este algoritmo es robusto frente a ruido y permite encontrar múltiples biclusters no necesariamente disjuntos.

Implementación de biclustering en Python

Las bibliotecas scikit-learn y NumPy facilitan la implementación práctica de biclustering. Scikit-learn incluye módulos específicos, como `SpectralBiclustering` y `SpectralCoclustering`, que aplican técnicas basadas en descomposición espectral para detectar estructuras en matrices. Aunque la biblioteca no proporciona implementaciones directas del algoritmo Cheng & Church, existen implementaciones comunitarias y es posible desarrollarlas utilizando herramientas básicas de manipulación matricial.

Configuración inicial

Para trabajar con biclustering en Python, se recomienda preparar el entorno con las siguientes bibliotecas:

```
import numpy as np
from sklearn.datasets import make_biclusters
from sklearn.cluster import SpectralBiclustering
from sklearn.preprocessing import scale
import matplotlib.pyplot as plt
```

Ejemplo básico con SpectralBiclustering

El módulo `SpectralBiclustering` implementa un enfoque basado en la descomposición de la matriz de datos en componentes ortogonales, apto para descubrir bloques con patrones similares. A continuación se muestra un procedimiento típico:

```
# Generar datos sintéticos con estructura biclusterizada
data, rows, columns = make_biclusters(
    shape=(300, 300), n_clusters=5, noise=5, shuffle=False, random_
state=0
)
```

```
data = scale(data, axis=1)
# Instanciar el modelo
model = SpectralBiclustering(n_clusters=5, method='log', random_state=0)
model.fit(data)
# Recuperar los biclusters detectados
row_labels = model.row_labels_
column_labels = model.column_labels_
# Visualizar el resultado
plt.matshow(data[np.argsort(row_labels)][:, np.argsort(column_labels)],
cmap=plt.cm.Blues)
plt.title("Biclustering: Matriz ordenada por biclusters")
plt.show()
```

Este procedimiento genera una matriz de datos artificial con cinco biclusters y aplica el algoritmo espectral. La visualización ordena la matriz para resaltar los bloques detectados.

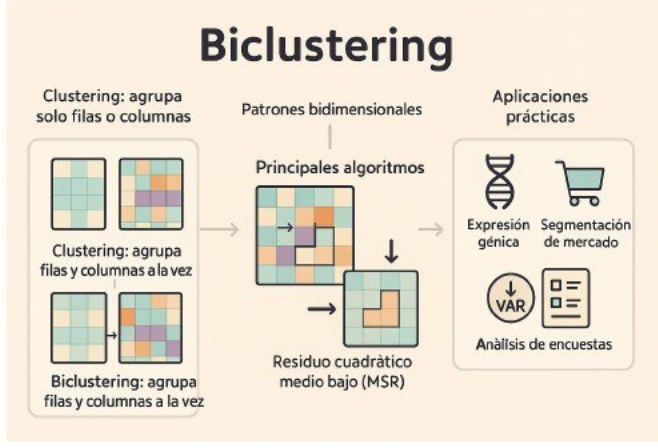

Implementación básica del algoritmo Cheng & Church

Aunque scikit-learn no incluye el método Cheng & Church, puede implementarse un prototipo simple utilizando NumPy. El siguiente es un esquema conceptual para un solo bicluster:

```
import numpy as np
def mean_squared_residue(submatrix):
    row_means = submatrix.mean(axis=1, keepdims=True)
```

```
    col_means = submatrix.mean(axis=0, keepdims=True)
    total_mean = submatrix.mean()
    residue = submatrix - row_means - col_means + total_mean
    msr = np.mean(residue  2)
    return msr
def cheng_church(matrix, msr_threshold, min_rows, min_cols, max_
iterations=100):
    rows = list(range(matrix.shape[0]))
    cols = list(range(matrix.shape[1]))
    for _ in range(max_iterations):
submatrix = matrix[np.ix_(rows, cols)]
msr = mean_squared_residue(submatrix)
if msr <= msr_threshold and len(rows) >= min_rows and len(cols) >= min_cols:
    break
# Eliminar la fila con mayor residuo si es necesario
row_residues = ((submatrix - submatrix.mean(axis=1, keepdims=True))2).
mean(axis=1)
if row_residues.max() > msr_threshold:
    rows.pop(np.argmax(row_residues))
# Eliminar la columna con mayor residuo si es necesario
col_residues = ((submatrix - submatrix.mean(axis=0, keepdims=True))2).
mean(axis=0)
if col_residues.max() > msr_threshold:
    cols.pop(np.argmax(col_residues))
    return rows, cols
```

Esta función selecciona filas y columnas que cumplen con el umbral de MSR, eliminando iterativamente aquellas que deterioran la coherencia del bicluster. Para extraer todos los biclusters de una matriz, se repite el proceso en las regiones no cubiertas (enmascaramiento).

Evaluación de la calidad de los biclusters

La validación de biclusters implica medir tanto la coherencia interna como la relevancia externa respecto a la matriz original y a los objetivos de análisis.

Algunas métricas clave incluyen:

- Residuo cuadrático medio (MSR): cuantifica la varianza interna del bicluster.

- Tamaño del bicluster: filas y columnas incluidas deben ser suficientes para resultar interpretables.
- Solapamiento: evaluar si el solapamiento entre biclusters aporta o complica la interpretación.
- Enriquecimiento funcional: en biología, se analiza si los genes agrupados comparten funciones o rutas conocidas.
- Estabilidad: reproducibilidad del biclustering ante pequeñas perturbaciones de los datos.

La selección de parámetros (por ejemplo, número de biclusters, umbral de MSR) se ajusta mediante validación cruzada, análisis de la matriz de residuos y, en contextos aplicados, juicio experto sobre la utilidad práctica de los bloques detectados.

Aplicaciones prácticas del biclustering

El biclustering resulta especialmente útil en dominios donde los patrones relevantes afectan solo fracciones del conjunto de datos y se requiere interpretar relaciones locales. Entre sus principales aplicaciones destacan:

- Análisis de expresión génica: identificación de grupos de genes coexpresados bajo subconjuntos de condiciones experimentales. Esto permite descubrir módulos funcionales, inferir rutas biológicas y priorizar candidatos para estudios adicionales.
- Minería de datos de mercado: segmentación simultánea de clientes y productos, revelando grupos de consumidores con preferencias sobre subconjuntos específicos de la oferta.
- Análisis de encuestas: agrupación de participantes y preguntas con patrones de respuesta similares, útil para detectar tendencias o segmentos no evidentes.
- Recomendadores: descomposición de matrices de usuario-producto para identificar nichos de mercado y personalizar recomendaciones.
- Imágenes y visión artificial: segmentación de regiones en imágenes a partir de patrones locales, útil en diagnóstico médico y análisis automatizado.

Micro-caso aplicado: En un laboratorio de biología molecular, los investigadores analizan una matriz de expresión génica derivada de microarrays. El biclustering revela que un subconjunto de genes muestra coexpresión únicamente en muestras sometidas a estrés oxidativo. Este patrón local permite identificar una posible ruta de respuesta específica a ese estímulo, guiando experimentos posteriores y el diseño de terapias dirigidas.

Consideraciones prácticas y mejores prácticas

Al aplicar biclustering en la práctica, se recomienda:

- Preprocesar los datos: normalizar, escalar y filtrar valores atípicos para mejorar la calidad de los biclusters detectados.
- Explorar diferentes algoritmos y parámetros: cada algoritmo puede descubrir tipos de patrones distintos, por lo que conviene comparar resultados.
- Visualizar los resultados: ordenar filas y columnas según la pertenencia a biclusters facilita la interpretación y la presentación a usuarios finales.
- Evaluar la robustez: repetir análisis sobre subconjuntos de datos o tras perturbaciones para asegurar estabilidad.
- Documentar las decisiones: registrar criterios de selección de parámetros, métricas utilizadas y hallazgos relevantes para garantizar reproducibilidad.

Las limitaciones principales del biclustering incluyen su mayor complejidad computacional respecto al clustering tradicional y la dificultad para interpretar muchos biclusters solapados o de tamaño reducido. La interpretación asistida por expertos y el uso de métricas objetivas contribuyen a superar estos retos.

Comparativa de algoritmos de biclustering

La selección del algoritmo depende de la naturaleza de los datos y los objetivos analíticos. La siguiente tabla sintetiza las principales características de los métodos presentados:

Algoritmo	Tipo de patrón detectado	Solapamiento	Robustez al ruido	Implementación en scikit-learn	Ventajas principales	Limitaciones
K-means extendido	Homogeneidad local	Parcial	Moderada	Indirecta (requiere adaptación)	Intuitivo, rápido para matrices pequeñas	Menor capacidad para patrones complejos
Cheng & Church	Varianza baja, coherencia	Sí	Alta	No (requiere implementación)	Preciso para bloques coherentes	Sensible a selección de umbral

Algoritmo	Tipo de patrón detectado	Solapamiento	Robustez al ruido	Implementación en scikit-learn	Ventajas principales	Limitaciones
Spectral Biclustering	Bloques estructurales	Variable	Alta	Sí (directo)	Eficiente, apto para matrices grandes	Puede requerir preprocesamiento

La elección del algoritmo óptimo requiere equilibrar precisión, interpretabilidad, eficiencia y compatibilidad con los objetivos del análisis.

Interpretación y visualización de biclusters

La interpretación de los biclusters demanda técnicas de visualización y análisis complementario. Entre las estrategias más efectivas se encuentran:

- Reordenar la matriz de datos según la pertenencia a biclusters, resaltando visualmente los bloques detectados.
- Mapas de calor con codificación por color, útiles para identificar patrones de coexpresión o preferencias locales.
- Análisis de enriquecimiento: en ámbitos biológicos, comparar los genes incluidos con bases de datos funcionales.
- Resumen estadístico: calcular medias, varianzas y otros estadísticos dentro de cada bicluster para caracterizar su naturaleza.

El uso combinado de visualización y análisis cuantitativo facilita la comunicación de hallazgos y la toma de decisiones basada en los bloques identificados.

Limitaciones y desafíos actuales

El biclustering, si bien potente, enfrenta desafíos en escenarios reales:

- Escalabilidad: el procesamiento de matrices muy grandes puede ser costoso en tiempo y memoria; algoritmos aproximados o distribuidos contribuyen a mitigar este problema.
- Detección de patrones ruidosos o solapados: la proliferación de biclusters pequeños o altamente solapados puede dificultar la interpretación.
- Selección de parámetros óptimos: umbrales y número de biclusters influyen decisivamente en la calidad y relevancia de los resultados.

- Validación externa: la ausencia de "ground truth" en problemas reales exige combinar métricas internas con evaluación experta.

El desarrollo de algoritmos adaptativos, la integración con técnicas de reducción de dimensionalidad y la incorporación de información a priori representan líneas activas de investigación para superar estas limitaciones.

Integración del biclustering en el flujo de análisis de datos

El biclustering se integra en el flujo de análisis de datos como una herramienta de descubrimiento exploratorio y segmentación avanzada. Tras la limpieza y preprocesamiento de los datos, el biclustering permite detectar estructuras locales no evidentes, que pueden servir de base para análisis posteriores, generación de hipótesis y personalización de estrategias en diversos dominios.

El valor añadido del biclustering reside en su capacidad para adaptar el análisis a la heterogeneidad de los datos, evitando generalizaciones excesivas y abriendo oportunidades para la identificación de relaciones singulares con alto potencial interpretativo.

Recuerda

El biclustering aporta una visión granular y bidimensional de los datos, permitiendo descubrir bloques de relaciones relevantes entre subconjuntos de filas y columnas que el clustering tradicional no revela. La implementación práctica en Python, apoyada en scikit-learn y NumPy, facilita su adopción en proyectos de análisis avanzado, destacando especialmente en aplicaciones biológicas y comerciales donde la identificación de patrones locales es crucial para la toma de decisiones.

3.5. Manifolds

Los manifolds constituyen una pieza central en el análisis de datos de alta dimensión, especialmente en el aprendizaje no supervisado. En la práctica, la mayoría de los conjuntos de datos complejos—imágenes, señales biomédicas, textos vectorizados—poseen una estructura intrínseca de menor dimensión que la del espacio en el que se representan originalmente. Esta estructura subyacente suele corresponder a un manifold, es decir, una variedad matemática que localmente se comporta como un espacio euclídeo de menor dimensión. El reconocimiento y la explotación de manifolds permiten reducir la complejidad de los datos, facilitar su visualización y mejorar la capacidad de los algoritmos para encontrar patrones relevantes.

Fundamentos teóricos de manifolds

En términos matemáticos, un manifold es un conjunto que, en una vecindad suficientemente pequeña alrededor de cada punto, se comporta como un espacio vectorial euclídeo de dimensión menor. Así, aunque los datos estén embebidos en un espacio de alta dimensión

La mayoría de los datos en R^N suelen concentrarse cerca de una subvariedad de menor dimensión D (D < N).

La hipótesis del manifold sostiene que, en muchos problemas de machine learning, los datos relevantes residen en un manifold de baja dimensión inmerso en un espacio de mayor dimensión. Esta suposición es fundamental, ya que permite aplicar técnicas de reducción de dimensionalidad que preservan las relaciones estructurales importantes de los datos, eliminando redundancias y ruido.

Motivación práctica para la reducción de dimensionalidad

Trabajar con datos de alta dimensión conlleva varios problemas:

- Curse of dimensionality: A medida que aumenta la dimensionalidad, el volumen del espacio crece exponencialmente, diluyendo la densidad de los datos y dificultando la generalización de los modelos.
- Costo computacional: Procesar y almacenar datos en espacios de alta dimensión demanda recursos computacionales significativos.
- Visualización: La interpretación y el análisis exploratorio de los datos resultan inviables más allá de tres dimensiones.

Las técnicas de reducción de dimensionalidad buscan proyectar los datos sobre una representación más compacta, conservando la mayor cantidad posible de información relevante sobre su estructura.

Técnicas clásicas y modernas para la identificación de manifolds

Las técnicas para identificar y explotar manifolds se dividen en dos grandes categorías:

- Lineales: Suponen que el manifold es plano o puede aproximarse bien por un subespacio lineal. Ejemplo: Análisis de Componentes Principales (PCA).
- No lineales: Permiten capturar manifolds curvos o con geometrías complejas. Ejemplo: t-Distributed Stochastic Neighbor Embedding (t-SNE).

Comparativa entre técnicas de reducción de dimensionalidad

Técnica	Tipo	Preserva relaciones globales	Preserva relaciones locales	Escalabilidad	Interpretabilidad	Complejidad computacional
PCA	Lineal	Sí	Parcialmente	Alta	Alta	Baja
t-SNE	No lineal	No	Sí	Media	Baja	Alta
Isomap	No lineal	Sí	Sí	Media	Media	Media
LLE	No lineal	No	Sí	Media	Media	Media
MDS	Lineal/ No lin	Parcialmente	Parcialmente	Media	Media	Media

Análisis de Componentes Principales (PCA)

El PCA es una de las técnicas más utilizadas para la reducción lineal de dimensionalidad. Busca encontrar las direcciones (componentes principales) que maximizan la varianza de los datos, proyectando los datos originales sobre un subespacio de menor dimensión donde la mayor parte de la información se conserva.

Procedimiento PCA:

- Centrar los datos restando la media de cada variable.
- Calcular la matriz de covarianza.
- Obtener los vectores propios (autovectores) y valores propios (autovalores) de la matriz de covarianza.
- Ordenar los autovectores según los autovalores de mayor a menor.
- Seleccionar los k primeros autovectores para formar una base ortogonal y proyectar los datos en ese subespacio.

La transformación resultante es lineal, lo que facilita la interpretación y la reconstrucción aproximada de los datos originales a partir de la representación reducida.

Ejemplo mínimo de PCA en Python

```
import numpy as np
from sklearn.decomposition import PCA
# Simulación de datos
X = np.random.rand(100, 5)
# Reducción a 2 dimensiones
pca = PCA(n_components=2)
X_reduced = pca.fit_transform(X)
print("Varianza explicada:", pca.explained_variance_ratio_)
```

La salida muestra la proporción de la varianza total que explican las dos primeras componentes principales, lo que ayuda a decidir cuántas dimensiones mantener para conservar la información relevante.

t-Distributed Stochastic Neighbor Embedding (t-SNE)

El t-SNE es una técnica no lineal diseñada para visualizar datos de alta dimensión en espacios de dos o tres dimensiones. A diferencia de PCA, t-SNE enfatiza la preservación de las relaciones locales: puntos cercanos en el espacio original tienden a permanecer cercanos en la proyección.

Características principales de t-SNE:

- Convierte las distancias euclídeas entre puntos en probabilidades de similitud.
- Minimiza la divergencia Kullback-Leibler entre las distribuciones de similitud en el espacio alto y bajo dimensional.
- Suele mostrar agrupaciones (clusters) y estructuras locales con gran claridad.
- No es adecuada para proyecciones lineales ni para la interpretación directa de los ejes resultantes.

Procedimiento t-SNE

- Calcular las probabilidades de similitud entre puntos en el espacio original.
- Inicializar aleatoriamente las posiciones en el espacio de menor dimensión.
- Iterativamente, ajustar las posiciones para minimizar la divergencia entre distribuciones de similitud.
- Visualizar el resultado en 2D o 3D para inspección visual de patrones.

Ejemplo mínimo de t-SNE en Python

```
from sklearn.manifold import TSNE
# Simulación de datos
X = np.random.rand(100, 5)
# Reducción a 2 dimensiones
tsne = TSNE(n_components=2, perplexity=30, random_state=42)
X_embedded = tsne.fit_transform(X)
print("Shape de la proyección:", X_embedded.shape)
```

El resultado puede graficarse para explorar posibles agrupaciones u otras estructuras.

Interpretación y aplicación en análisis exploratorio

La reducción de dimensionalidad basada en manifolds sirve como herramienta de análisis exploratorio para:

- Detectar agrupaciones naturales (clustering visual).
- Identificar outliers o valores atípicos.
- Sugerir relaciones no evidentes entre variables.
- Reducir el ruido y la redundancia antes de aplicar otros algoritmos de aprendizaje.

Mientras que PCA permite interpretar la importancia relativa de cada componente y reconstruir los datos aproximados, t-SNE y otras técnicas no lineales suelen emplearse principalmente para visualización e identificación de patrones, sin una interpretación directa de los ejes resultantes.

Aplicación práctica con Scikit-learn

Las bibliotecas de Python como Scikit-learn ofrecen implementaciones eficientes de técnicas de reducción de dimensionalidad.

Pipeline típico para reducción de dimensionalidad

- Seleccionar y cargar el conjunto de datos.
- Estandarizar o normalizar las variables si es necesario.
- Elegir la técnica de reducción de dimensionalidad adecuada (PCA para relaciones lineales, t-SNE para patrones no lineales o visualización).

- Ajustar el modelo y transformar los datos.
- Visualizar o analizar los resultados.

Ejemplo práctico: Iris dataset

```
from sklearn import datasets
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt
# Cargar datos
iris = datasets.load_iris()
X = iris.data
y = iris.target
# Estandarizar
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
# t-SNE
tsne = TSNE(n_components=2, perplexity=30, random_state=42)
X_tsne = tsne.fit_transform(X_scaled)
# Visualización PCA
plt.figure(figsize=(8,4))
plt.subplot(1,2,1)
plt.scatter(X_pca[:,0], X_pca[:,1], c=y, cmap='viridis')
plt.title('PCA')
# Visualización t-SNE
plt.subplot(1,2,2)
plt.scatter(X_tsne[:,0], X_tsne[:,1], c=y, cmap='viridis')
plt.title('t-SNE')
plt.show()
```

La comparación visual revela que t-SNE suele separar mejor las clases en este tipo de datos, aunque lo hace a costa de una interpretación menos directa de los ejes.

Consideraciones prácticas y limitaciones

El uso de técnicas de reducción de dimensionalidad debe guiarse por el conocimiento de la estructura de los datos y los objetivos del análisis:

- PCA es adecuado cuando la varianza relevante se distribuye sobre componentes lineales. Es eficiente, interpretable y adecuado para preprocesamiento previo a otros algoritmos.
- t-SNE es preferible para visualización exploratoria, especialmente cuando se sospecha la presencia de estructuras no lineales. No es recomendable para transformar nuevos datos fuera del conjunto de entrenamiento, debido a su naturaleza no paramétrica.
- Escalabilidad: Técnicas como t-SNE pueden ser lentas para grandes volúmenes de datos. Para grandes conjuntos, se recomienda muestrear o emplear variantes optimizadas.
- Elección de hiperparámetros: Especialmente en métodos no lineales, los resultados pueden ser sensibles a parámetros como la 'perplejidad' en t-SNE.
- Interpretabilidad: Los ejes de proyección en técnicas no lineales no suelen corresponder a combinaciones fácilmente interpretables de las variables originales.

Extensión a otros métodos de reducción de dimensionalidad

Además de PCA y t-SNE, existen otras técnicas relevantes para la explotación de manifolds:

- Isomap: Busca preservar las distancias geodésicas (a lo largo del manifold), lo que permite capturar estructuras globales no lineales.
- Locally Linear Embedding (LLE): Preserva las relaciones lineales locales entre vecinos cercanos.
- Multidimensional Scaling (MDS): Intenta conservar las distancias entre todos los puntos, lineal o no linealmente.

La elección adecuada depende de la naturaleza de los datos y de los objetivos específicos del análisis.

Integración con el aprendizaje no supervisado

La reducción de dimensionalidad basada en manifolds complementa los algoritmos de aprendizaje no supervisado, como clustering y detección de anomalías.

Al proyectar los datos sobre un espacio de menor dimensión que preserva su estructura relevante, se facilita la tarea de algoritmos como K-means, DBSCAN o Gaussian Mixture Models, mejorando la eficiencia y, en ocasiones, la calidad de los resultados.

Por ejemplo, aplicar PCA antes de un clustering puede eliminar variables redundantes y ruido, permitiendo que los algoritmos de agrupamiento se centren en los patrones esenciales. De igual modo, la visualización con t-SNE puede sugerir el número adecuado de clusters o revelar la presencia de subgrupos inesperados.

Micro-caso aplicado: Un equipo de análisis biomédico recibe señales de electrocardiograma (ECG) de 12 derivaciones, registradas a 1000 muestras por segundo durante varios minutos. El dataset resultante posee miles de variables por observación. Antes de aplicar clustering para identificar patrones de arritmia, el equipo utiliza PCA para reducir la dimensionalidad a 10 componentes principales que explican el 95% de la varianza, facilitando la visualización y el agrupamiento efectivo de los registros similares en el espacio reducido.

Resumen comparativo de técnicas (tabla extendida)

Técnica	Linealidad	Preserva estructura global	Preserva estructura local	Escalabilidad	Interpretabilidad	Ideal para
PCA	Sí	Sí	Parcialmente	Alta	Alta	Preprocesamiento, visualización simple, compresión de datos
t-SNE	No	No	Sí	Media	Baja	Visualización, descubrimiento de clusters
Isomap	No	Sí	Sí	Media	Media	Captura de manifolds curvos globales
LLE	No	No	Sí	Media	Media	Análisis de vecindarios locales

Técnica	Linealidad	Preserva estructura global	Preserva estructura local	Escalabilidad	Interpretabilidad	Ideal para
MDS	Parcial	Parcial	Parcial	Media	Media	Preservar distancias generales

La reducción de dimensionalidad basada en manifolds constituye una herramienta esencial en el aprendizaje no supervisado, permitiendo a los profesionales descubrir y aprovechar estructuras ocultas en los datos, mejorar la eficiencia de los algoritmos y obtener representaciones más comprensibles y manejables.

Ejercicio

Aplica PCA y t-SNE sobre un conjunto de datos de tu elección (por ejemplo, imágenes, registros biomédicos o textos vectorizados). Compara visualmente los resultados, identifica posibles agrupaciones o patrones, y reflexiona sobre las diferencias que observas en la representación y agrupamiento según la técnica utilizada.

3.6. Análisis de la cesta

El análisis de la cesta representa una técnica central en el aprendizaje no supervisado, orientada a identificar patrones de compra, correlaciones y relaciones ocultas entre productos dentro de grandes conjuntos de datos transaccionales. Utilizado extensamente en entornos minoristas, supermercados, plataformas de comercio electrónico y sistemas de recomendación, este método permite inferir reglas de asociación que describen la probabilidad de que ciertos artículos se adquieran conjuntamente. La aplicación de estos conocimientos posibilita optimizar estrategias de venta cruzada, promociones y disposición de productos, incrementando la eficiencia operativa y el valor para el cliente.

Fundamentos del análisis de la cesta

El análisis de la cesta parte de la representación de los datos transaccionales como una colección de transacciones, donde cada transacción corresponde a una cesta de la compra individual y cada cesta contiene un subconjunto de productos disponibles. El objetivo consiste en identificar conjuntos de artículos que aparecen

conjuntamente con una frecuencia significativa, superando umbrales determinados de relevancia.

Este proceso se apoya en los siguientes conceptos clave:

- Reglas de asociación: Implican relaciones del tipo "si A, entonces B", donde A y B son subconjuntos de artículos. Por ejemplo, la regla {pan, mantequilla} → {leche} sugiere que cuando un cliente adquiere pan y mantequilla, existe una alta probabilidad de que también compre leche.
- Ítems y transacciones: Los ítems (productos) se agrupan en cada transacción (compra). El conjunto de todas las transacciones constituye la base para el análisis.
- Frecuencia de ítems: El número de transacciones en las que aparece un ítem o conjunto de ítems.

El valor operativo de estas reglas está determinado por métricas cuantitativas que evalúan su interés y utilidad.

Métricas esenciales: soporte, confianza y elevación

Para cuantificar la relevancia y utilidad de una regla de asociación, se emplean tres métricas principales:

- Soporte (Support): Proporción de transacciones en las que aparece un conjunto de ítems respecto al total. Refleja la frecuencia relativa de la combinación de productos analizada.

  Ejemplo: Si 100 de 1000 transacciones contienen {pan, leche}, el soporte es 0.1 (10%).

  Fórmula:

$$\text{soporte}\left(A \to B\right) = \frac{\text{transacciones que contienen}}{A \cup B}\text{total de transacciones}$$

- Confianza (Confidence): Probabilidad de que una transacción contenga el ítem B dado que ya contiene el ítem A. Mide la fiabilidad de la inferencia A → B.

  Ejemplo: Si en 80 de 100 transacciones con pan también se compra leche, la confianza de {pan} → {leche} es 0.8 (80%).

  Fórmula:

$$\text{confianza}\left(A \to B\right) = \frac{\text{transacciones que contienen}}{A \cup B}\text{transacciones que contienen}A$$

- Elevación (Lift): Relación entre la confianza de la regla y el soporte de B. Indica hasta qué punto la presencia de A incrementa la probabilidad de B, comparado con la ocurrencia independiente de B.

  Ejemplo: Si la confianza de {pan} → {leche} es 0.8 y el soporte de {leche} es 0.5, la elevación es 1.6. Un valor mayor que 1 implica correlación positiva.

  Fórmula:

$$\text{elevació n}\left(A \to B\right) = \frac{\text{confianza}(A \to B)}{\text{soporte}(B)}$$

Una regla con soporte bajo puede carecer de relevancia práctica, mientras que una confianza alta sin elevación significativa indica que la relación puede ser explicada por la frecuencia individual de B. Por ello, se busca siempre un equilibrio entre soporte, confianza y elevación.

Algoritmos principales para el análisis de la cesta

El análisis eficiente de grandes volúmenes de datos transaccionales requiere algoritmos especializados que permitan identificar reglas de asociación relevantes sin incurrir en costes computacionales excesivos. Los dos métodos más utilizados son Apriori y FP-Growth.

Apriori

El algoritmo Apriori explora iterativamente todos los subconjuntos posibles de ítems, identificando aquellos que cumplen con un umbral mínimo de soporte. La clave de Apriori es la propiedad de anti-monotonía: cualquier subconjunto de un conjunto frecuente también es frecuente. Procedimiento básico de Apriori:

- Identificar todos los ítems individuales cuyo soporte supera el umbral mínimo.
- Generar conjuntos de ítems de tamaño 2 a partir de los ítems frecuentes.
- Evaluar el soporte de estos conjuntos. Retener solo los que cumplen el umbral.
- Repetir el proceso para subconjuntos de tamaño k, incrementando k en cada iteración.
- Finalizar cuando no se generan más conjuntos frecuentes.
- Generar reglas de asociación a partir de los conjuntos frecuentes, evaluando confianza y elevación.

Ventajas:

- Implementación intuitiva.
- Fácil interpretación de resultados.

Limitaciones:

- Coste computacional elevado en bases de datos extensas, debido a la generación exhaustiva de candidatos.
- Gran consumo de memoria para conjuntos de ítems grandes.

FP-Growth

El algoritmo FP-Growth (Frequent Pattern Growth) optimiza el proceso evitando la generación explícita de todos los candidatos posibles. Utiliza una estructura de árbol compacta denominada FP-Tree, que almacena conjuntos de ítems frecuentes de manera eficiente.

Procedimiento básico de FP-Growth:

- Construcción del FP-Tree:
  - Calcular el soporte de cada ítem.
  - Ordenar los ítems en cada transacción según la frecuencia descendente.
  - Insertar las transacciones en el FP-Tree, compartiendo prefijos comunes.
- Extracción de patrones frecuentes:
  - Recorrer el FP-Tree para identificar todos los conjuntos de ítems frecuentes sin generación de candidatos explícitos.
  - Extraer reglas de asociación a partir de los patrones frecuentes.

Ventajas:

- Eficiencia computacional, especialmente en bases de datos grandes.
- Menor uso de memoria comparado con Apriori.

Limitaciones:

- Implementación más compleja.
- Menor interpretabilidad de la estructura interna.

Algoritmo	Coste computacional	Uso de memoria	Adaptabilidad a grandes datasets	Facilidad de implementación
Apriori	Alto	Alto	Limitada	Alta
FP-Growth	Bajo	Bajo	Excelente	Media

La elección entre Apriori y FP-Growth depende de la escala del problema y los recursos computacionales disponibles.

Implementación en Python

Python ofrece librerías especializadas para el análisis de la cesta, como mlxtend, que facilita la aplicación de los algoritmos Apriori y FP-Growth y la generación de reglas de asociación.

Preparación de datos

El primer paso consiste en transformar el conjunto de datos transaccionales en una matriz binaria (uno por ítem presente, cero por ítem ausente por cada transacción). Este formato es requerido por la mayoría de las funciones de minería de asociaciones.

Ejemplo de matriz de transacciones

Transacción	Pan	Leche	Mantequilla	Queso	Jugo
1	1	1	0	1	0
2	0	1	1	0	1
3	1	1	1	0	1
4	1	0	1	1	0

Este formato puede obtenerse mediante la función `pd.get_dummies()` de pandas o mediante el método `TransactionEncoder` de mlxtend.

Ejemplo práctico: Apriori en Python

Supóngase un conjunto de datos de transacciones similar al anterior. El objetivo es identificar reglas de asociación relevantes.

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules
# Datos de ejemplo
dataset = [
    ['pan', 'leche', 'queso'],
    ['leche', 'mantequilla', 'jugo'],
    ['pan', 'leche', 'mantequilla', 'jugo'],
    ['pan', 'mantequilla', 'queso'],
]
# Codificación de las transacciones
te = TransactionEncoder()
te_ary = te.fit(dataset).transform(dataset)
```

```
df = pd.DataFrame(te_ary, columns=te.columns_)
# Identificación de conjuntos frecuentes
frequent_itemsets = apriori(df, min_support=0.5, use_colnames=True)
# Generación de reglas de asociación
rules = association_rules(frequent_itemsets, metric="confidence", min_
threshold=0.7)
print(rules[['antecedents', 'consequents', 'support', 'confidence', 'lift']])
```

El resultado muestra las reglas identificadas junto con sus métricas de soporte, confianza y elevación. Este enfoque permite ajustar los umbrales para filtrar sólo las reglas más relevantes en función de los objetivos del análisis.

Ejemplo práctico: FP-Growth en Python

El algoritmo FP-Growth puede aplicarse sobre la misma matriz binaria, proporcionando mayor eficiencia en conjuntos de datos extensos.

```
from mlxtend.frequent_patterns import fpgrowth
# Identificación de conjuntos frecuentes con FP-Growth
frequent_itemsets_fp = fpgrowth(df, min_support=0.5, use_colnames=True)
# Generación de reglas de asociación
rules_fp = association_rules(frequent_itemsets_fp, metric="confidence",
min_threshold=0.7)
print(rules_fp[['antecedents', 'consequents', 'support', 'confidence',
'lift']])
```

Ambos algoritmos retornan una estructura de datos que permite seleccionar y analizar reglas por sus métricas, facilitando la toma de decisiones informada.

Interpretación y uso de las reglas de asociación

La utilidad de las reglas de asociación extraídas depende de su interpretación adecuada en el contexto de negocio o aplicación. Existen criterios operativos para filtrar y priorizar reglas:

- Soporte mínimo: Descarta reglas poco frecuentes, que no aportan valor por su baja incidencia.
- Confianza mínima: Selecciona reglas con alta fiabilidad, minimizando falsos positivos.
- Elevación significativa: Prioriza reglas con correlación positiva real, evitando asociaciones espurias por alta frecuencia individual.

Adicionalmente, se consideran factores como la acciónabilidad de la regla (¿es posible implementar una promoción conjunta?), el valor económico de los ítems involucrados y la estacionalidad de las compras.

Métrica	Interpretación operativa
Soporte	Relevancia práctica, frecuencia de la combinación
Confianza	Fiabilidad de la inferencia
Elevación	Fuerza de la asociación comparada con la ocurrencia aleatoria

Un análisis efectivo integra estas métricas con información adicional, como márgenes de ganancia, logística del inventario y preferencias del cliente.

Consideraciones sobre la preparación de datos

La calidad del análisis depende en gran medida de la correcta preparación de los datos. Algunos aspectos clave incluyen:

- Eliminación de duplicados: Asegura que cada transacción se registre solo una vez.
- Homogeneización de ítems: Unificación de denominaciones, categorías y formatos para evitar segmentación artificial.
- Filtrado de productos irrelevantes: Exclusión de ítems promocionales, obsequios o productos fuera de análisis.
- Gestión de datos faltantes: Imputación, eliminación o tratamiento según la importancia del producto.

El preprocesamiento minucioso garantiza que los patrones identificados sean representativos y útiles.

Ampliaciones y variantes del análisis de la cesta

El análisis tradicional de la cesta puede extenderse mediante variantes para abordar escenarios complejos:

- Reglas multietapa o secuenciales: Considera el orden de compra de productos, útil en análisis de carritos abandonados o secuencias de consumo.

- Reglas con restricciones: Impone condiciones sobre categorías, valores o relaciones jerárquicas.
- Análisis ponderado: Incorpora la cantidad o valor monetario de los productos, ponderando la relevancia de las reglas.

Estas extensiones permiten adaptar el análisis a contextos específicos como telecomunicaciones, banca o servicios, donde la "cesta" corresponde a paquetes de servicios, combinaciones de productos financieros o secuencias de acciones.

Micro-caso aplicado: En una cadena de supermercados, el análisis de la cesta revela que los clientes que compran café y azúcar presentan un 85% de probabilidad de adquirir leche en la misma transacción, con una elevación de 1.7 sobre la media. Esta información se utiliza para diseñar promociones conjuntas y reorganizar la disposición de productos, incrementando las ventas cruzadas y la satisfacción del cliente.

Limitaciones y buenas prácticas

El análisis de la cesta, aunque poderoso, presenta ciertas limitaciones:

- Explosión combinatoria: El número de posibles combinaciones crece exponencialmente con la cantidad de productos, lo que puede dificultar el análisis en grandes catálogos.
- Asociaciones espurias: Algunas reglas pueden aparecer por azar o por efecto de la alta frecuencia de ciertos productos básicos.
- No implica causalidad: La correlación entre productos no garantiza relación causal; se recomienda aplicar juicio experto antes de tomar decisiones estratégicas.
- Evolución temporal: Los patrones pueden variar por temporada, promociones o cambios en el surtido. Es necesario actualizar el análisis periódicamente.

Buenas prácticas para maximizar el valor del análisis:

- Ajustar los umbrales de soporte y confianza según la realidad operativa y el tamaño del dataset.
- Complementar el análisis con visualización de datos, facilitando la interpretación de resultados.
- Validar las reglas identificadas mediante experimentos controlados o análisis retrospectivo.

- Utilizar el análisis de la cesta como insumo para sistemas de recomendación, planificación de inventario y diseño de promociones.

Aplicaciones prácticas en distintos sectores

El análisis de la cesta trasciende el entorno minorista y se aplica en múltiples sectores:

- Comercio electrónico: Recomendación de productos ("los clientes que compraron esto, también compraron…").
- Telecomunicaciones: Identificación de paquetes de servicios frecuentemente contratados juntos.
- Banca y seguros: Detección de productos financieros o pólizas complementarias adquiridas por el mismo cliente.
- Salud: Agrupación de medicamentos comúnmente prescritos juntos.
- Industria y manufactura: Análisis de repuestos o insumos consumidos conjuntamente en procesos productivos.

Estas aplicaciones demuestran la versatilidad y valor estratégico del análisis de la cesta en la toma de decisiones basadas en datos.

Implementación avanzada y optimización

El rendimiento del análisis puede mejorarse mediante técnicas adicionales:

- Optimización de parámetros:
- Ajuste dinámico de umbrales de soporte y confianza.
- Segmentación de clientes para análisis personalizado.
- Paralelización del procesamiento:
- Utilización de frameworks distribuidos (p. ej., Spark MLlib) para grandes volúmenes de datos.
- Integración con modelos predictivos:
- Alimentar sistemas de recomendación automática, motores de personalización o alertas de inventario.

Además, el desarrollo de dashboards interactivos permite visualizar reglas y patrones relevantes, facilitando la toma de decisiones en tiempo real.

Comparativa de herramientas para análisis de la cesta en Python

Herramienta/Librería	Algoritmos soportados	Facilidad de uso	Escalabilidad	Integración con pandas
mlxtend	Apriori, FP-Growth	Alta	Media	Excelente
Orange3	Apriori	Alta (GUI)	Media	Limitada
PyCaret	Apriori	Alta	Media	Excelente
Spark MLlib	FP-Growth	Media	Alta	Requiere adaptación

La selección de la herramienta depende del tamaño del dataset, la experiencia del equipo y los sistemas existentes.

Consideraciones éticas y de privacidad

El análisis de la cesta utiliza datos transaccionales que pueden contener información sensible sobre los hábitos y preferencias de los clientes. Es fundamental cumplir con regulaciones de protección de datos y anonimizar los registros cuando corresponda. La explotación ética de los patrones descubiertos refuerza la confianza y la percepción positiva del cliente.

Integración con estrategias de negocio

El valor del análisis de la cesta se maximiza cuando las reglas identificadas alimentan directamente la toma de decisiones:

- Promociones dirigidas basadas en patrones de compra reales.
- Optimización de la disposición de productos en tiendas físicas o digitales.
- Personalización de recomendaciones y campañas de marketing.
- Mejora de la gestión de inventarios y reducción de roturas de stock.

Actividades

8. ¿Cómo aplicarías clustering con k-means, k-medoids, DBSCAN y agglomerative sobre un mismo dataset sin etiquetas, justificando la elección

de k o eps, comparando la estabilidad de las particiones y evaluando la calidad con silhouette, Calinski-Harabasz y Davies-Bouldin, dejando trazabilidad reproducible del proceso?

9. ¿De qué manera llevarías a cabo un ejercicio de biclustering para co-segmentar observaciones y variables (por ejemplo, clientes-productos o pacientes-síntomas), describiendo el criterio de agrupación obtenido y cómo interpretarías los patrones simultáneos resultantes en términos operativos?

10. ¿Cómo ejecutarías una reducción de dimensionalidad con PCA para cuantificar la varianza explicada y, en paralelo, una proyección con t-SNE y UMAP para visualización, comparando las representaciones obtenidas y justificando la pérdida de información aceptable para el análisis?

11. ¿Cómo realizarías un análisis de cesta (market basket) generando reglas de asociación y reportando soporte, confianza y lift, explicando cómo priorizarías reglas accionables y cómo validarías que los patrones extraídos son coherentes con el comportamiento observado en los datos?

GLOSARIO

A

Accuracy: Métrica que mide la proporción de aciertos de un modelo de clasificación sobre el total de predicciones.

Anaconda: Distribución científica de Python que facilita la gestión de entornos y la instalación de bibliotecas.

Aprendizaje automático: Rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos.

Aprendizaje supervisado: Técnica de Machine Learning que utiliza datos etiquetados para entrenar modelos predictivos.

Aprendizaje no supervisado: Técnica que analiza datos sin etiquetas para descubrir patrones o estructuras ocultas.

Array: Estructura de datos ordenada usada para almacenar valores numéricos o vectores en librerías como NumPy.

B

Bagging: Método de combinación de modelos que mejora la estabilidad y precisión mediante el promedio de resultados.

Bias (sesgo): Error sistemático en un modelo cuando las predicciones se desvían de los valores reales.

Biclustering: Técnica de agrupamiento simultáneo de observaciones y variables en un conjunto de datos.

Booleano: Tipo de dato lógico con dos valores posibles, True o False.

C

Clasificación: Tipo de tarea supervisada que asigna una etiqueta o categoría a cada observación.

Clustering: Método no supervisado que agrupa observaciones similares en función de su distancia o similitud.

CPU: Unidad central de procesamiento utilizada para ejecutar operaciones computacionales en modelos de ML.

Cuaderno (Notebook): Entorno interactivo que combina código, visualizaciones y texto, como Jupyter Notebook.

D

DataFrame: Estructura de datos de pandas que organiza información en filas y columnas.

Dataset: Conjunto de datos utilizado para entrenar, validar o probar un modelo de Machine Learning.

Deep Learning: Subcampo del aprendizaje automático basado en redes neuronales profundas.

Dimensionalidad: Número de variables o características presentes en un conjunto de datos.

E

Entrenamiento: Proceso mediante el cual un modelo ajusta sus parámetros a partir de datos etiquetados o no etiquetados.

Entorno virtual: Espacio aislado de Python que permite gestionar dependencias sin interferir con otros proyectos.

Error cuadrático medio (MSE): Métrica que mide el promedio de los errores al cuadrado entre predicciones y valores reales.

Evaluación: Etapa del flujo de Machine Learning donde se mide el rendimiento del modelo mediante métricas específicas.

F

Feature (característica): Atributo o variable que describe una observación en un conjunto de datos.

F1-score: Métrica que combina precisión y recall mediante su media armónica.

Función de pérdida: Expresión matemática que mide la diferencia entre la predicción del modelo y el valor real.

H

Hiperparámetro: Parámetro configurable antes del entrenamiento que controla el comportamiento del modelo.

K

K-means: Algoritmo de agrupamiento que asigna puntos a k clústeres en función de su cercanía al centroide.

K-fold: Técnica de validación cruzada que divide los datos en k subconjuntos para evaluar la estabilidad del modelo.

L

Lasso: Método de regularización que penaliza la magnitud de los coeficientes para reducir la complejidad del modelo.

Learning rate (tasa de aprendizaje): Parámetro que controla la magnitud del ajuste de los pesos en cada iteración.

Logistic Regression: Modelo lineal utilizado para tareas de clasificación binaria.

M

Machine Learning: Conjunto de técnicas que permiten a las máquinas aprender a partir de datos y mejorar su rendimiento.

Matriz de confusión: Tabla que resume las predicciones correctas e incorrectas de un modelo de clasificación.

Modelo: Representación matemática entrenada para realizar predicciones o inferencias sobre nuevos datos.

MSE (Mean Squared Error): Error cuadrático medio utilizado en regresión como medida del desempeño.

N

Normalización: Proceso de escalado de variables para mantenerlas dentro de un rango comparable.

NumPy: Librería de Python orientada al cálculo numérico y manejo de matrices.

P

Pandas: Biblioteca de Python utilizada para manipulación y análisis de datos tabulares.

Pipeline: Flujo automatizado que encadena pasos de preprocesamiento y modelado en un proyecto de ML.

PCA (Análisis de Componentes Principales): Técnica de reducción de dimensionalidad que conserva la varianza principal.

Precisión (Precision): Métrica que mide la proporción de verdaderos positivos entre todas las predicciones positivas.

Predicción: Resultado obtenido por un modelo tras aplicar el aprendizaje sobre nuevos datos.

R

Random Forest: Conjunto de árboles de decisión que mejora la precisión mediante el promedio de resultados.

Recall (Sensibilidad): Métrica que mide la capacidad del modelo para identificar correctamente los casos positivos.

Regresión: Tipo de tarea supervisada que predice valores numéricos continuos.

S

Scikit-learn: Biblioteca de Python que implementa algoritmos y utilidades de Machine Learning.

Sesgo (Bias): Diferencia entre la predicción promedio del modelo y los valores reales.

Silhouette: Métrica para evaluar la calidad de un agrupamiento no supervisado.

SMOTE: Técnica de sobremuestreo usada para equilibrar clases desbalanceadas.

SVM (Support Vector Machine): Algoritmo de clasificación que busca el hiperplano que mejor separa las clases.

T

TensorFlow: Biblioteca de código abierto para el desarrollo de modelos de Deep Learning.

Train/Test Split: División de datos en conjuntos de entrenamiento y prueba para evaluar la generalización.

V

Validación cruzada: Técnica para evaluar el rendimiento de un modelo en múltiples particiones del conjunto de datos.

Z

ZeroDivisionError: Excepción en Python que se produce al intentar dividir entre cero.

AUTOEVALUACIÓN

1. ¿Qué librería de Python permite crear pipelines con transformaciones encadenadas y modelos integrados?

a. pandas

b. matplotlib

c. scikit-learn

d. keras

2. ¿Cuál de las siguientes métricas es más adecuada para evaluar un modelo de clasificación binaria con clases desbalanceadas?

a. Accuracy

b. F1-score

c. MAE

d. R^2

3. ¿Qué técnica se utiliza para corregir el desbalanceo de clases generando ejemplos sintéticos?

a. PCA

b. UMAP

c. SMOTE

d. Lasso

4. ¿Qué algoritmo de aprendizaje no supervisado agrupa observaciones en función de su proximidad al centroide más cercano?

a. Random Forest

b. k-means

c. Regresión logística

d. DBSCAN

5. ¿Cuál es el propósito principal de la función fit() en scikit-learn?

a. Dividir el dataset

b. Visualizar resultados

c. Ajustar el modelo a los datos

d. Guardar el modelo entrenado

6. ¿Qué biblioteca se utiliza principalmente para crear gráficos interactivos en Python?

a. pandas

b. numpy

c. imbalanced-learn

d. plotly

7. ¿Qué tipo de aprendizaje se basa en recompensas y penalizaciones dentro de un entorno interactivo?

a. Supervisado

b. No supervisado

c. Reforzado

d. Regularizado

8. ¿Cuál es una característica del algoritmo Random Forest?

a. Genera clústeres sin necesidad de etiquetas

b. Reduce la dimensionalidad

c. Combina múltiples árboles para mejorar precisión

d. Se utiliza exclusivamente para regresión

9. Explica brevemente el flujo de trabajo típico de un proyecto de Machine Learning.

10.Menciona tres métricas comunes para evaluar modelos de clasificación y su función principal.

Orbe.ai+

Orbe.ai+: La herramienta definitiva para docentes

En el Área del Docente de **Orbe.ai+** encontrarás todas las herramientas necesarias para una gestión ágil de tu trabajo, unificadas en una potente aplicación diseñada especialmente para docentes.
Disfruta de acceso exclusivo a contenido educativo de calidad y funcionalidades avanzadas que simplifican tu día a día en el aula.

¿Qué ofrece Orbe.ai+?

- **Chat IA:** Resuelve dudas y crea recursos de forma automatizada.
- **Acceso ilimitado a contenidos:** Encuentra todos los temas, actividades, pruebas y soluciones necesarias para tus clases.
- **Visor de PDF:** Gestiona y organiza tus documentos de forma eficiente.

¿Cómo empezar?

¡Prueba Orbe.ai+ gratis durante **3 días** y descubre su potencial!

Escanea el QR para solicitar tu acceso.

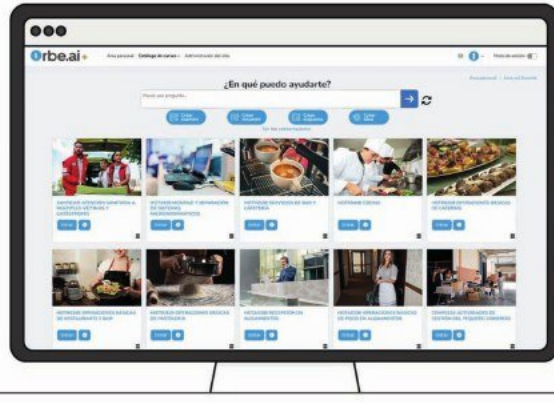

951 17 10 28 - info@orbeformacion.com - www.areadeldocente.com

9000003337012